

ESPECIALIZACIÓN EN CIENCIA DE DATOS

Guía de instalación paso a paso

Databricks en Amazon Web Services

Data Lakehouse con Amazon S3 y MLOps serverless

Ing. Santiago Alejandro Zuñiga Melo



Índice

Presentación **3**

1. Creación de la cuenta de AWS **3**
1.1. Crear una cuenta nueva . . . 3
1.2. Correo y nombre de la cuenta . . . 4
1.3. Verificar el correo . . . 4
1.4. Crear la contraseña . . . 5
1.5. Elegir el plan . . . 5
1.6. Datos de contacto . . . 6
1.7. Información de facturación . . . 6
1.8. Confirmar el teléfono . . . 7
1.9. Escribir el código SMS . . . 7
1.10. Consola de AWS . . . 8

2. Plan de pago y presupuesto **8**
2.1. Buscar Facturación . . . 9
2.2. Página de facturación . . . 9
2.3. Actualizar a plan de pago . . . 10
2.4. Confirmar la actualización . . . 10
2.5. Crear un presupuesto . . . 11
2.6. Indicar el correo de alertas . . . 11
2.7. Presupuesto creado . . . 12

3. Suscripción a Databricks **12**
3.1. Buscar Databricks . . . 12
3.2. Suscribirse . . . 13
3.3. Verificar la suscripción . . . 13

4. Lago de datos en Amazon S3 **14**
4.1. Buscar Amazon S3 . . . 14
4.2. Crear el bucket . . . 14
4.3. Nombre y espacio regional . . . 15
4.4. Control de versiones . . . 15
4.5. Bucket creado . . . 16
4.6. Crear las carpetas . . . 16
4.7. Verificar la estructura . . . 17

5. Claves de acceso **17**

5.1. Credenciales de seguridad 17
5.2. Aceptar la advertencia 18
5.3. Guardar la clave 18

6. Espacio de trabajo de Databricks en AWS 19
6.1. Crear la cuenta de Databricks 19
6.2. Verificar el periodo de prueba 20

7. Conexión y ejecución del proyecto 20
7.1. Importar el cuaderno 20
7.2. Revisar la descripción 21
7.3. Configurar las credenciales 21
7.4. Validar la conexión 22
7.5. Ingesta en la capa raw 23
7.6. Verificar en Amazon S3 23
7.7. Experimento científico 24
7.8. Curva de convergencia 24
7.9. Registrar y exportar el modelo 25
7.10. Verificar el modelo en S3 25
7.11. Conclusión del experimento 26

Presentación

Esta guía documenta el procedimiento presentado en el video tutorial *Databricks en AWS*: una arquitectura de *Data Lakehouse* y MLOps con un lago de datos en Amazon S3 y Databricks Serverless para procesar los registros del conjunto *California Housing*, evaluar una hipótesis sobre la convergencia del error en bosques aleatorios y exportar el modelo entrenado a Amazon S3. Cada paso incluye la captura de la pantalla correspondiente.

Importante

Este procedimiento requiere una cuenta de AWS con tarjeta y un cambio a plan de pago; los servicios se cobran por uso. Revise los costos, configure el presupuesto de la sección 2.5 y elimine los recursos que no utilice al terminar la práctica.

Nota

Por seguridad, los datos personales y las credenciales aparecen difuminados o cubiertos en las capturas: correo, códigos de verificación, teléfono, dirección, datos de pago y claves de acceso. Cada estudiante debe diligenciar esos campos con sus propios datos.

Requisitos previos. Navegador actualizado, cuenta institucional con acceso a Microsoft Authenticator, una tarjeta de crédito o débito y un teléfono móvil para las verificaciones de AWS.

1. Creación de la cuenta de AWS

1.1 Crear una cuenta nueva

En la pantalla de inicio de sesión de la consola de AWS, seleccione **Create a new AWS account**.

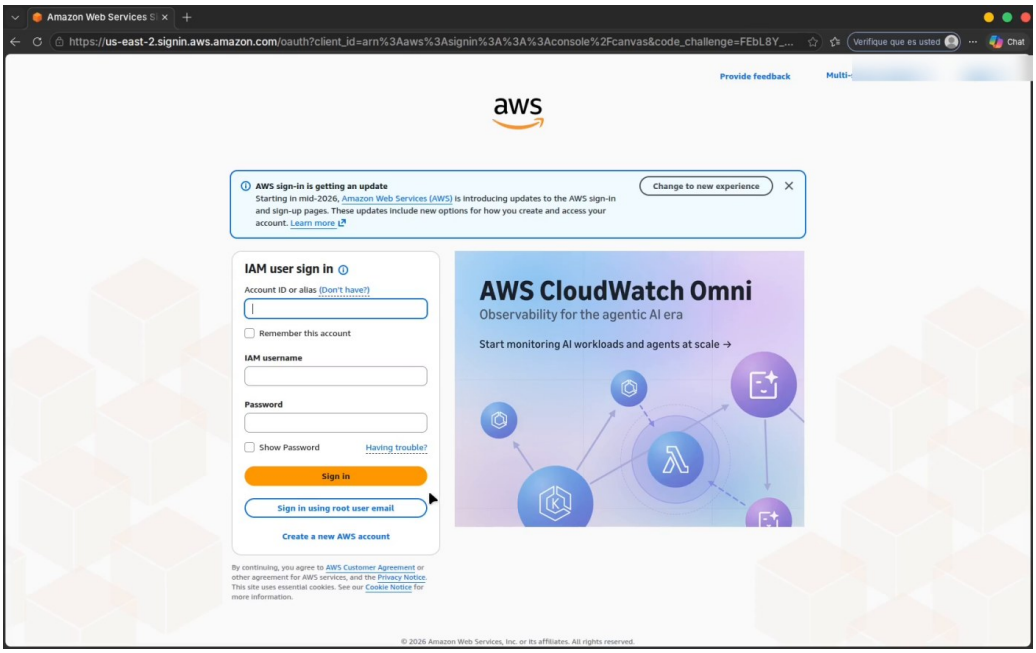


Figura 1: Crear una cuenta nueva

1.2 Correo y nombre de la cuenta

Escriba el correo institucional en **Root user email address**, asigne un nombre en **AWS account name** y pulse **Verify email address**.

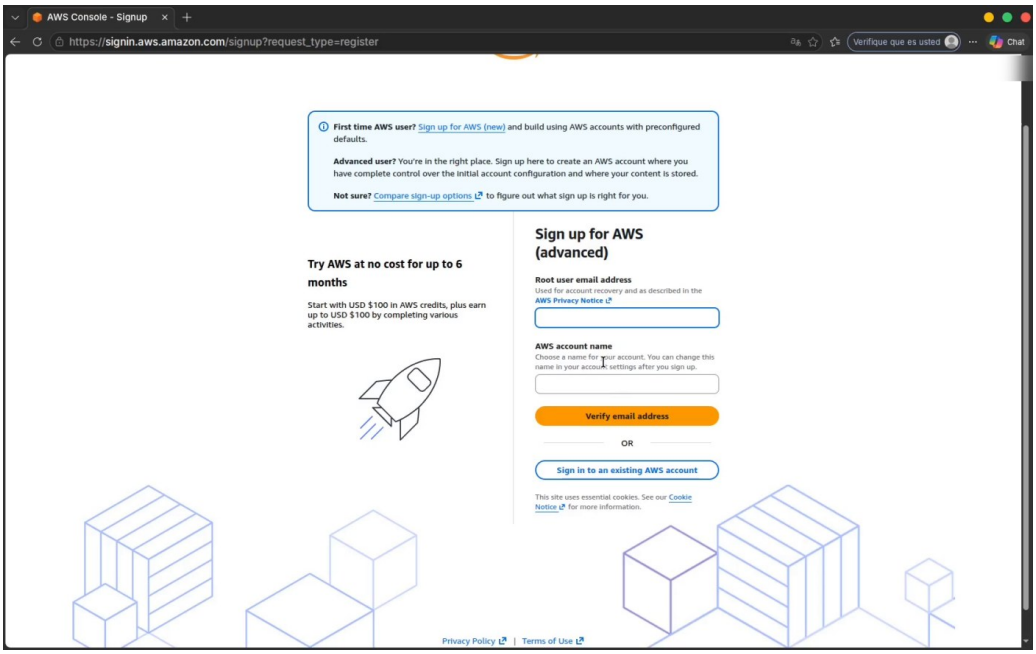


Figura 2: Correo y nombre de la cuenta

1.3 Verificar el correo

Copie el código recibido en el correo, escríbalo en **Verification code** y pulse **Verify**.

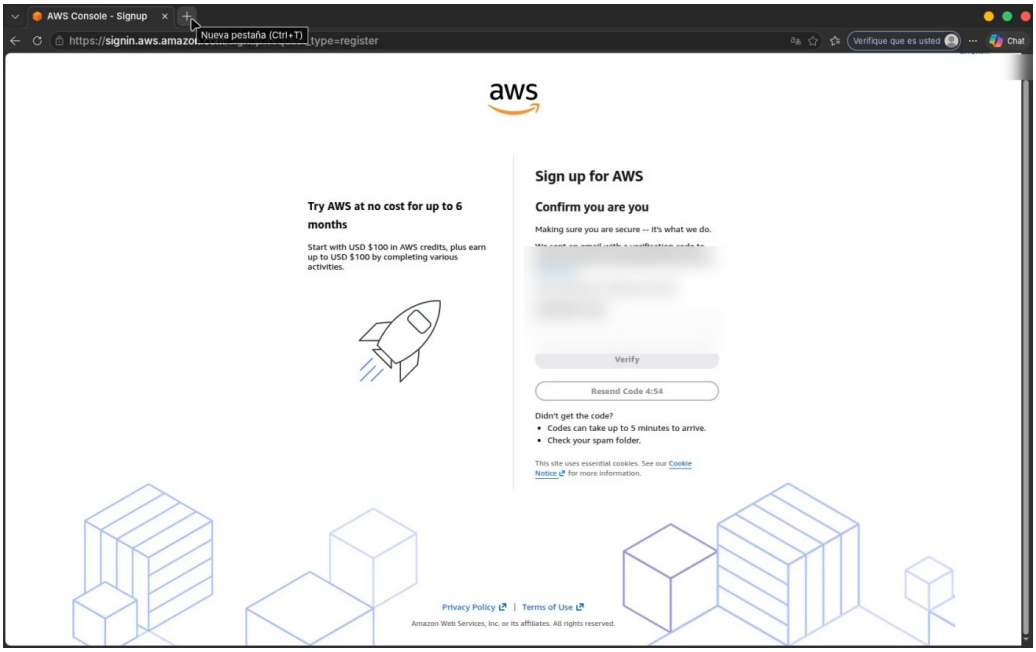


Figura 3: Verificar el correo

1.4 Crear la contraseña

Defina y confirme la contraseña del usuario raíz; luego pulse **Continue**.

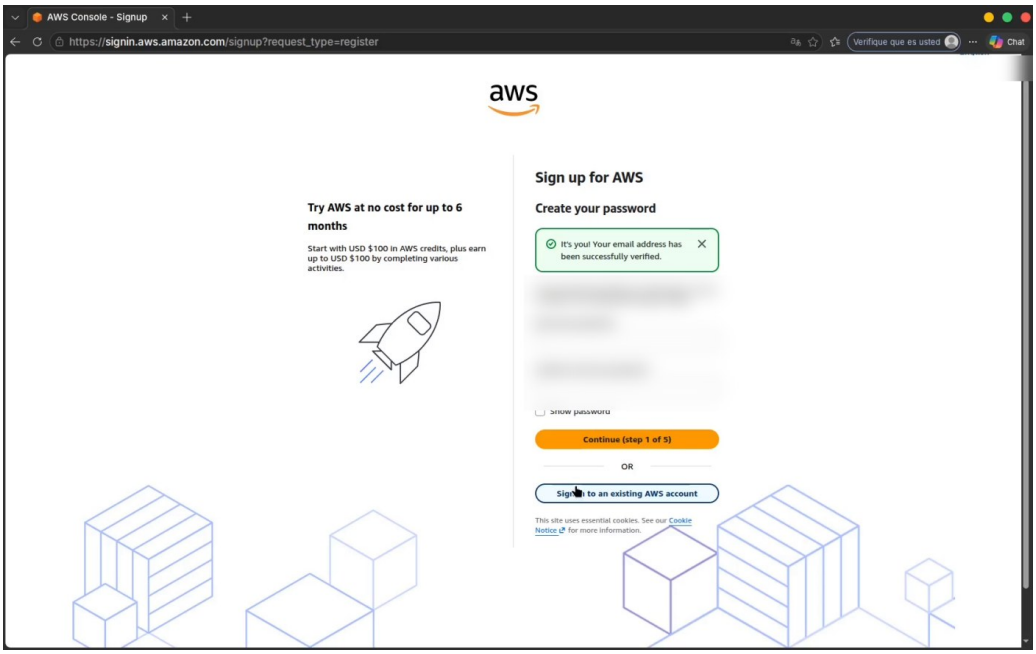


Figura 4: Crear la contraseña

1.5 Elegir el plan

En **Choose your account plan**, seleccione el plan gratuito con **Choose free plan**.

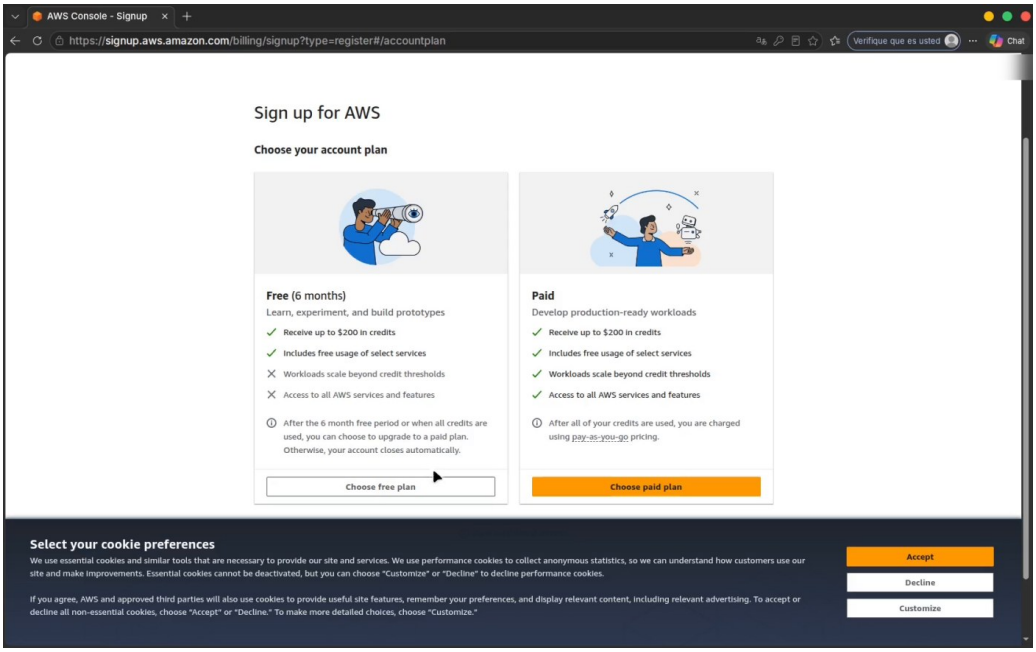


Figura 5: Elegir el plan

1.6 Datos de contacto

Diligencie nombre, organización, teléfono, país y dirección. Acepte el acuerdo de cliente de AWS y continúe.

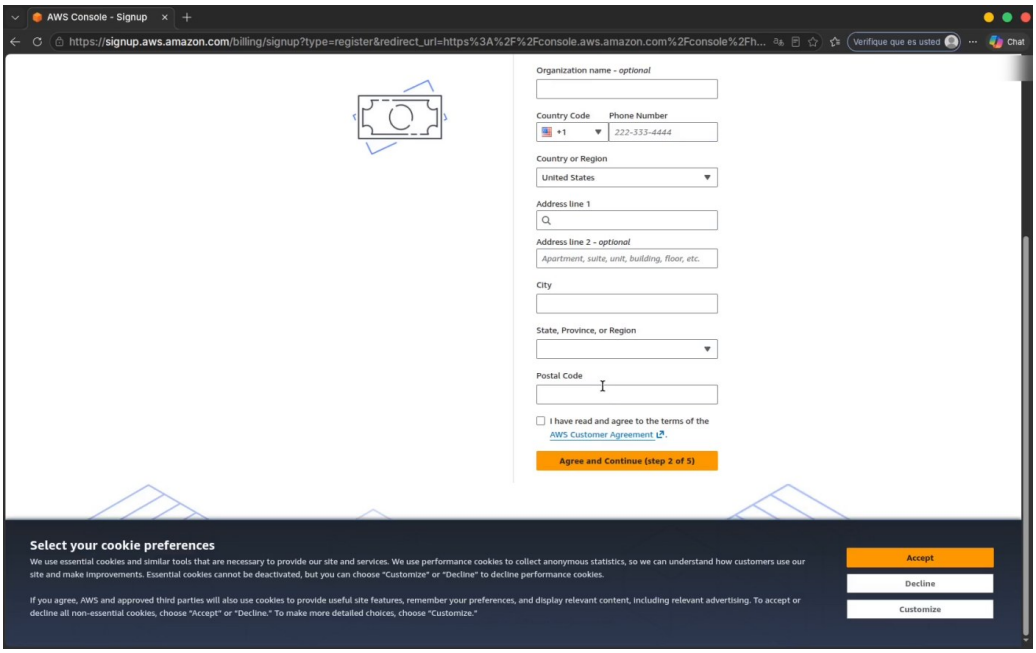


Figura 6: Datos de contacto

1.7 Información de facturación

Aunque se haya elegido el plan gratuito, AWS solicita una tarjeta para verificar la cuenta. Según esta pantalla, el proceso retiene el equivalente a 1 USD durante 3 a 5 días.

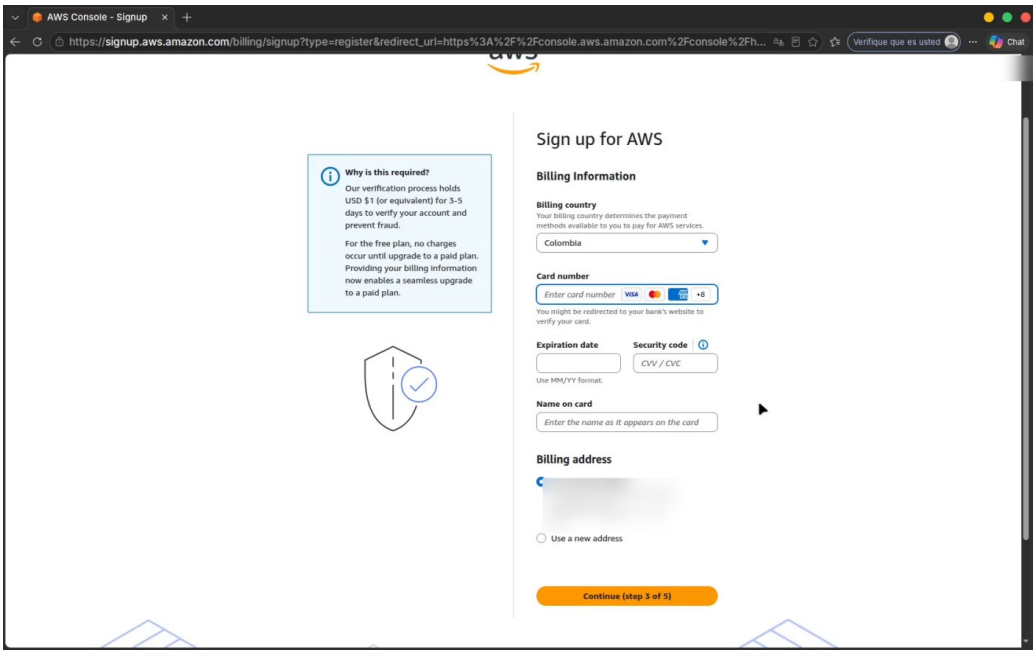


Figura 7: Información de facturación

1.8 Confirmar el teléfono

Indique el país y el número móvil y pulse **Send SMS** para recibir el código de verificación.

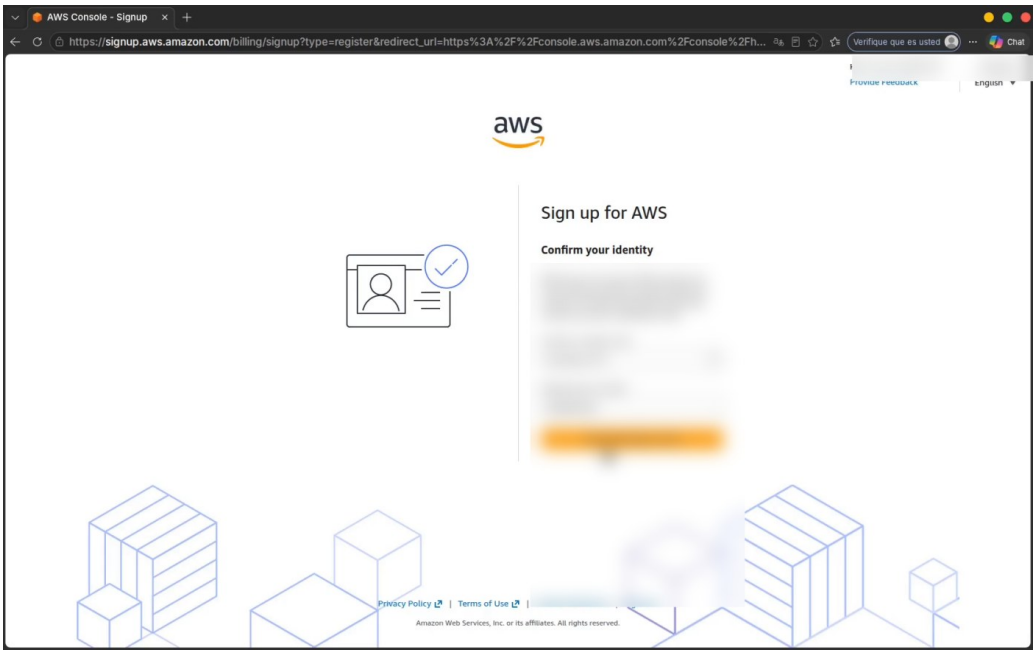


Figura 8: Confirmar el teléfono

1.9 Escribir el código SMS

Digite en **Verify code** el código recibido y continúe. Espere mientras el sistema configura la cuenta.

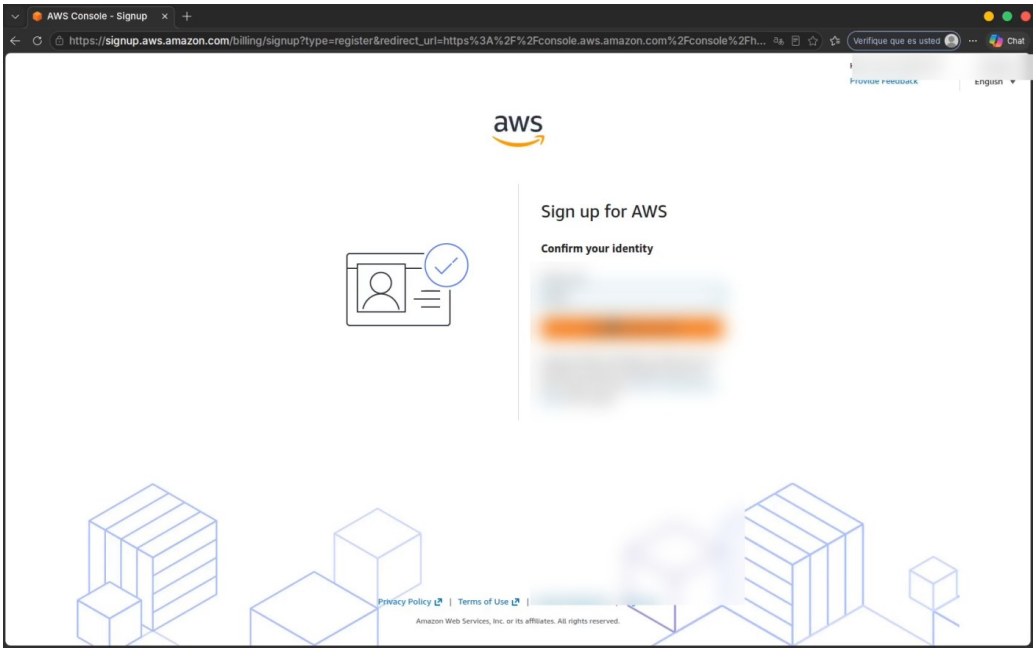


Figura 9: Escribir el código SMS

1.10 Consola de AWS

La consola muestra servicios visitados, formación, salud de AWS, costos, créditos asignados y retos que otorgan créditos adicionales.

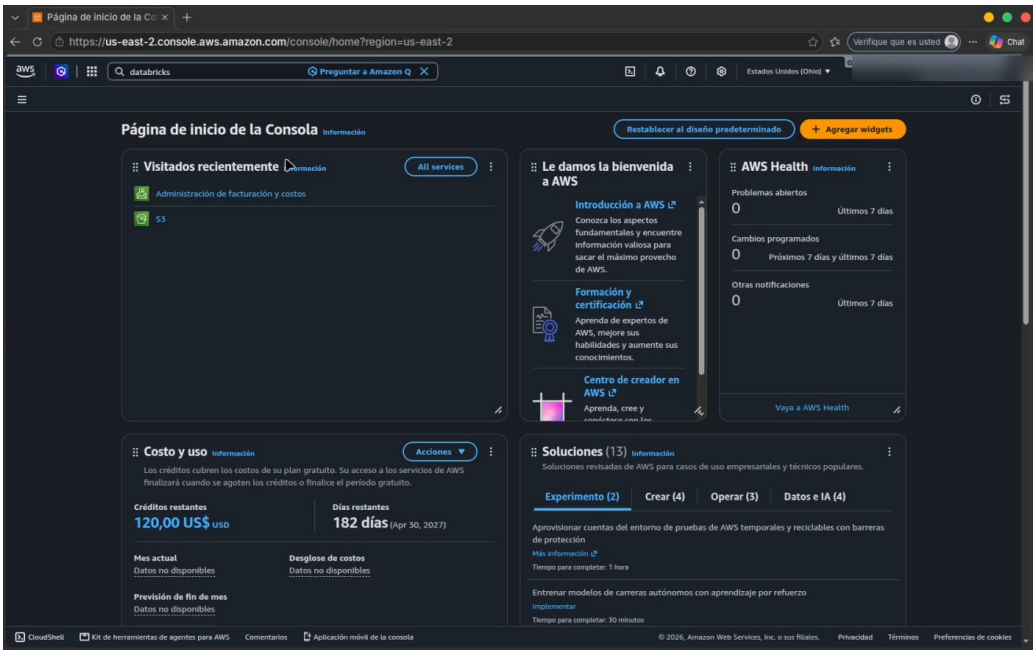


Figura 10: Consola de AWS

2. Plan de pago y presupuesto

> **Nota**
>
> La cuenta en plan gratuito es restringida: bloquea las suscripciones realizadas mediante AWS Marketplace. Por ello es necesario actualizar el plan antes de suscribir Databricks.

2.1 Buscar Facturación

En el buscador de la consola escriba *facturación* y abra **Administración de facturación y costos**.

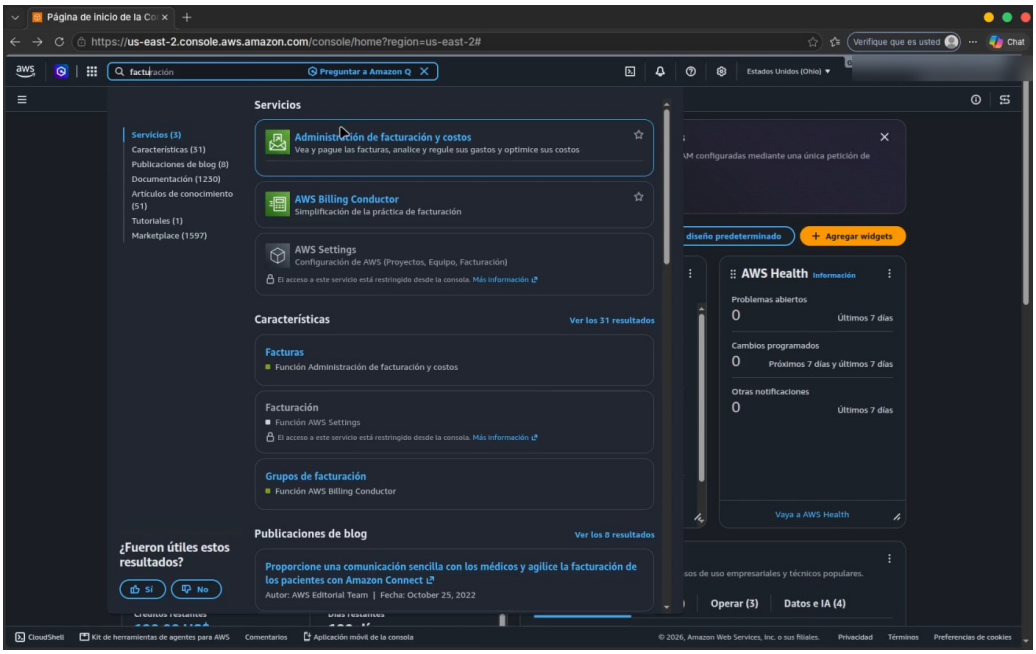


Figura 11: Buscar Facturación

2.2 Página de facturación

Esta página resume costos y presupuestos. Seleccione **Upgrade plan**.

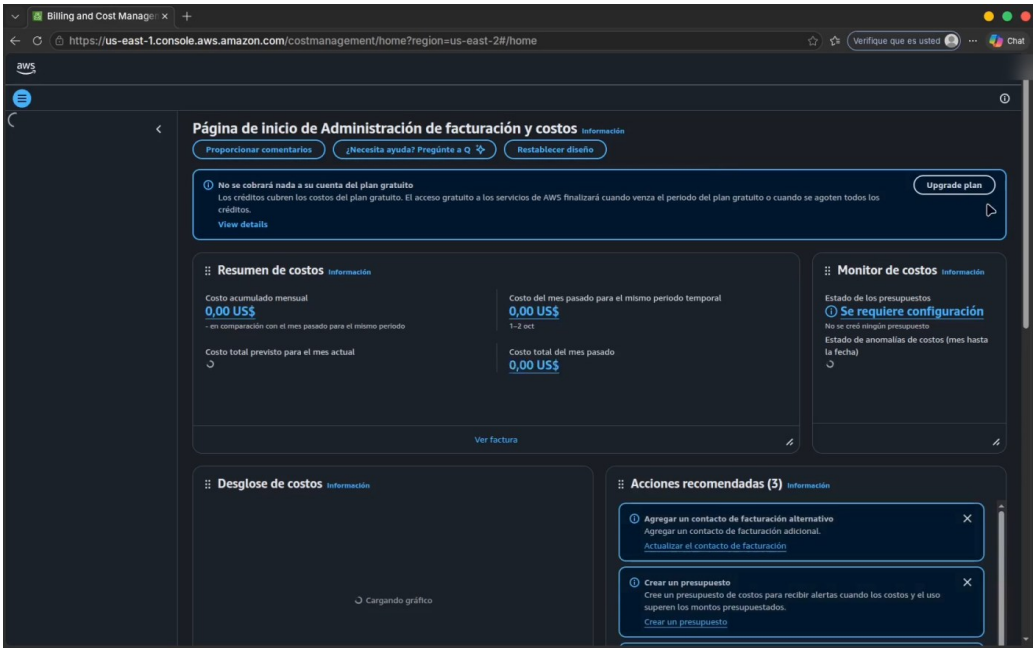


Figura 12: Página de facturación

2.3 Actualizar a plan de pago

Revise las características del plan y pulse **Actualizar plan**.

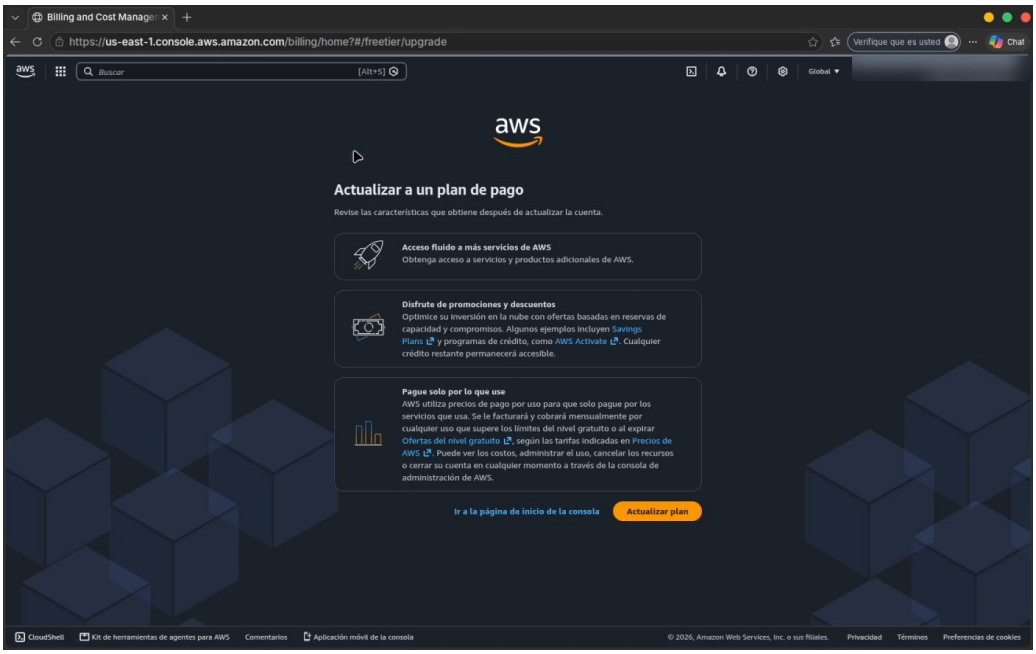


Figura 13: Actualizar a plan de pago

2.4 Confirmar la actualización

El sistema confirma que la cuenta se actualizó correctamente. Pulse **Continuar**.

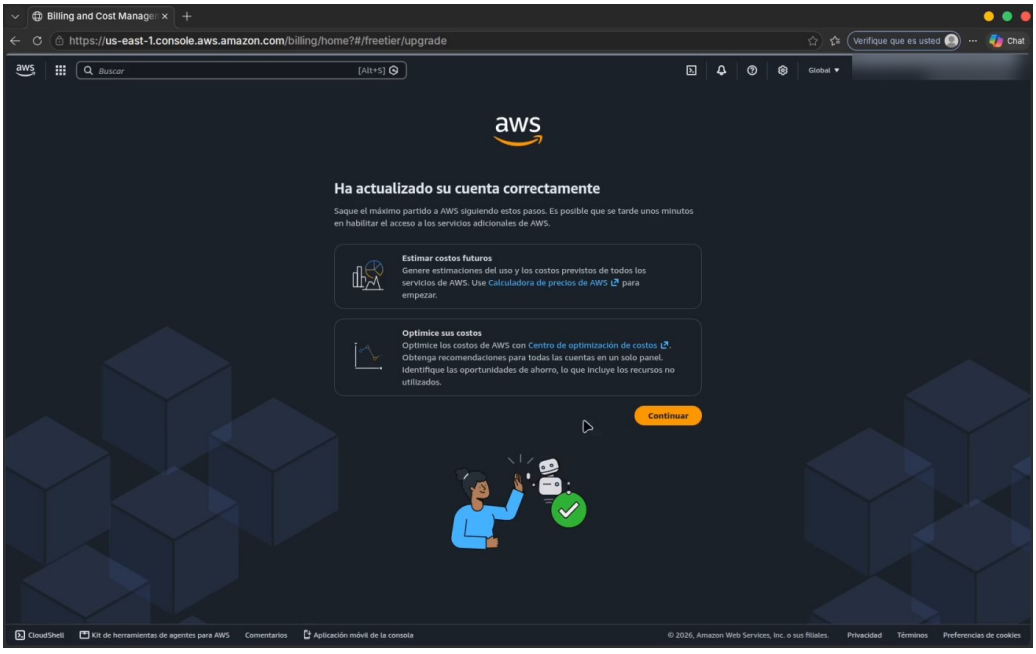


Figura 14: Confirmar la actualización

2.5 Crear un presupuesto

En **Facturación y costos**, seleccione **Estado de los presupuestos** y conserve **Uso de una plantilla** con **Presupuesto de gasto cero**, que notifica cuando el gasto supera 0,01 USD.

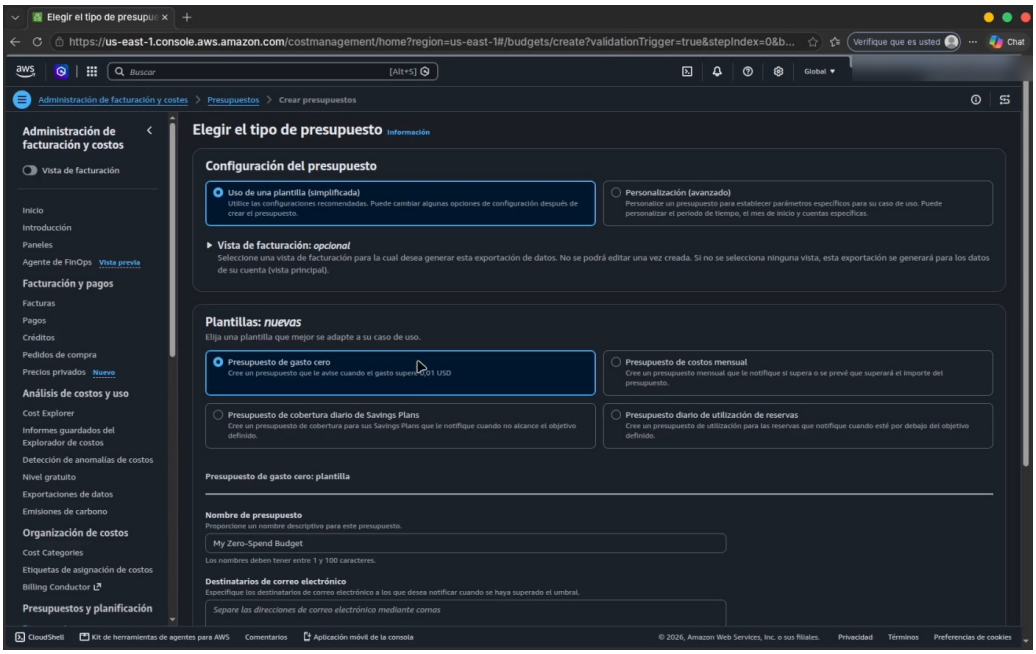


Figura 15: Crear un presupuesto

2.6 Indicar el correo de alertas

En **Destinatarios de correo electrónico**, escriba la dirección personal o institucional que recibirá las notificaciones. Este campo es obligatorio. Luego pulse **Crear presupuesto**.

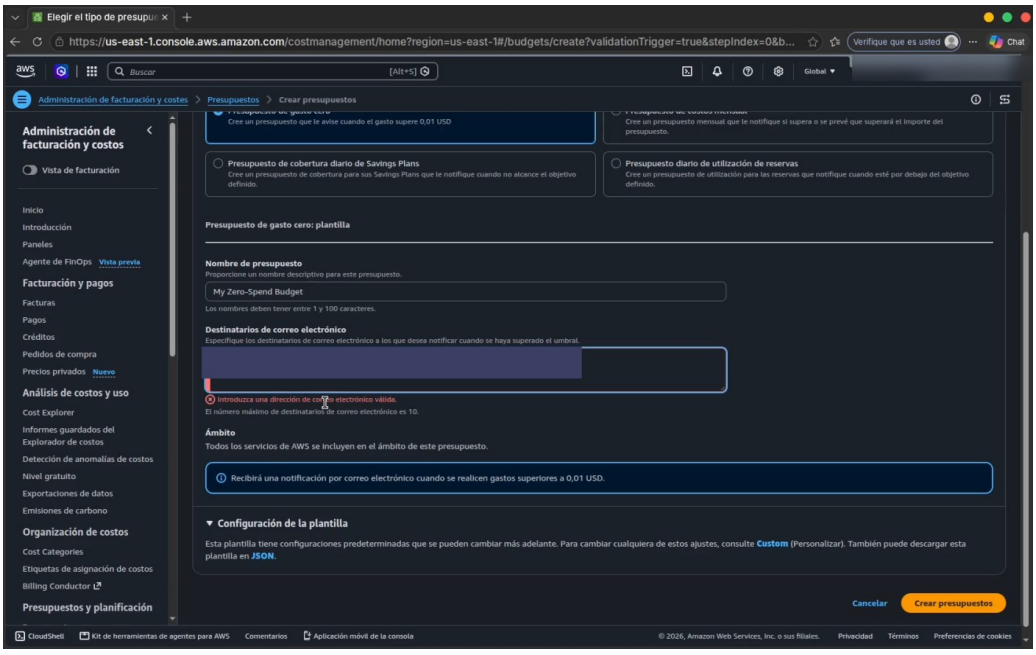


Figura 16: Indicar el correo de alertas

2.7 Presupuesto creado

El sistema confirma la creación de **My Zero-Spend Budget**, visible en la lista de presupuestos.

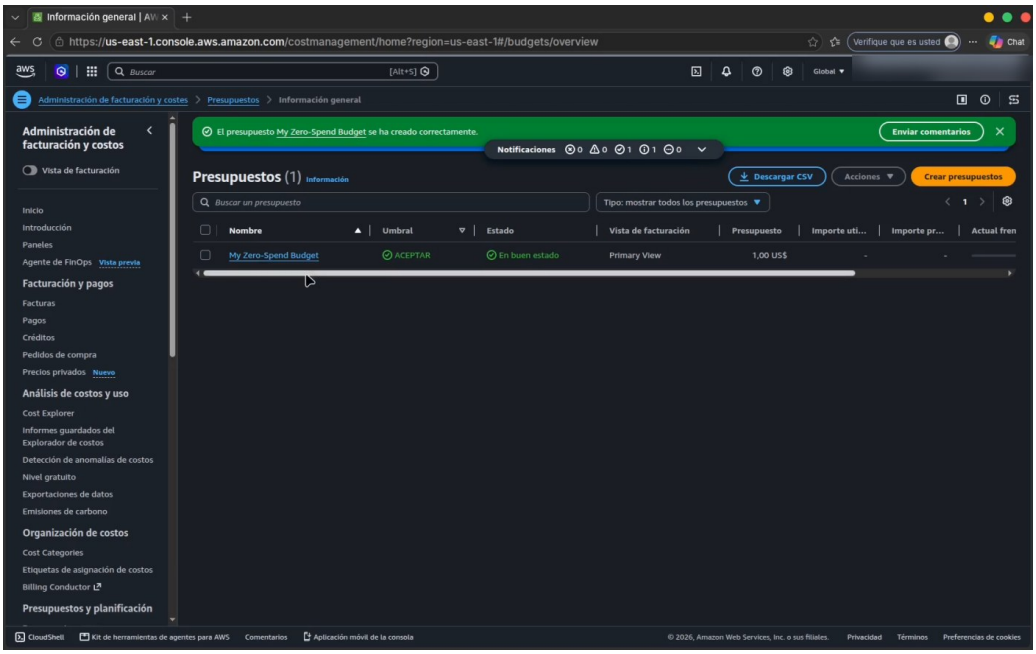


Figura 17: Presupuesto creado

3. Suscripción a Databricks

3.1 Buscar Databricks

En el buscador de la consola escriba *databricks* y abra **Databricks Data Intelligence Platform** en la sección Marketplace.

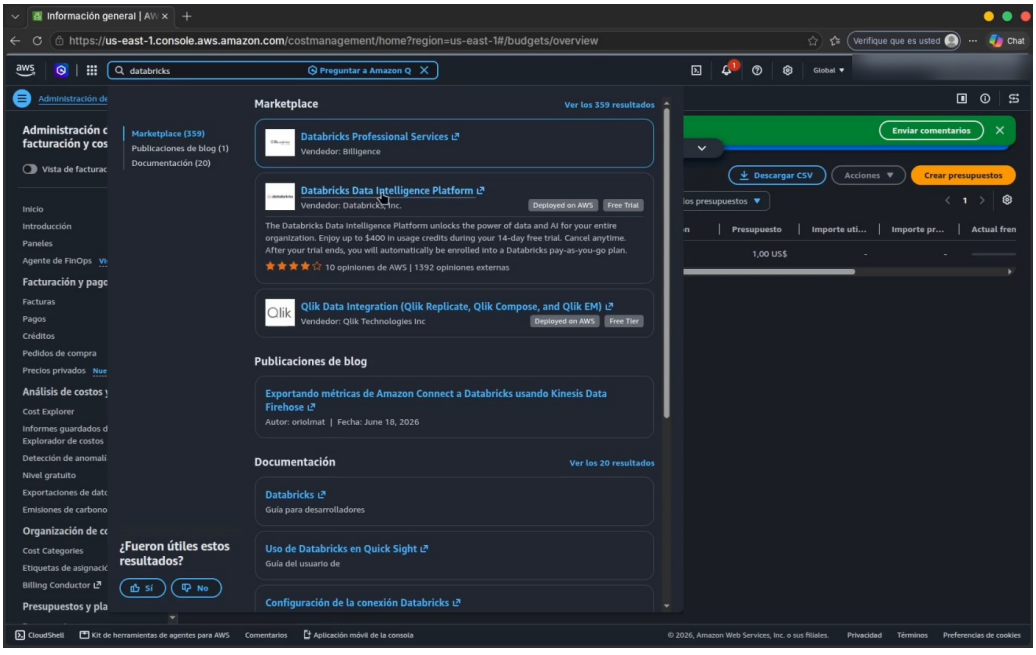


Figura 18: Buscar Databricks

3.2 Suscribirse

Seleccione **Ver opciones de compra**, revise las condiciones y pulse **Subscribe**. Este servicio se cobra por unidades de consumo de Databricks.

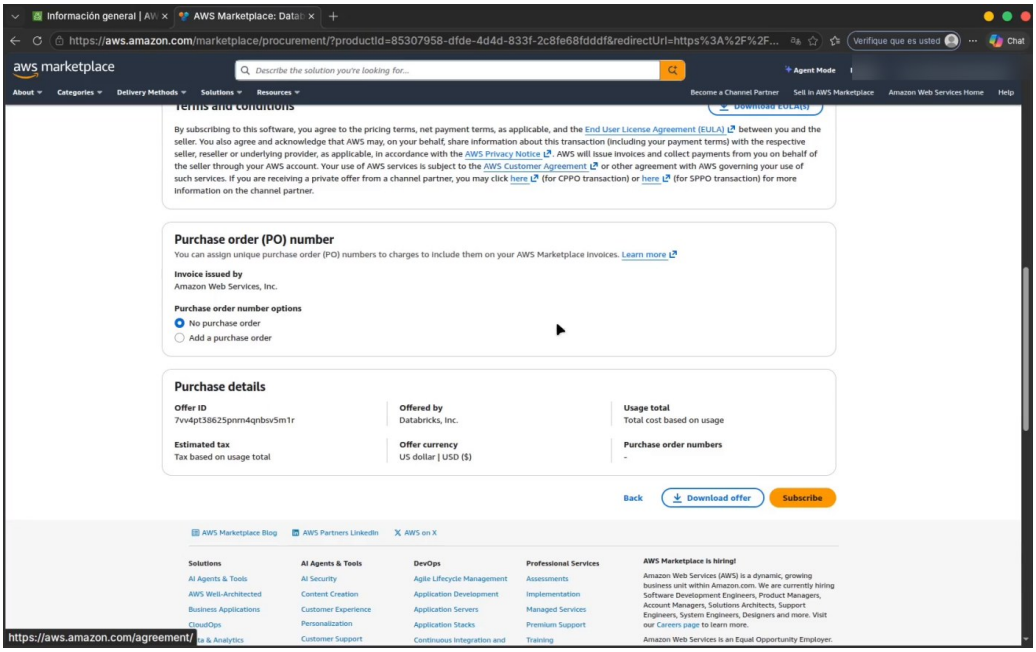


Figura 19: Suscribirse

3.3 Verificar la suscripción

En **AWS Marketplace**, opción **Administrar suscripciones**, confirme que **Databricks Data Intelligence Platform** aparece activa.

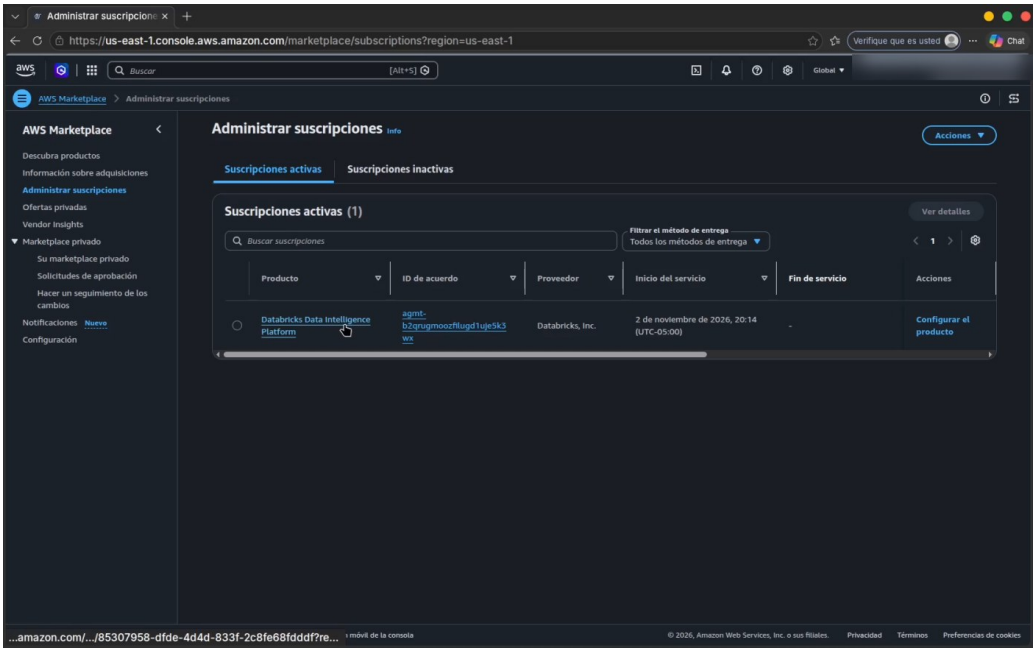


Figura 20: Verificar la suscripción

4. Lago de datos en Amazon S3

4.1 Buscar Amazon S3

Busque *Amazon S3* y abra el servicio. Allí se almacenará todo el entorno de datos.

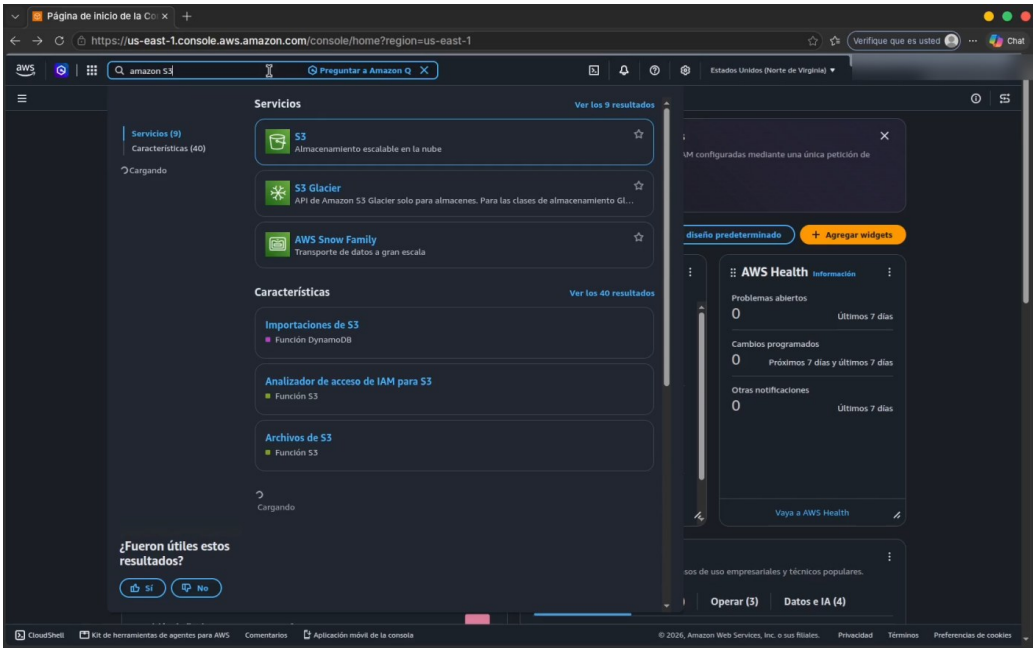


Figura 21: Buscar Amazon S3

4.2 Crear el bucket

Seleccione **Crear bucket** y conserve el tipo **Uso general**.

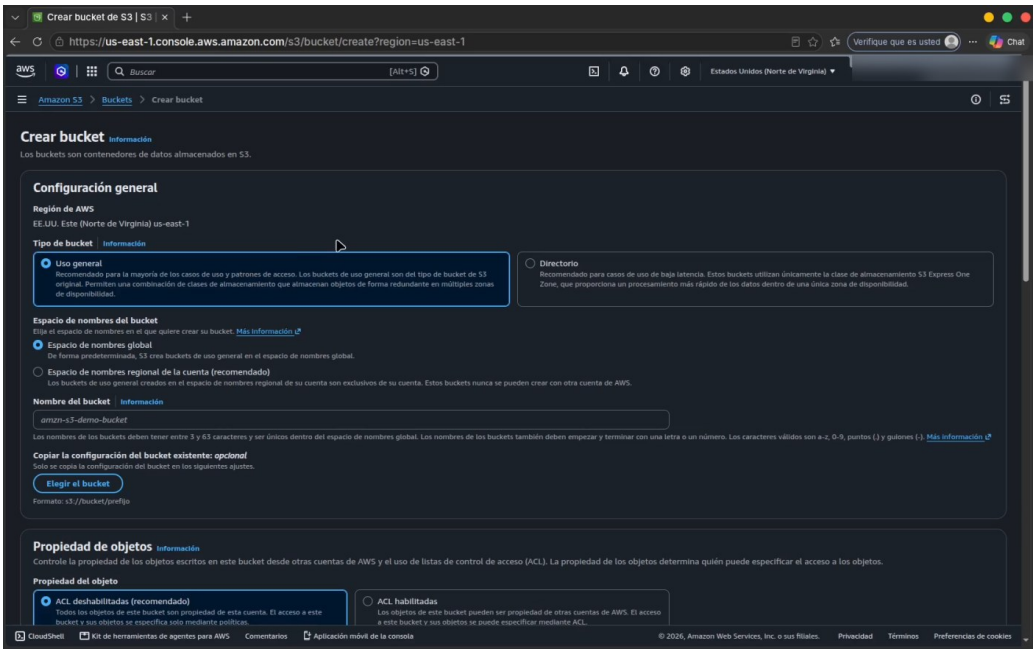


Figura 22: Crear el bucket

4.3 Nombre y espacio regional

Asigne un nombre (en el ejemplo, `datalaketg1`) y seleccione **Espacio de nombres regional de la cuenta**. AWS agrega a este prefijo un sufijo propio de la cuenta.

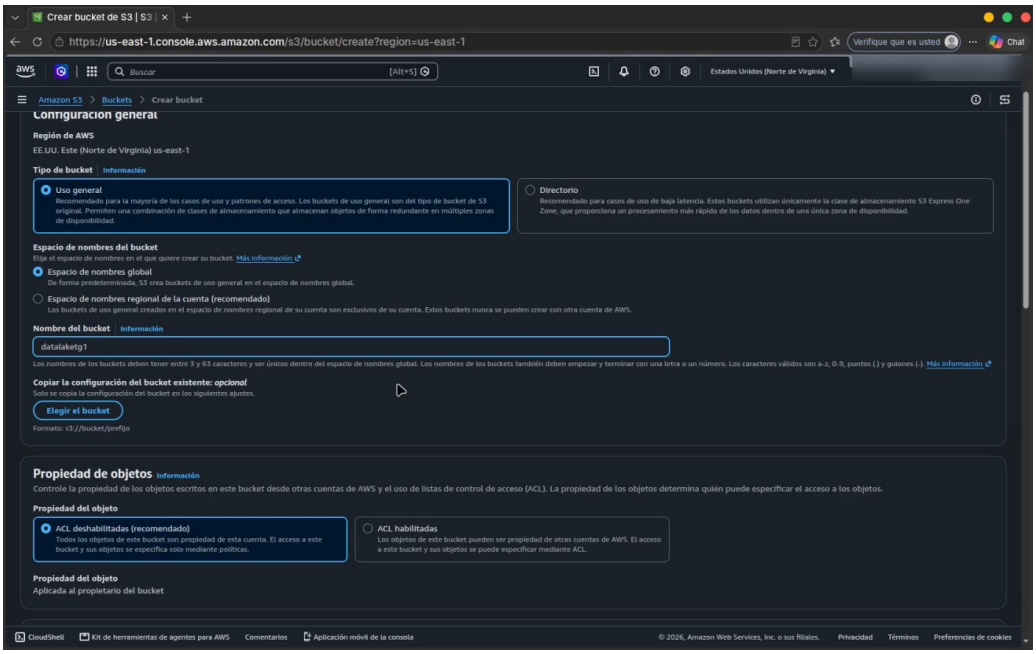


Figura 23: Nombre y espacio regional

4.4 Control de versiones

En **Control de versiones de buckets** seleccione **Habilitar**. Así es posible recuperar una versión anterior si un cambio afecta los datos. Conserve las demás opciones y pulse **Crear bucket**.

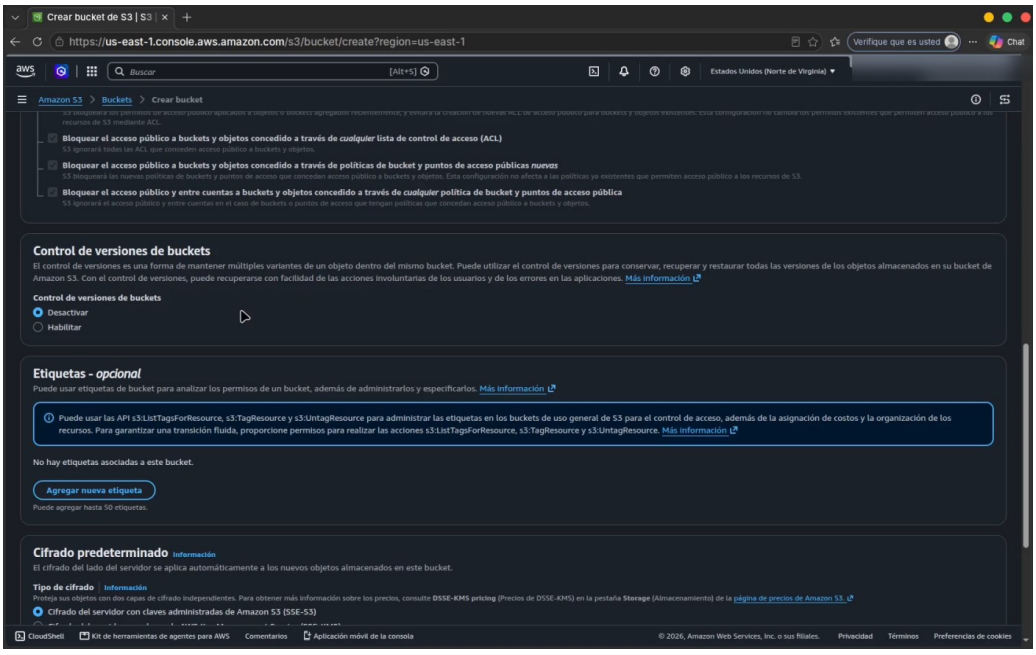


Figura 24: Control de versiones

4.5 Bucket creado

El sistema confirma la creación. Pulse **Crear carpeta**.

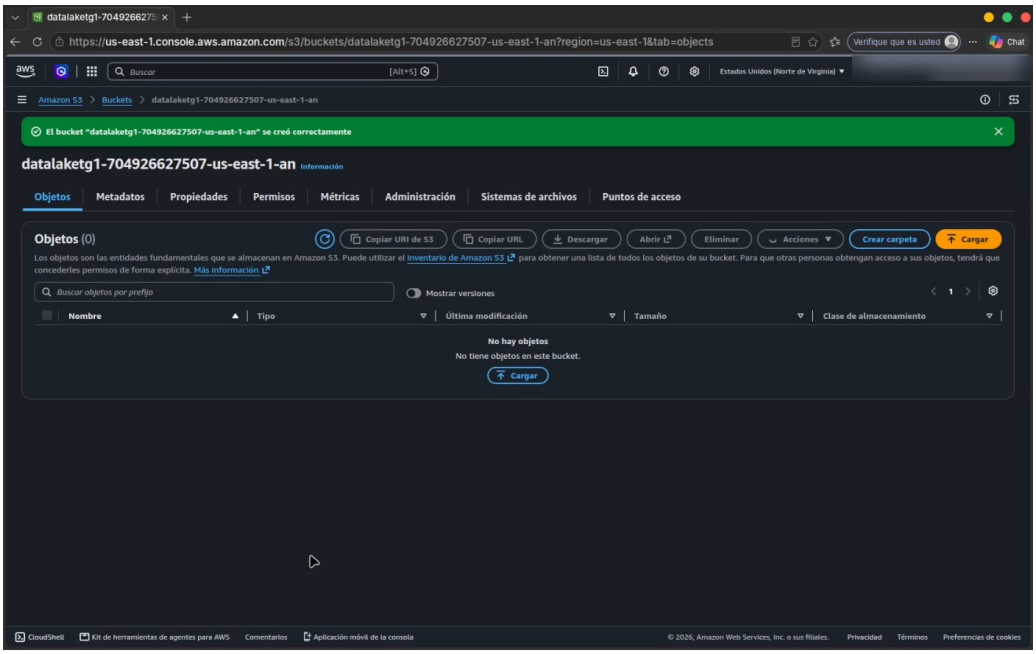


Figura 25: Bucket creado

4.6 Crear las carpetas

Cree una carpeta para cada capa: `raw_data` (datos en crudo), `curated` (datos transformados) y `models` (artefactos de ML).

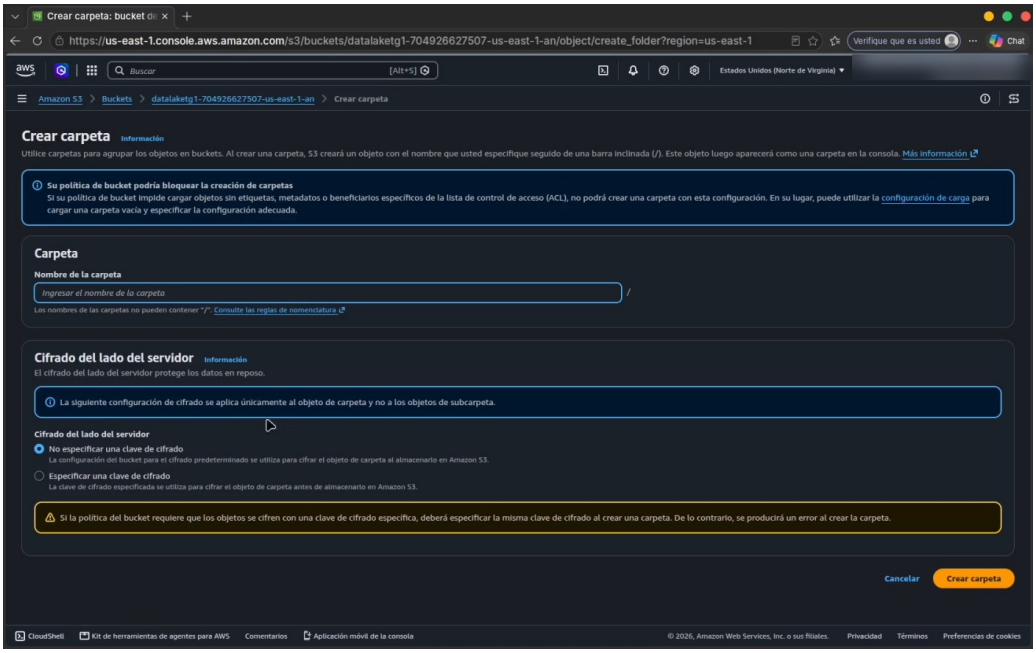


Figura 26: Crear las carpetas

4.7 Verificar la estructura

El bucket debe mostrar las tres carpetas del lago de datos.

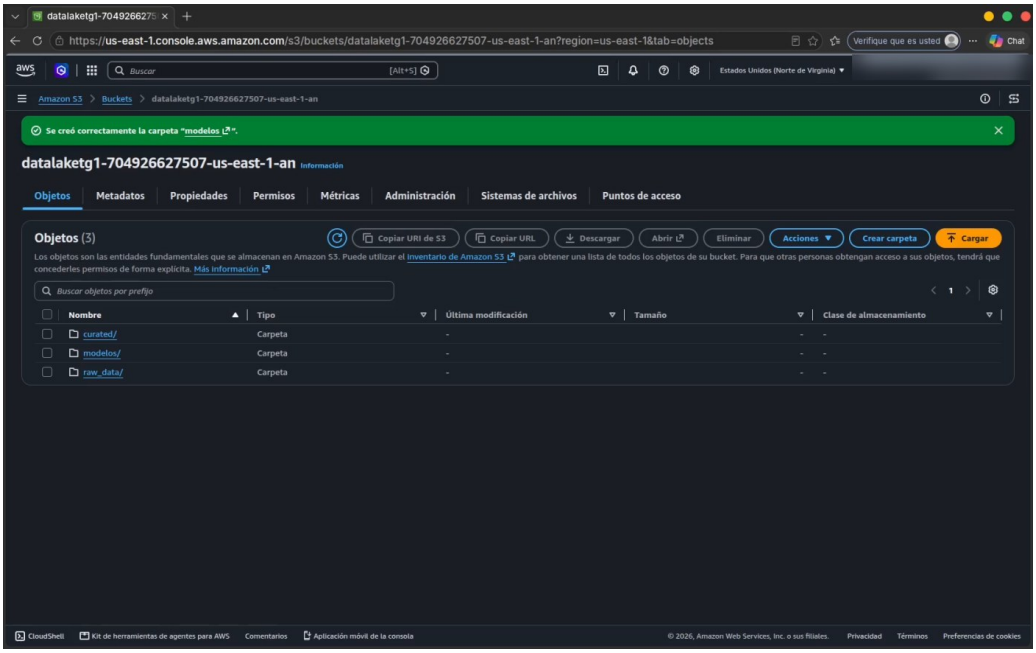


Figura 27: Verificar la estructura

5. Claves de acceso

5.1 Credenciales de seguridad

Haga clic en el nombre de usuario, arriba a la derecha, y seleccione **Credenciales de seguridad**. En **Claves de acceso**, pulse **Crear clave de acceso**.

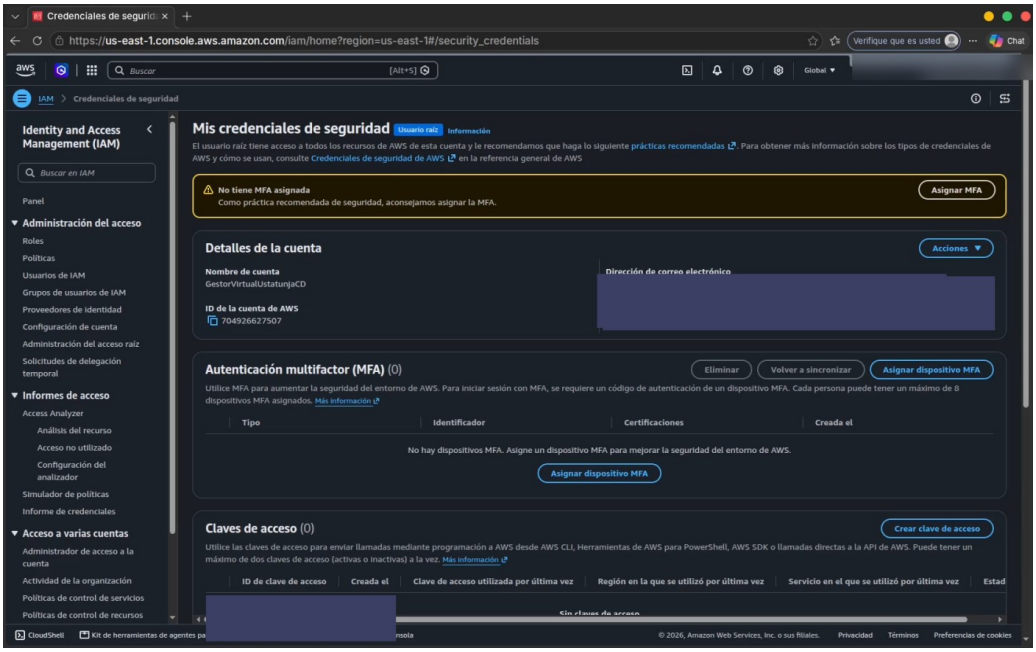


Figura 28: Credenciales de seguridad

5.2 Aceptar la advertencia

AWS advierte que no se recomiendan las claves del usuario raíz. Marque la casilla de confirmación y pulse **Crear clave de acceso**.

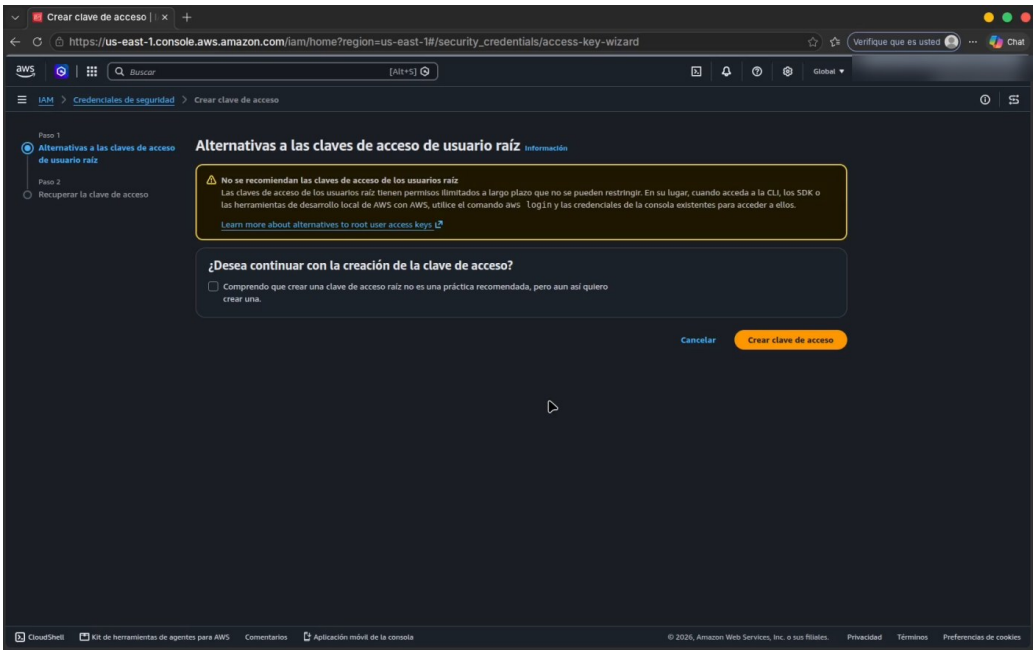


Figura 29: Aceptar la advertencia

5.3 Guardar la clave

Copie la clave de acceso y la clave secreta o pulse **Descargar archivo .csv**. **Este es el único momento en que AWS permite ver o descargar la clave secreta.**

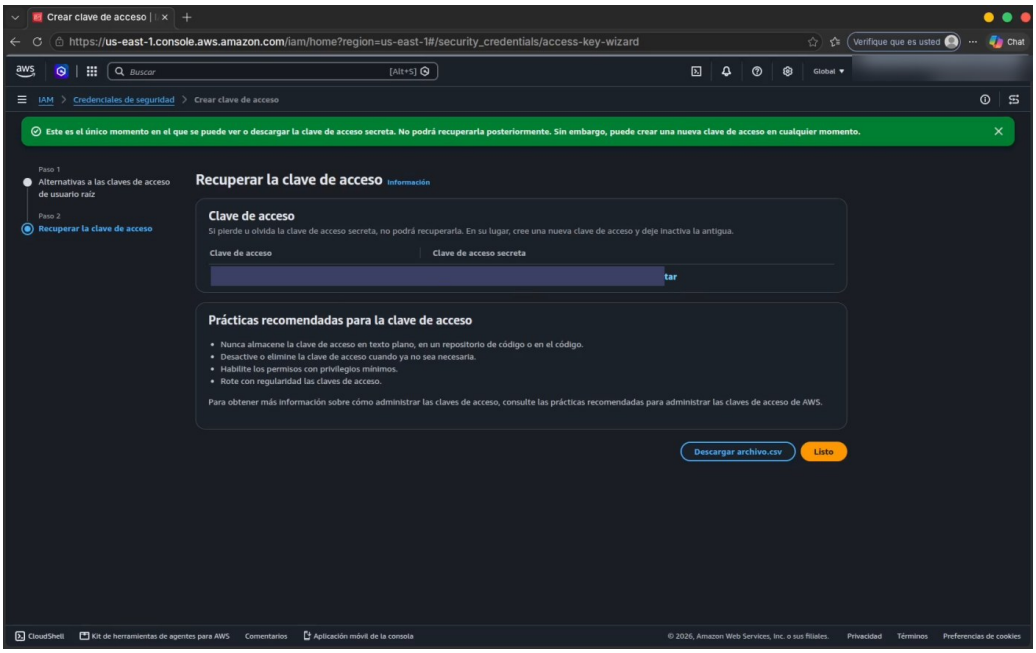


Figura 30: Guardar la clave

Importante

Las claves dan acceso programático a la cuenta. No las publique ni las comparta, no las deje en repositorios ni en videos y desactívelas al terminar la práctica. AWS recomienda evitar claves del usuario raíz; en entornos reales utilice un usuario de IAM con privilegios mínimos y guarde las claves en *Databricks Secrets*.

AWS admite un máximo de dos claves simultáneas. Si pierde una clave secreta, cree una nueva y elimine la anterior.

6. Espacio de trabajo de Databricks en AWS

6.1 Crear la cuenta de Databricks

Vaya a Databricks, continúe con la cuenta institucional de Microsoft y seleccione **Create a new account**. Indique el nombre y el país; en **Select a cloud** elija **AWS** y pulse **Continue**.

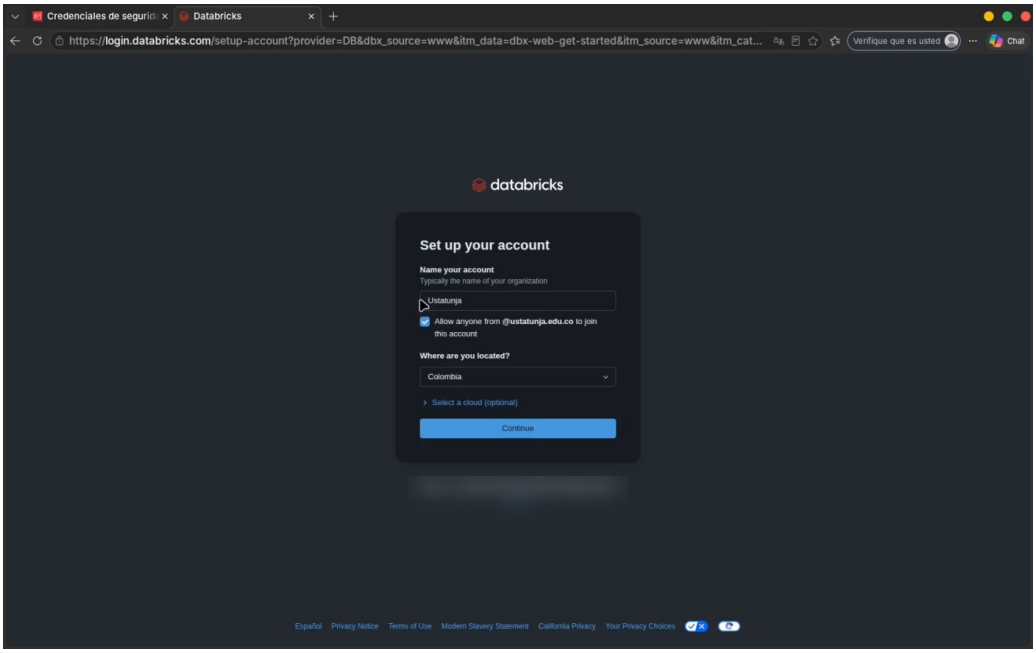


Figura 31: Crear la cuenta de Databricks

6.2 Verificar el periodo de prueba

En **Manage Trial** se consultan los créditos gratuitos. Con **AWS Marketplace** y **Buy with AWS** se comprueba que la suscripción está activa. El servicio se cobra según el uso.

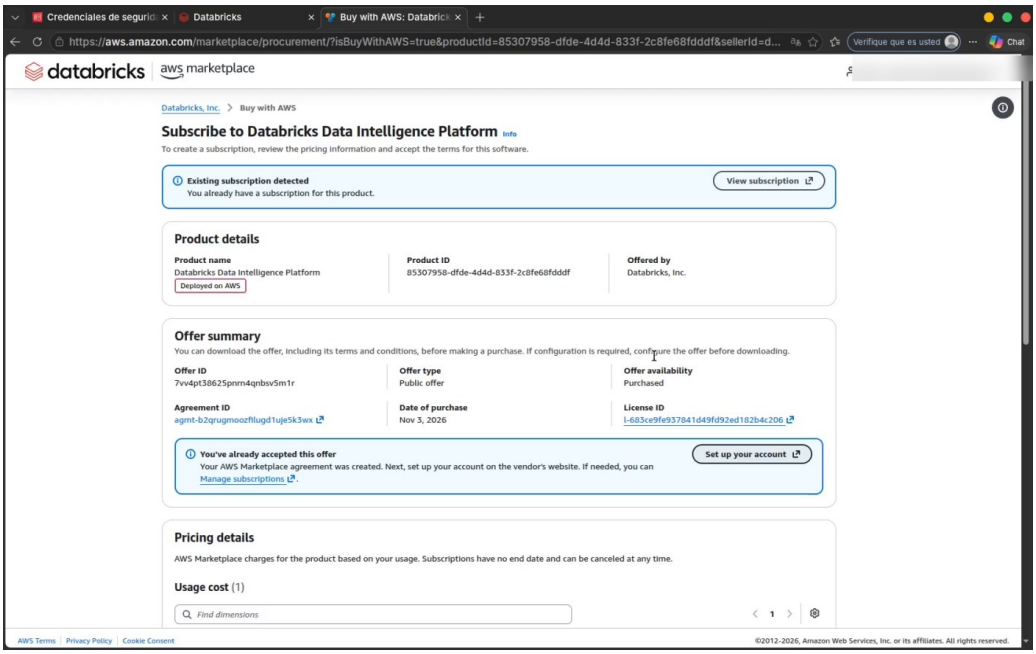


Figura 32: Verificar el periodo de prueba

7. Conexión y ejecución del proyecto

7.1 Importar el cuaderno

En **Workspace**, abra el menú de la carpeta del usuario, seleccione **Import** y cargue el archivo del proyecto.

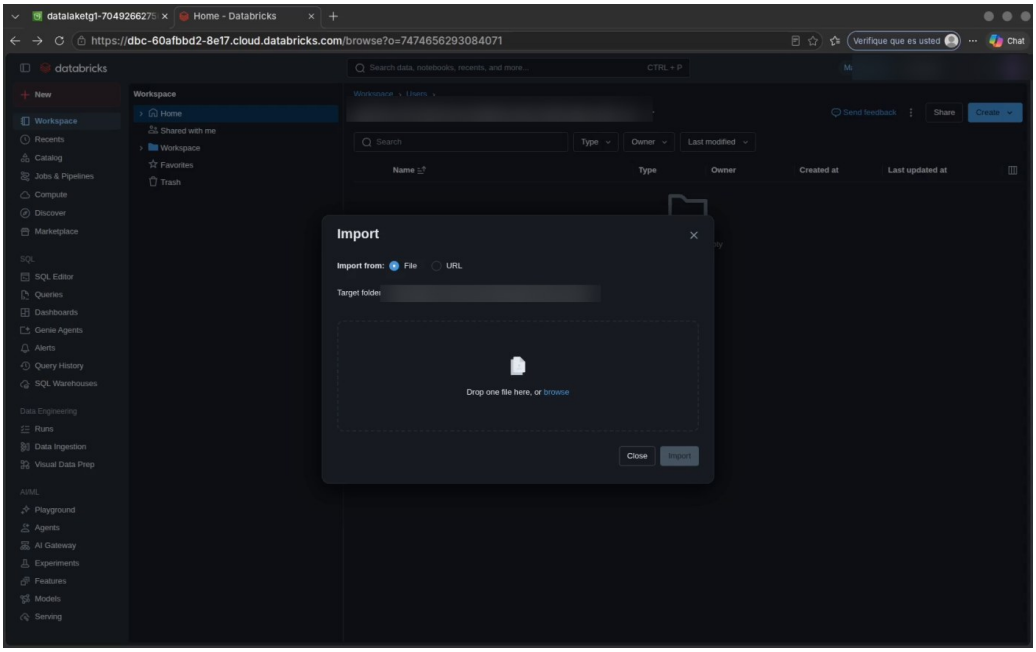


Figura 33: Importar el cuaderno

7.2 Revisar la descripción

El cuaderno inicia con el problema, las hipótesis, las variables y la infraestructura. Es una buena práctica describir cada sección con una celda de Markdown.

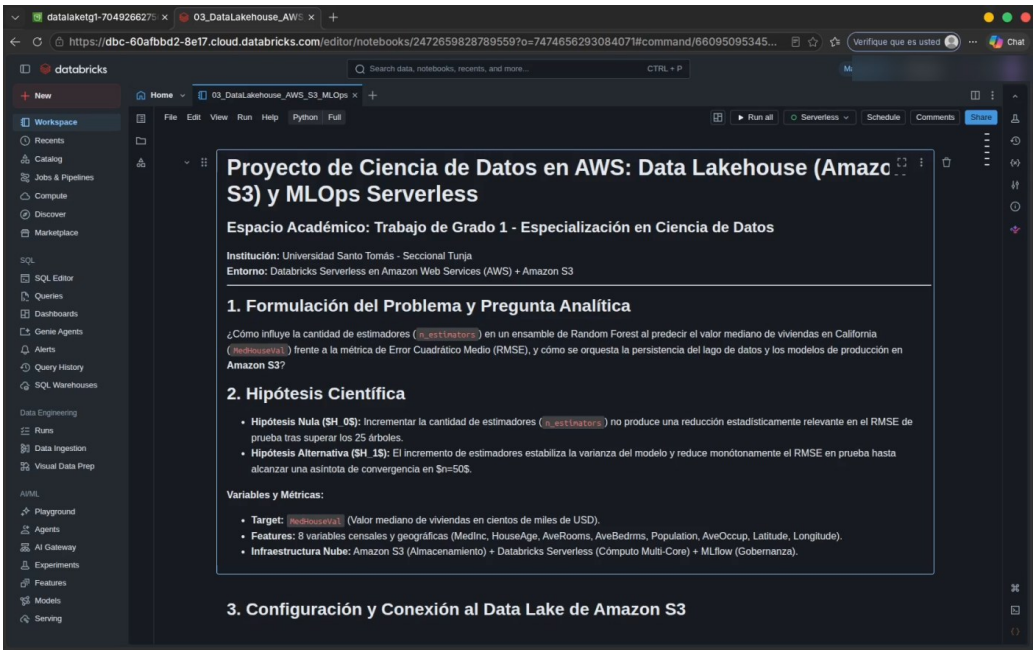


Figura 34: Revisar la descripción

7.3 Configurar las credenciales

En la sección 3 se indican la clave de acceso, la clave secreta, la región y el nombre del bucket. Reemplace cada valor por los de su propia cuenta.

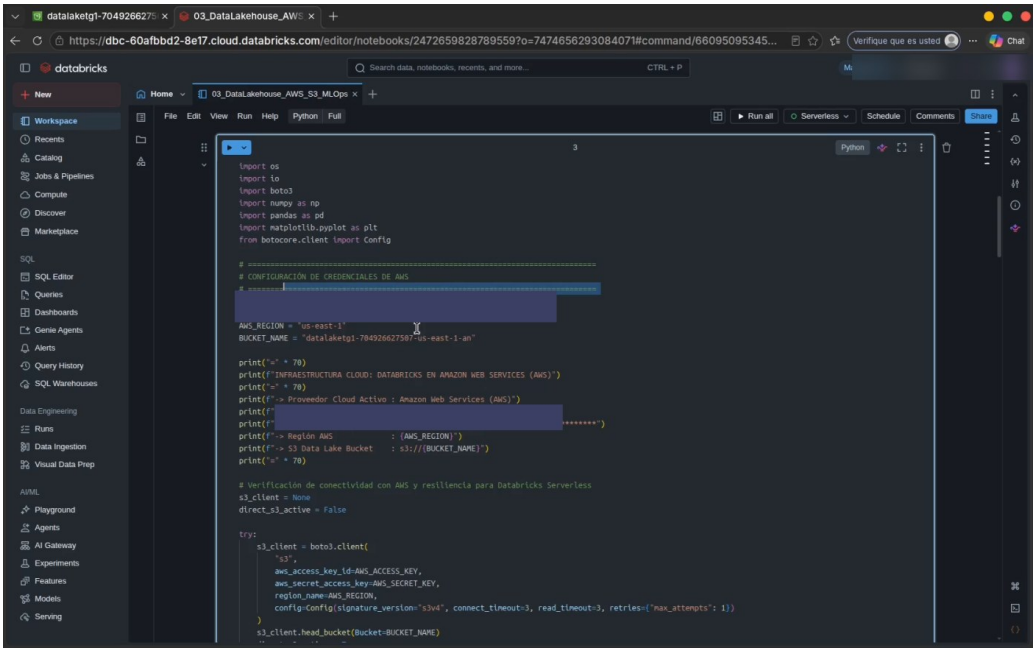


Figura 35: Configurar las credenciales

```
AWS_ACCESS_KEY = "SU_CLAVE_DE_ACCESO"
AWS_SECRET_KEY = "SU_CLAVE_SECRETA"
AWS_REGION = "us-east-1"
BUCKET_NAME = "nombre-completo-de-su-bucket"
```

7.4 Validar la conexión

Ejecute la celda. La salida muestra el proveedor, la clave en forma parcial, la región y el bucket, además de la validación de la conexión.

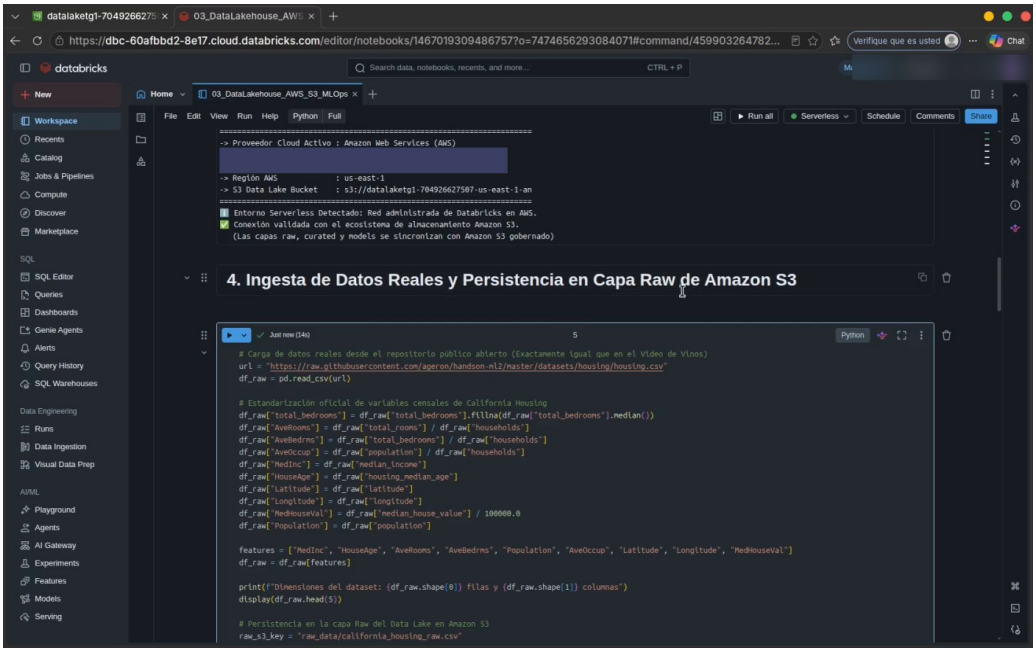


Figura 36: Validar la conexión

7.5 Ingesta en la capa raw

Ejecute la sección 4. El conjunto de datos se descarga y se guarda en `raw_data/`.

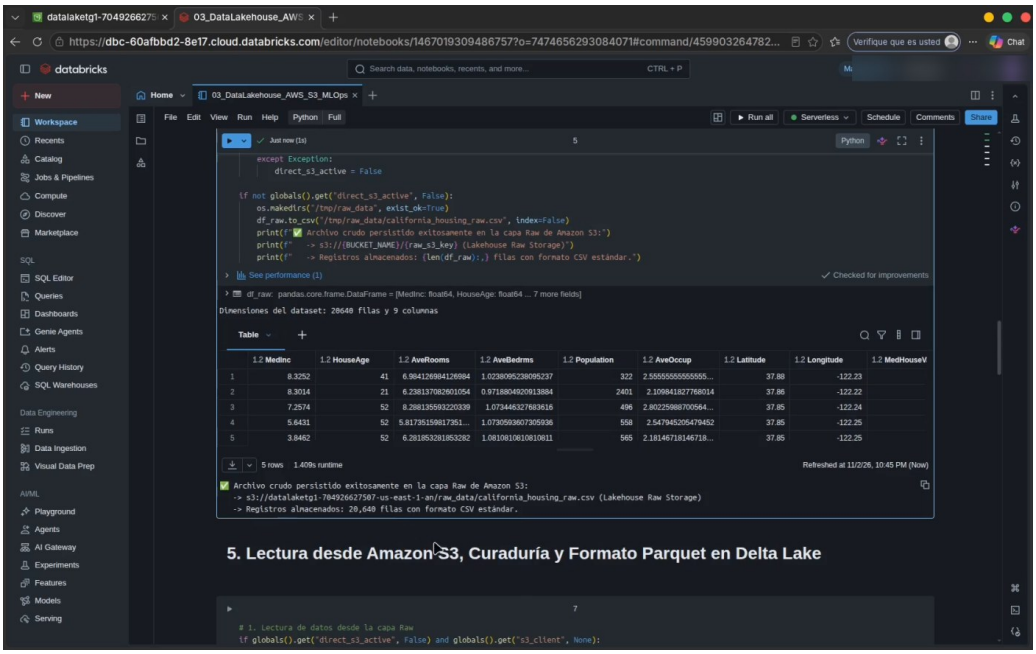


Figura 37: Ingesta en la capa raw

7.6 Verificar en Amazon S3

Abra el bucket y la carpeta `raw_data/` para confirmar que el archivo se cargó.

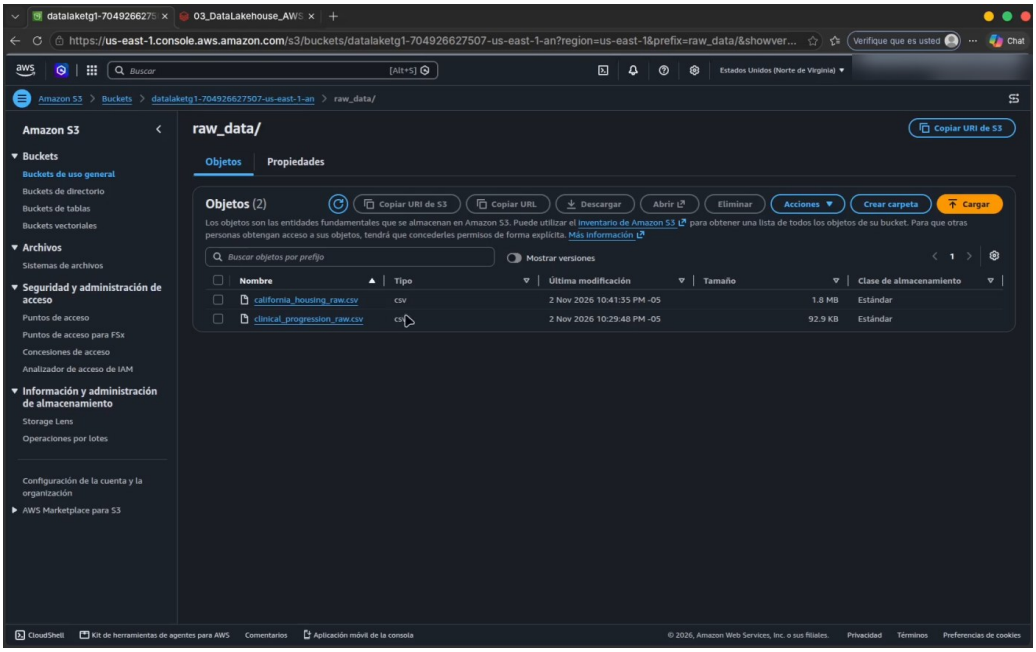


Figura 38: Verificar en Amazon S3

7.7 Experimento científico

Ejecute la sección 5, de lectura y validación de calidad, y luego la sección 6, que evalúa la hipótesis variando el número de árboles (`n_estimators`) con paralelismo multinúcleo (`n_jobs=-1`).

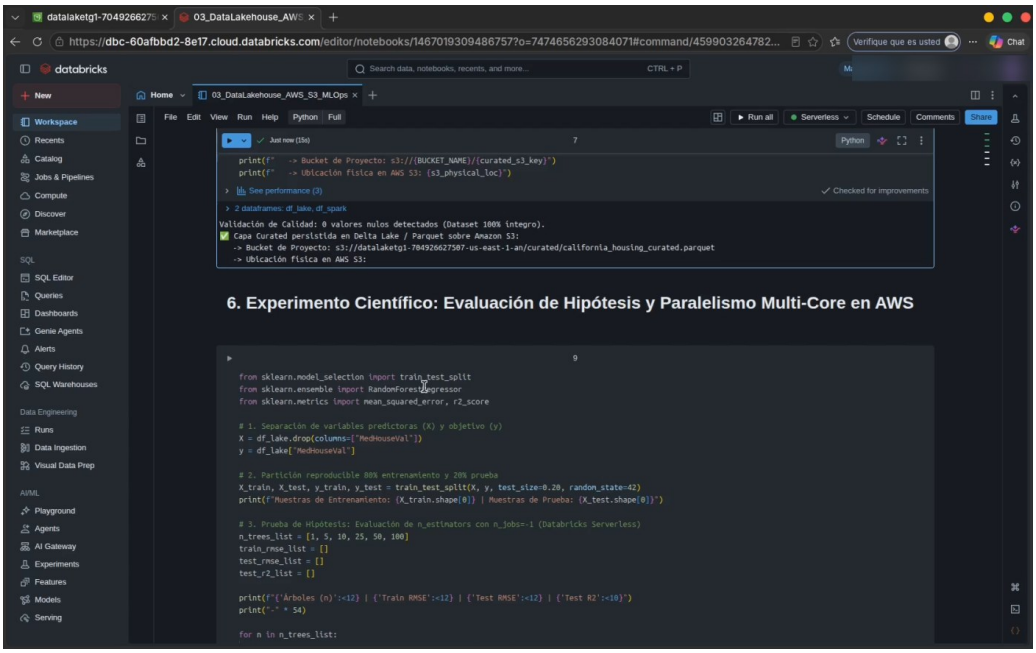


Figura 39: Experimento científico

7.8 Curva de convergencia

La sección 7 grafica el RMSE frente al número de estimadores y permite observar la convergencia del error.

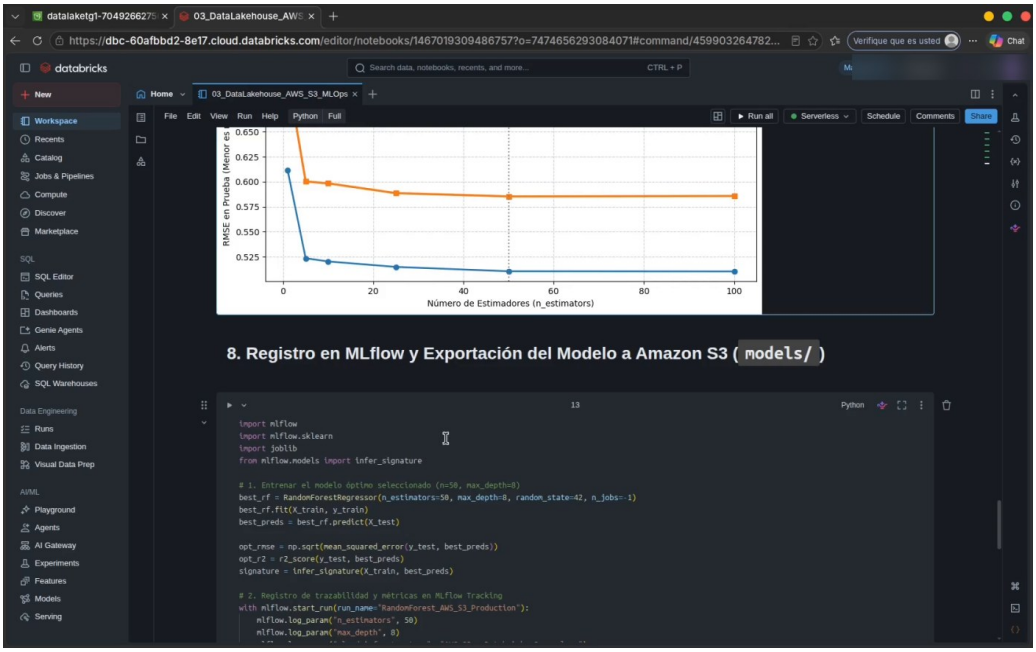


Figura 40: Curva de convergencia

7.9 Registrar y exportar el modelo

La sección 8 registra el mejor modelo en MLflow y exporta el artefacto a la capa `models/` de Amazon S3.

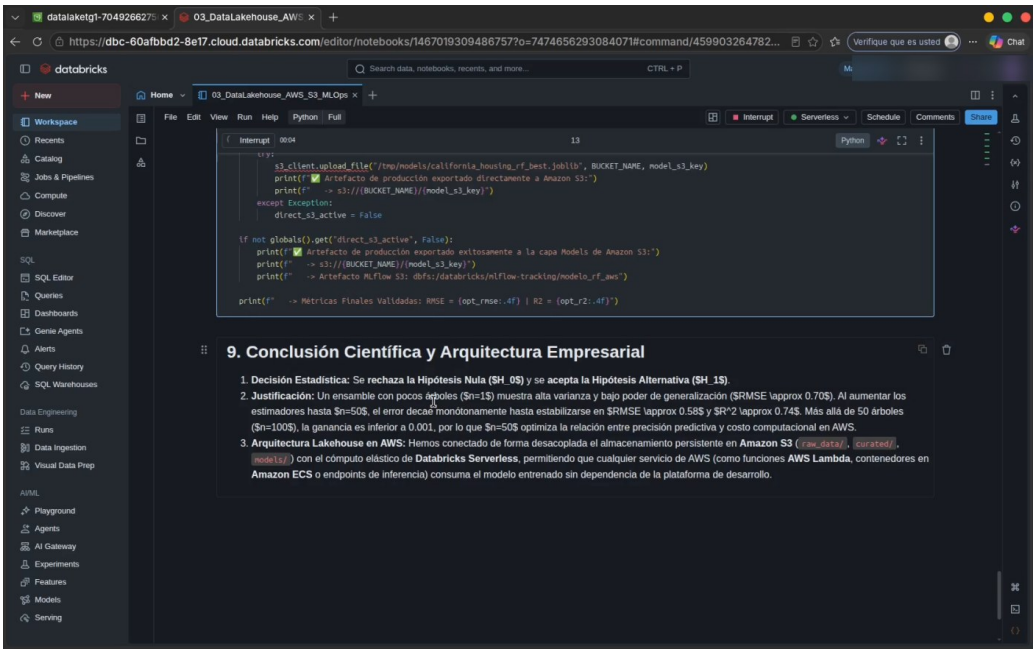


Figura 41: Registrar y exportar el modelo

7.10 Verificar el modelo en S3

En la carpeta `models/` del bucket debe aparecer el archivo `.joblib` del modelo.

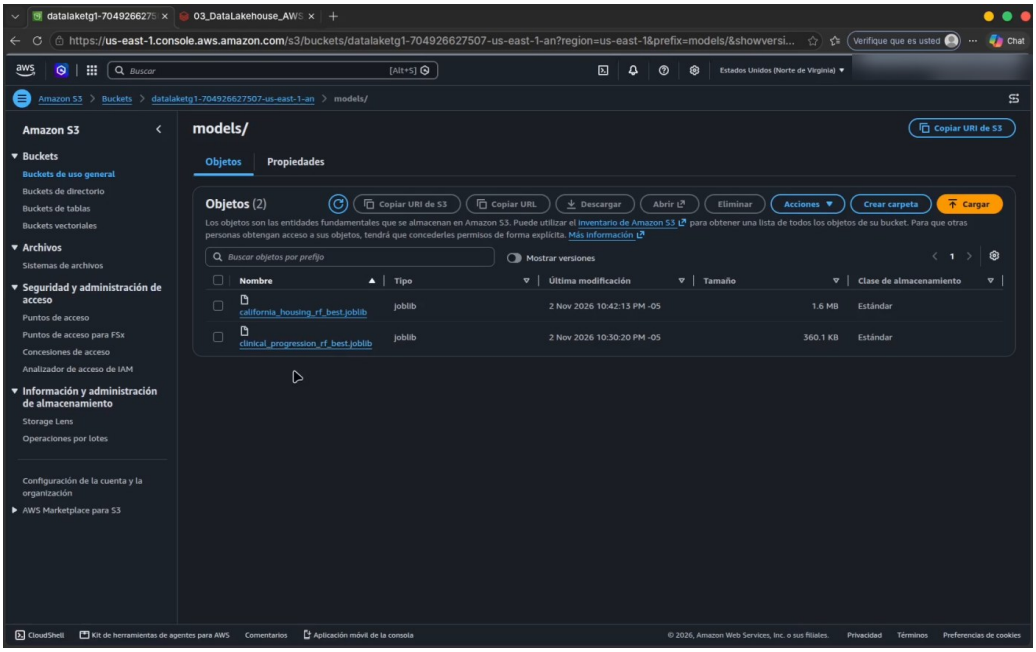


Figura 42: Verificar el modelo en S3

7.11 Conclusión del experimento

La sección 9 presenta la decisión estadística y su justificación. El modelo queda como artefacto versionado en Amazon S3, disponible para servicios como AWS Lambda o Amazon ECS.

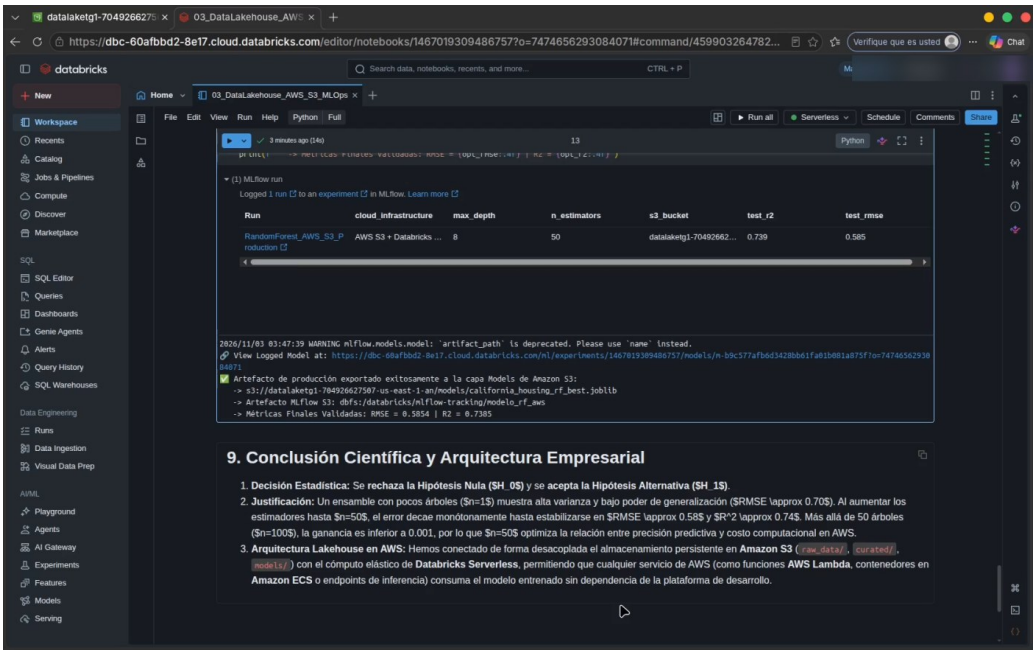


Figura 43: Conclusión del experimento

Importante

Al terminar. Desactive las claves de acceso que no vaya a utilizar, cancele la suscripción si no continuará con el servicio y revise la página de facturación para confirmar que no hay consumos activos.