ESPECIALIZACIÓN EN CIENCIA DE DATOS

Guía de instalación paso a paso

Databricks Free Edition

Del registro de la cuenta al modelo disponible en producción

Ing. Santiago Alejandro Zuñiga Melo

Índice

Presentación **2**

1. Procedimiento **2**

1.1. Ingresar al sitio de Databricks . . . 2
1.2. Registrarse con la cuenta institucional . . . 3
1.3. Aprobar el inicio de sesión . . . 3
1.4. Seleccionar o crear la cuenta . . . 4
1.5. Elegir el uso personal . . . 4
1.6. Configurar la cuenta . . . 5
1.7. Pantalla de bienvenida . . . 5
1.8. Workspace . . . 6
1.9. Catalog . . . 6
1.10. Compute . . . 7
1.11. SQL Editor . . . 7
1.12. SQL Warehouses . . . 8
1.13. Experiments . . . 8
1.14. Models . . . 9
1.15. Serving . . . 9
1.16. Importar el proyecto . . . 10
1.17. Formalizar el experimento . . . 10
1.18. Primer pilar: almacenamiento en Delta Lake . . . 11
1.19. Segundo pilar: MLflow Tracking . . . 11
1.20. Revisar las ejecuciones . . . 12
1.21. Tercer pilar: Model Registry . . . 12
1.22. Crear el endpoint de servicio . . . 13
1.23. Nombrar el endpoint . . . 13
1.24. Definir el escalamiento . . . 14
1.25. Esperar la configuración . . . 14
1.26. Endpoint disponible . . . 15
1.27. Probar el servicio . . . 15
1.28. Interpretar la respuesta . . . 16

Presentación

Esta guía documenta el procedimiento presentado en el video tutorial *Databricks Free Edition*: la creación de una cuenta gratuita, el recorrido por la interfaz y un proyecto completo de *Machine Learning*, con datos en Delta Lake, seguimiento con MLflow, registro del modelo y despliegue como servicio. Cada paso incluye la captura de la pantalla correspondiente.

Nota

Por seguridad, los datos personales y las credenciales aparecen difuminados o cubiertos en las capturas: correo, códigos de verificación y datos de la cuenta. Cada estudiante debe diligenciar esos campos con sus propios datos.

Requisitos previos. Navegador actualizado y cuenta institucional con acceso a Microsoft Authenticator.

1. Procedimiento

1.1 Ingresar al sitio de Databricks

Busque *Databricks* en el navegador, abra el primer enlace (`databricks.com`) y seleccione **Try Databricks**.

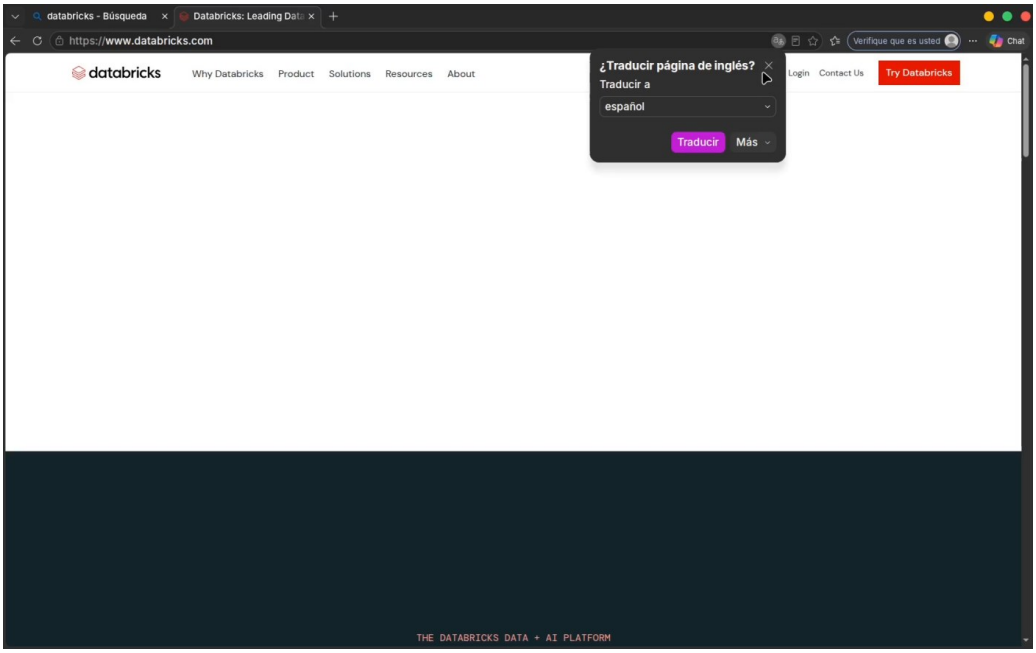


Figura 1: Ingresar al sitio de Databricks

1.2 Registrarse con la cuenta institucional

En la pantalla **Sign up**, seleccione **Continue with Microsoft** para ingresar con la cuenta institucional.

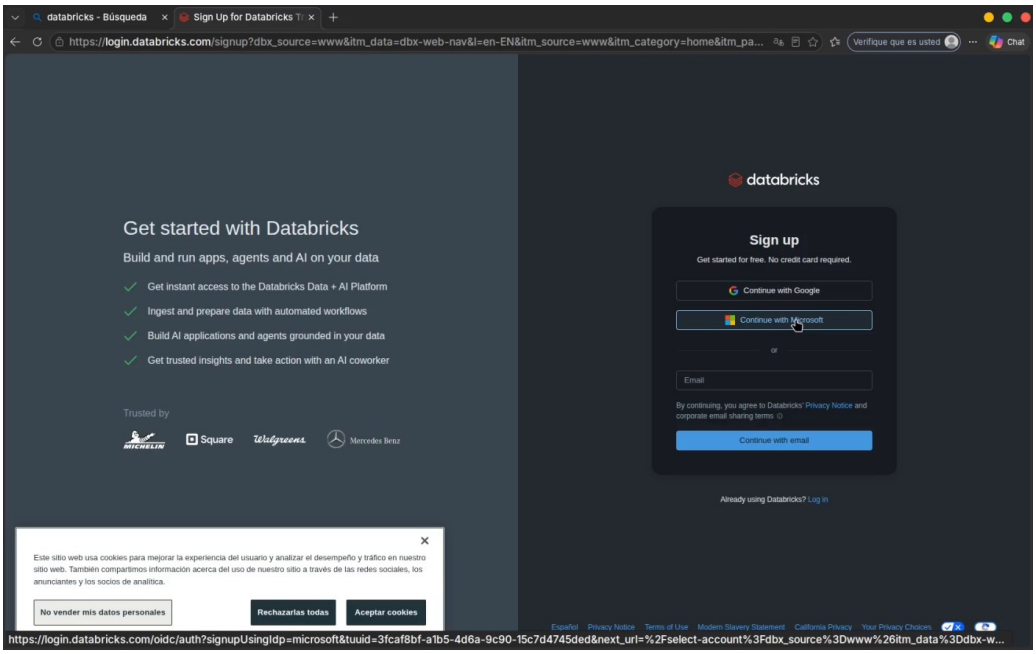


Figura 2: Registrarse con la cuenta institucional

1.3 Aprobar el inicio de sesión

Abra Microsoft Authenticator en el teléfono y apruebe la solicitud; digite el número que aparece en pantalla si la aplicación lo solicita.

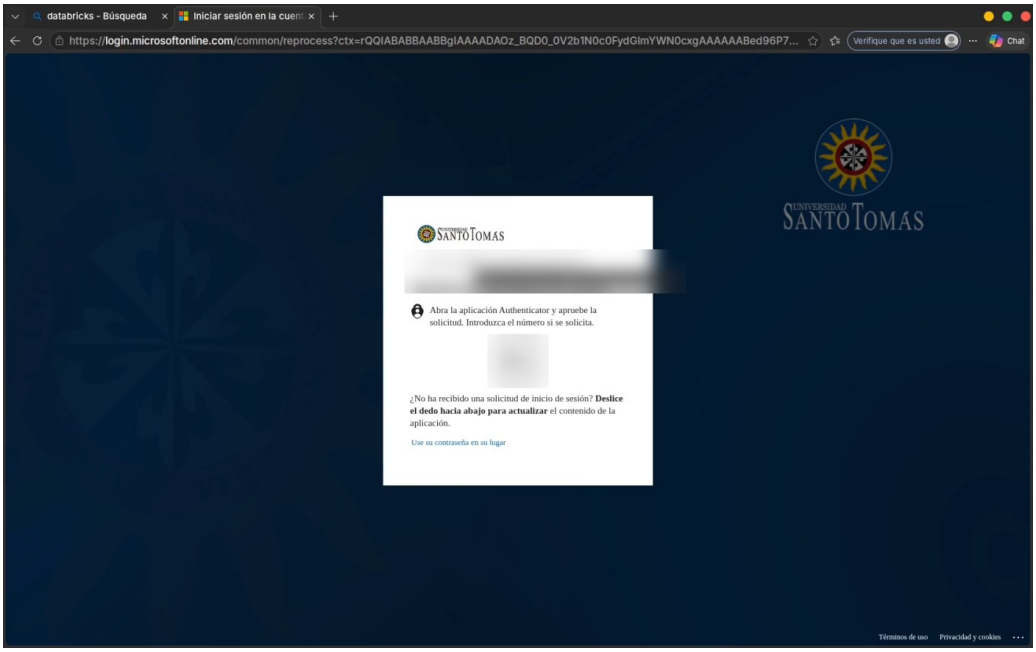


Figura 3: Aprobar el inicio de sesión

1.4 Seleccionar o crear la cuenta

Si Databricks detecta una cuenta asociada al correo, se muestra **Welcome back**. Elija la cuenta existente o **Create a new account**.

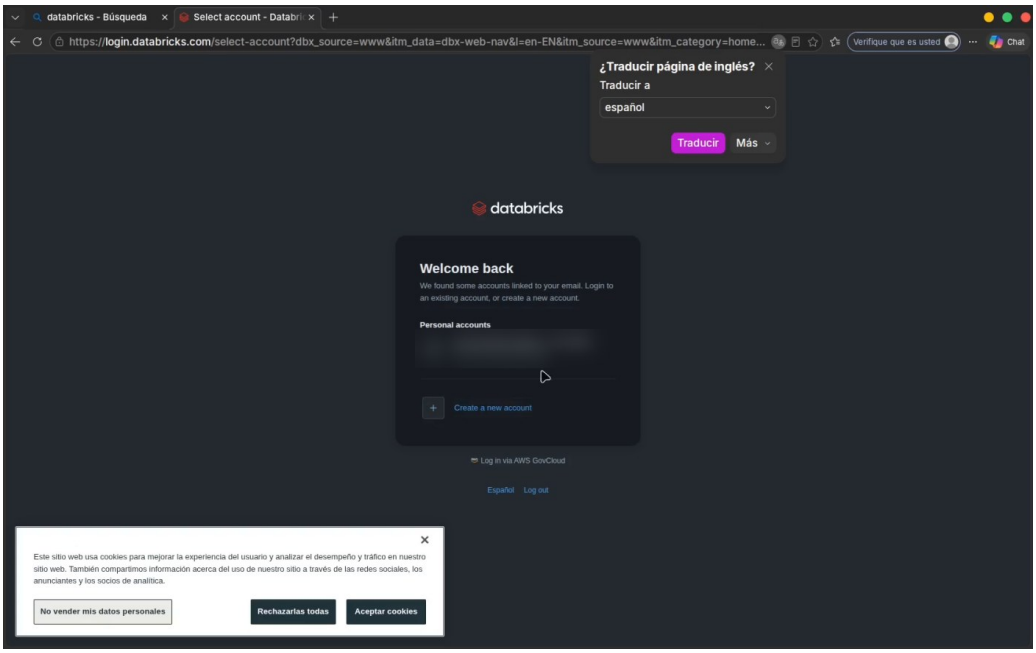


Figura 4: Seleccionar o crear la cuenta

1.5 Elegir el uso personal

En **What will you use Databricks for?**, seleccione **For personal use** y luego **Get Free Edition**. Esta edición no requiere tarjeta de crédito.

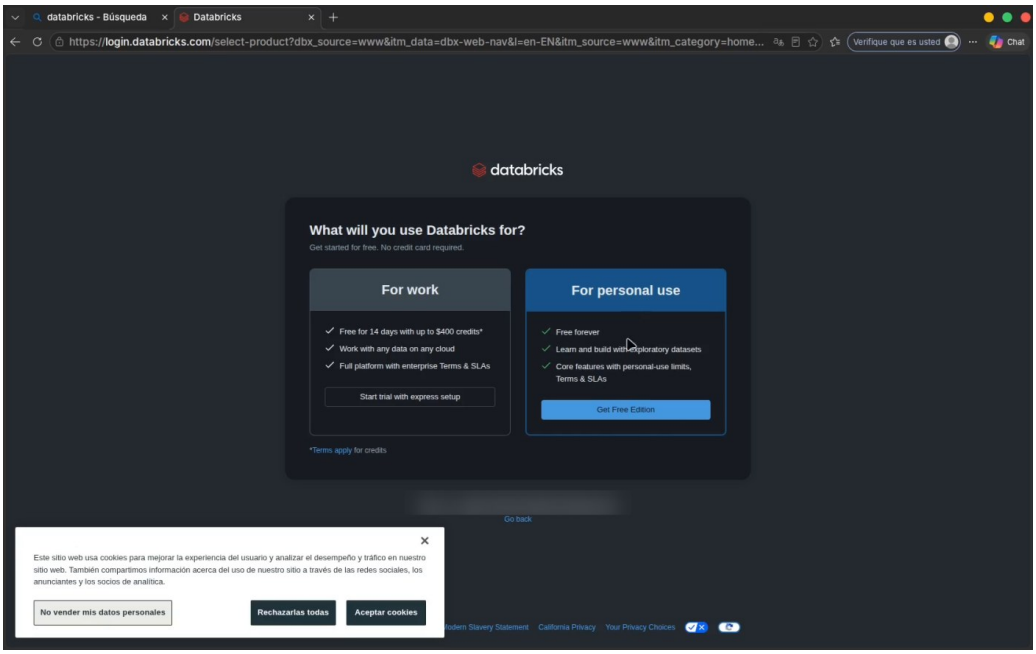


Figura 5: Elegir el uso personal

1.6 Configurar la cuenta

Indique el nombre de la cuenta y el país (**Where are you located?**) y pulse **Continue**. Espere mientras el sistema prepara el espacio de trabajo.

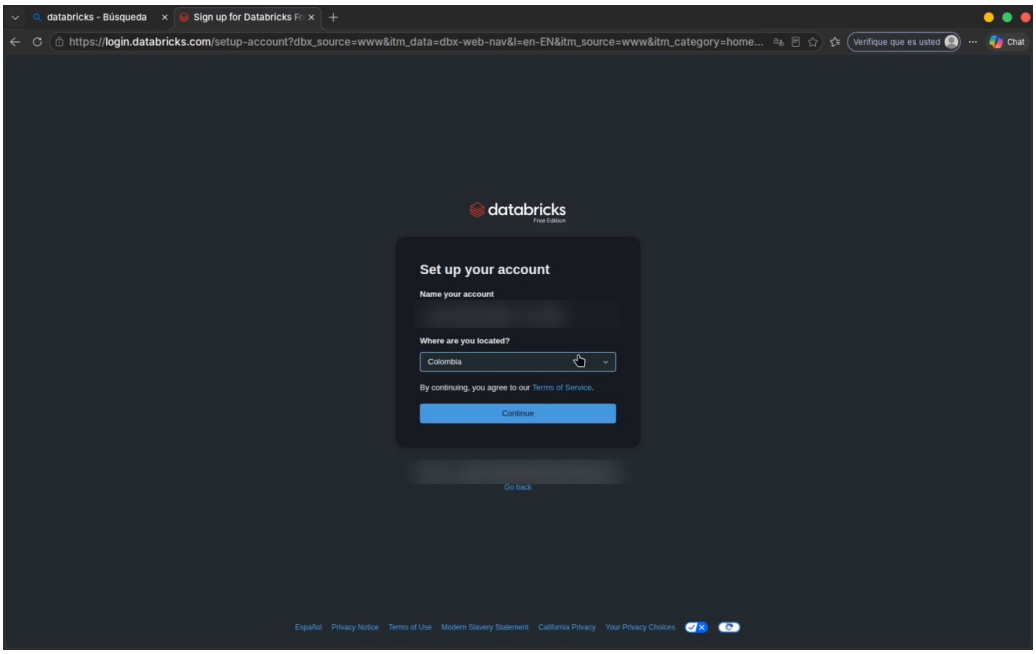


Figura 6: Configurar la cuenta

1.7 Pantalla de bienvenida

Al finalizar se muestra **Welcome to Databricks**. El buscador superior (atajo `Ctrl + P`) localiza cuadernos, tablas, experimentos y funciones. La barra izquierda organiza las herramientas por bloques.

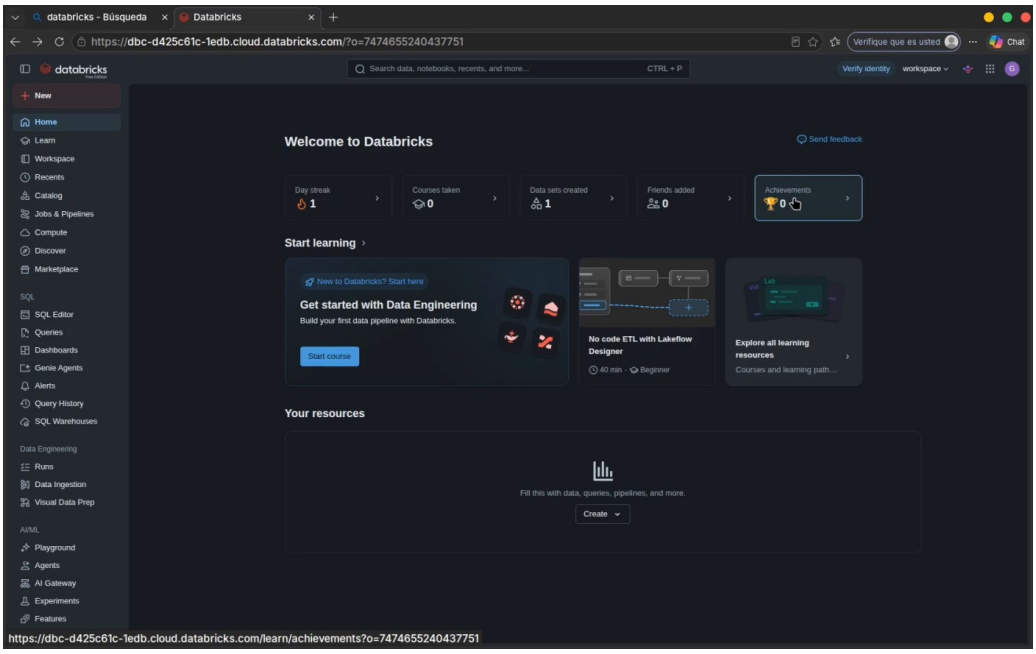


Figura 7: Pantalla de bienvenida

1.8 Workspace

Workspace es el explorador de archivos del entorno: allí se organizan los cuadernos y las carpetas del proyecto.

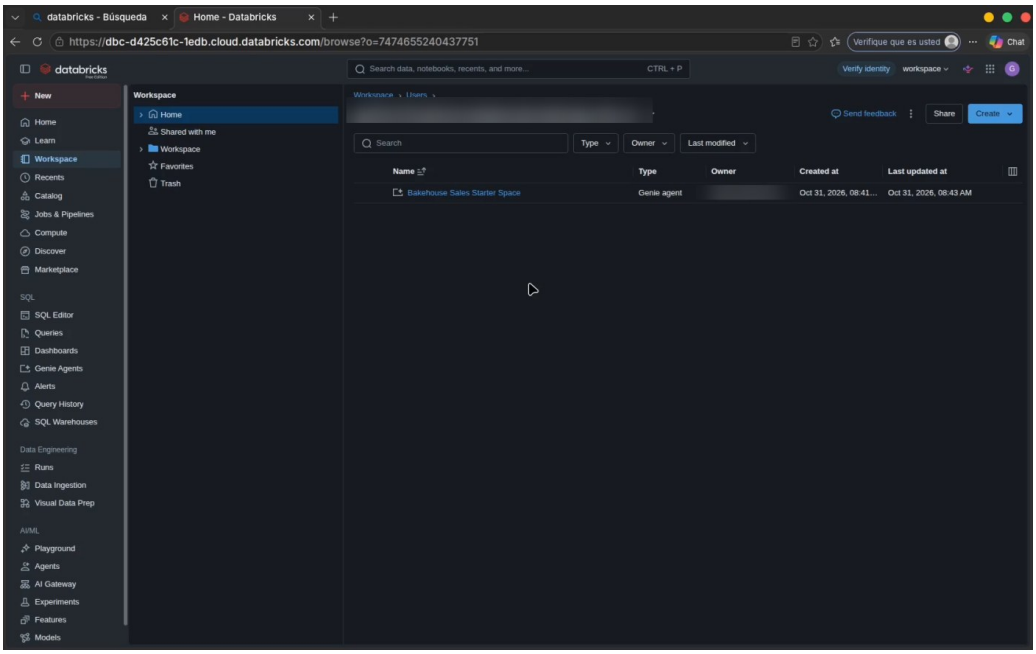


Figura 8: Workspace

1.9 Catalog

Catalog permite gestionar tablas estructuradas, esquemas y permisos.

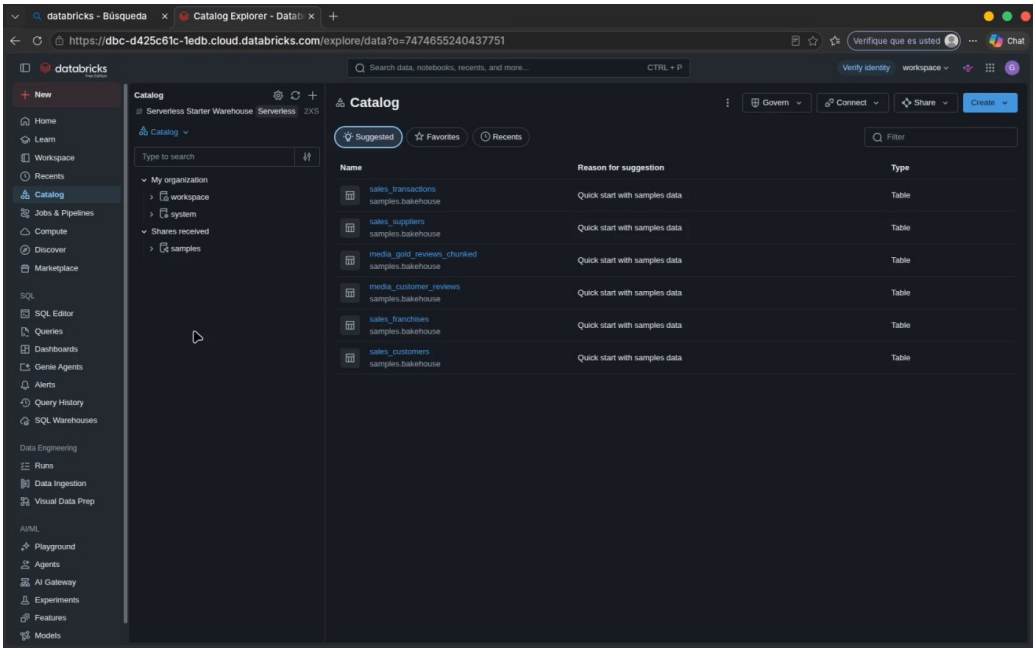


Figura 9: Catalog

1.10 Compute

Compute administra los motores de cálculo. Con la opción *serverless*, el recurso **Default Interactive Compute** ejecuta el código sin configurar máquinas virtuales de forma manual.

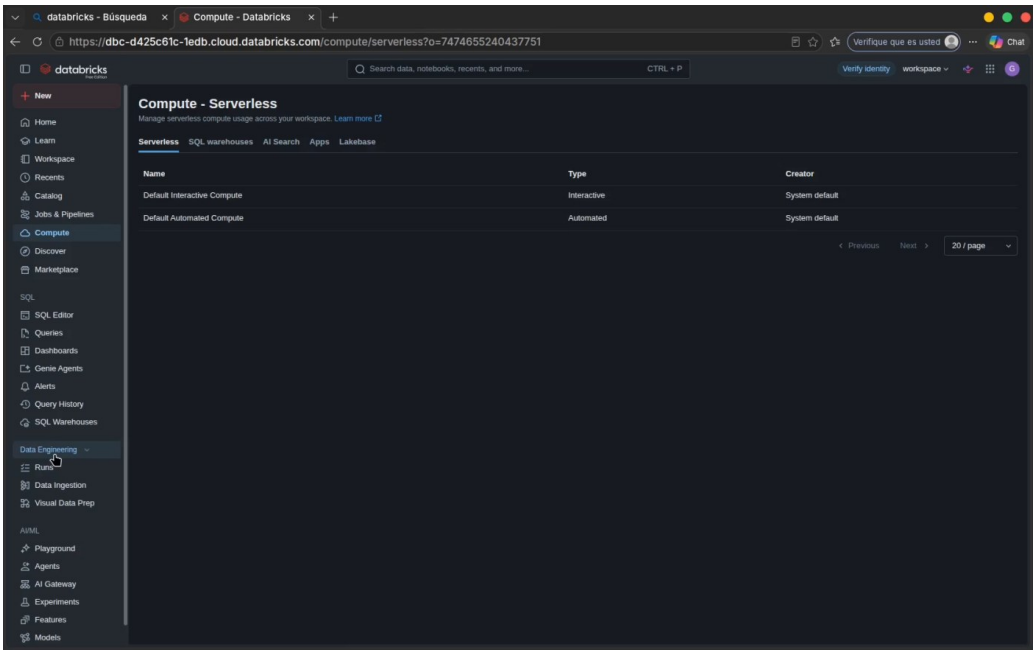


Figura 10: Compute

1.11 SQL Editor

El bloque SQL incluye **SQL Editor** para consultas, **Dashboards** para tableros interactivos y **Genie Agents** para consultas en lenguaje natural.

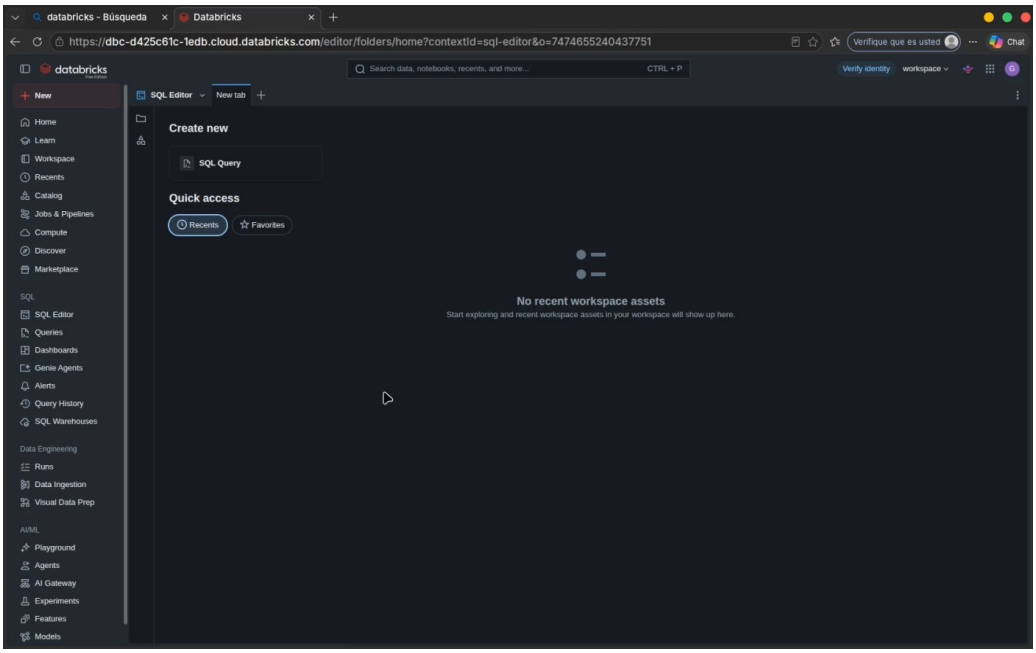


Figura 11: SQL Editor

1.12 SQL Warehouses

SQL Warehouses ofrece los recursos *serverless* que ejecutan las cargas analíticas de SQL. El bloque *Data Engineering* agrupa además **Runs**, **Data Ingestion** y **Visual Data Prep**.

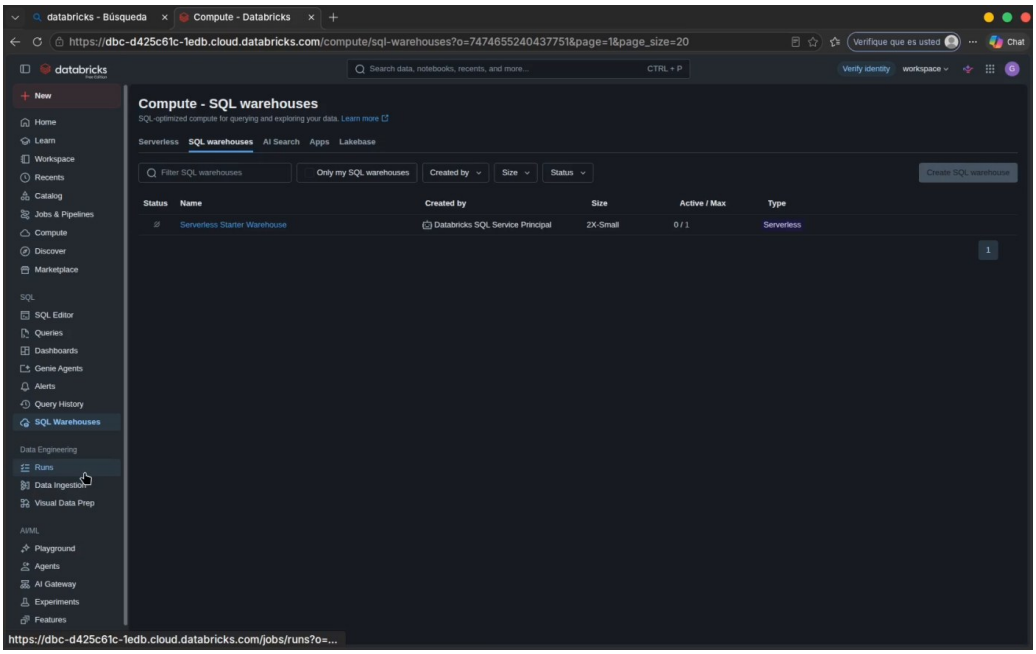


Figura 12: SQL Warehouses

1.13 Experiments

Experiments es el motor integrado de MLflow para hacer seguimiento a métricas, parámetros y curvas de entrenamiento.

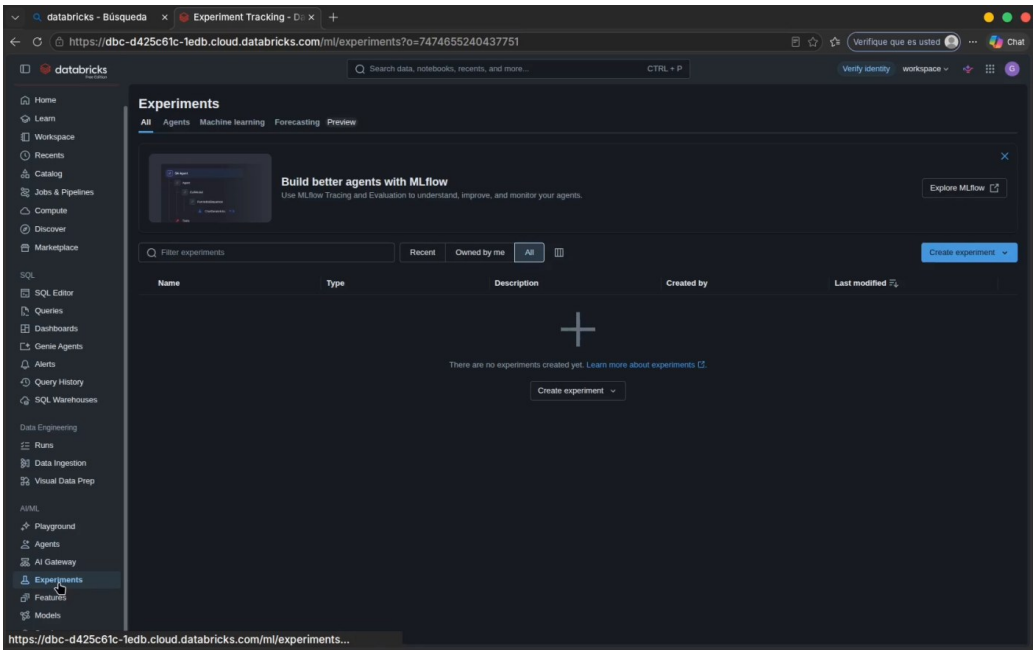


Figura 13: Experiments

1.14 Models

Models permite registrar, catalogar, gobernar y versionar los modelos.

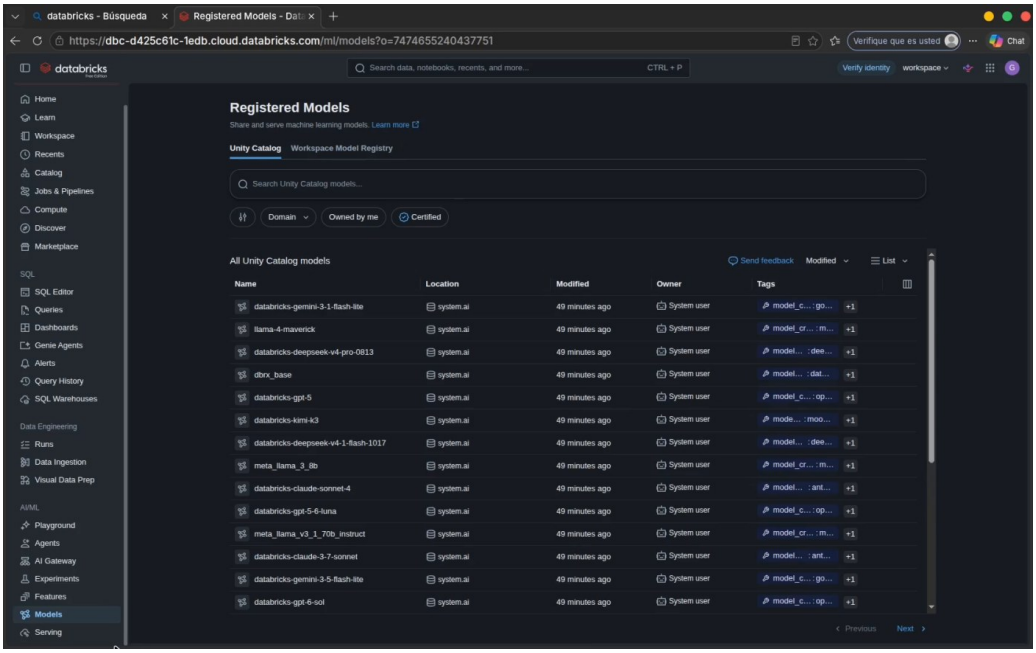


Figura 14: Models

1.15 Serving

Serving es la infraestructura para desplegar *endpoints* REST en tiempo real.

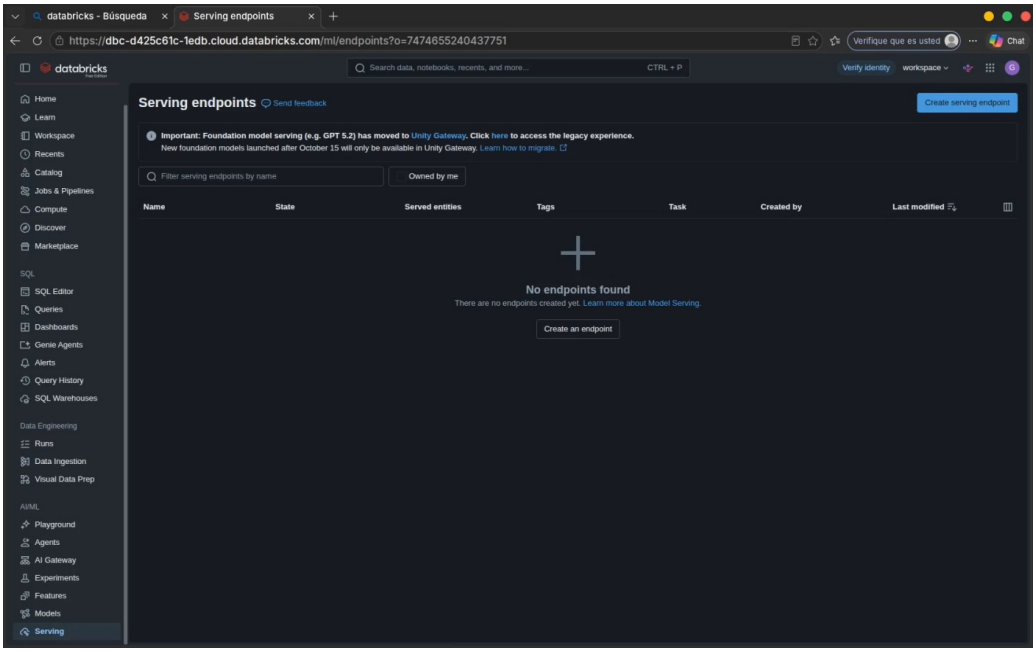


Figura 15: Serving

1.16 Importar el proyecto

En **Workspace**, abra el menú de la carpeta del usuario, seleccione **Import** y cargue el cuaderno del proyecto.

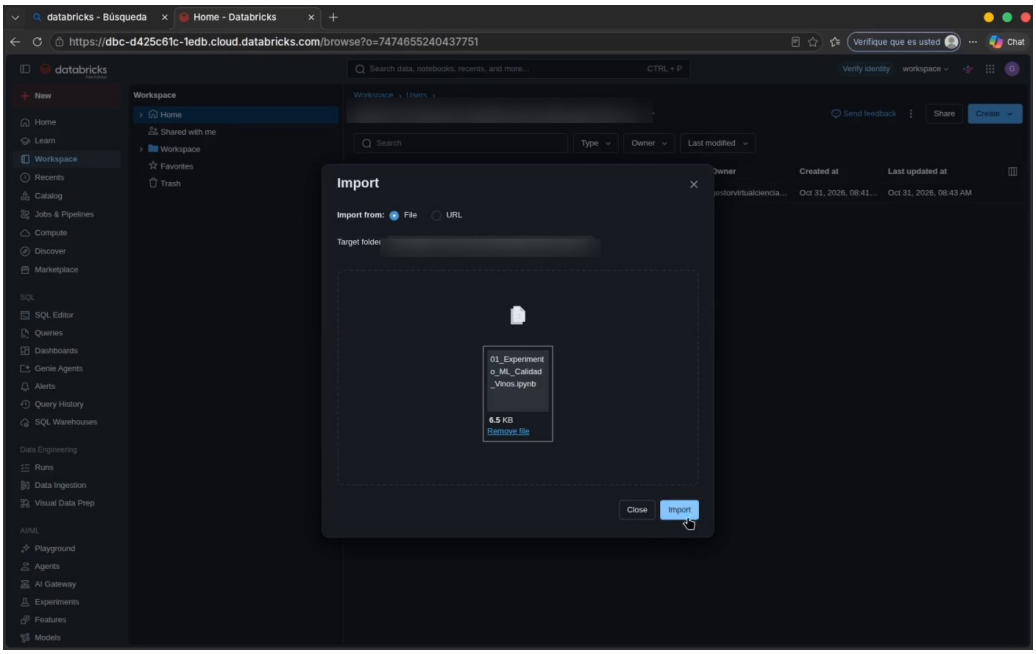


Figura 16: Importar el proyecto

1.17 Formalizar el experimento

El cuaderno inicia con la pregunta analítica y las hipótesis nula (H_0) y alternativa (H_1) sobre el efecto de la complejidad del modelo en su capacidad de generalización.



Figura 17: Formalizar el experimento

1.18 Primer pilar: almacenamiento en Delta Lake

Ejecute la celda de ingesta. Los datos persisten en el catálogo como una tabla Delta, lo cual aporta transacciones ACID, control de versiones y gobernanza.

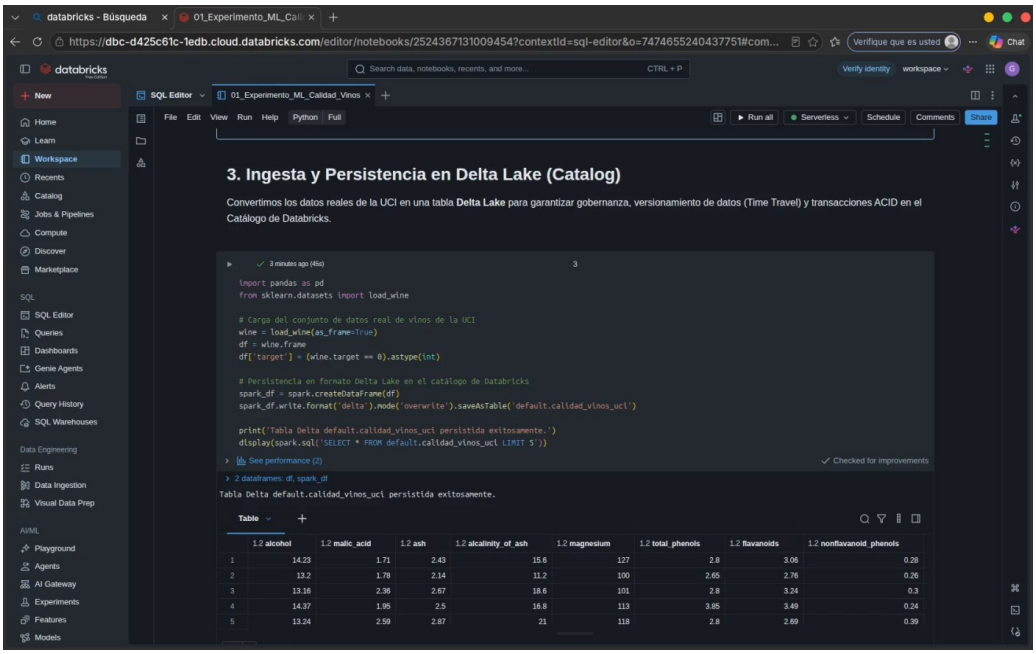


Figura 18: Primer pilar: almacenamiento en Delta Lake

1.19 Segundo pilar: MLflow Tracking

Esta celda entrena un *Random Forest* con diferentes profundidades. Cada ejecución registra hiperparámetros, métricas (exactitud y F1), artefactos y la firma de datos.

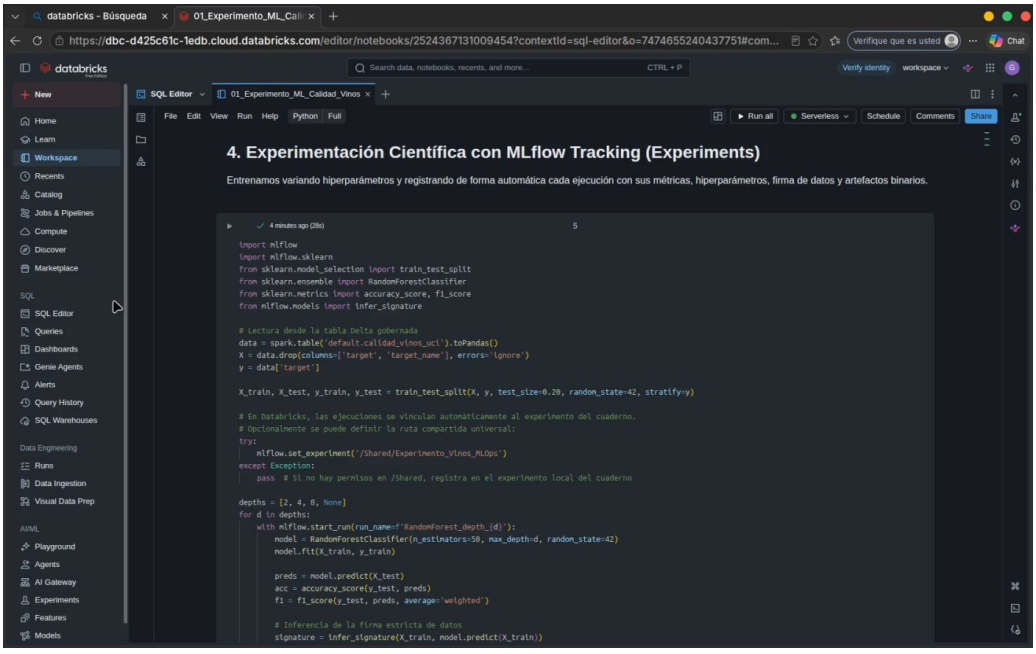


Figura 19: Segundo pilar: MLflow Tracking

1.20 Revisar las ejecuciones

Al terminar, la salida de la celda lista cada ejecución con su `max_depth`, `test_accuracy` y `test_f1`.

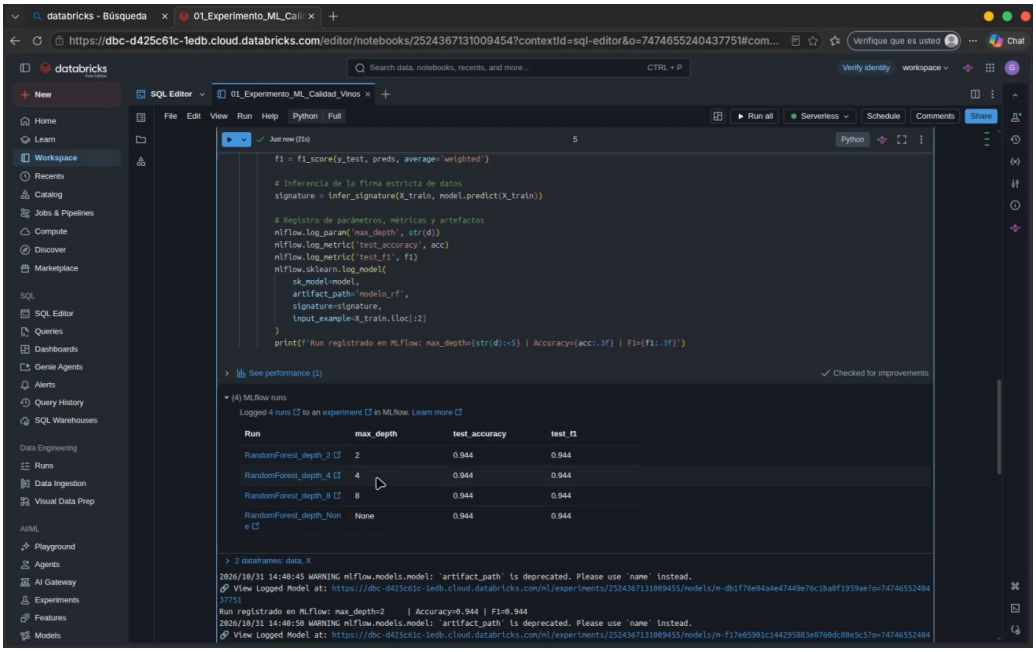


Figura 20: Revisar las ejecuciones

1.21 Tercer pilar: Model Registry

Ejecute la celda de registro. El modelo se cataloga formalmente con una versión, lo cual proporciona trazabilidad, auditoría y linaje de datos.

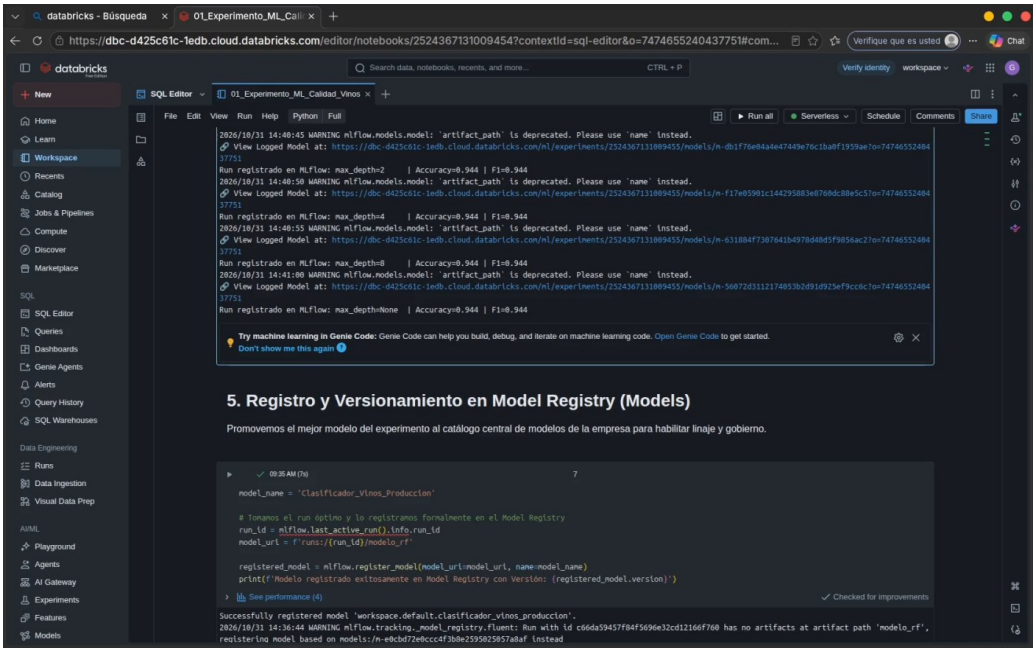


Figura 21: Tercer pilar: Model Registry

1.22 Crear el endpoint de servicio

Vaya a **Serving** y seleccione **Create serving endpoint**.

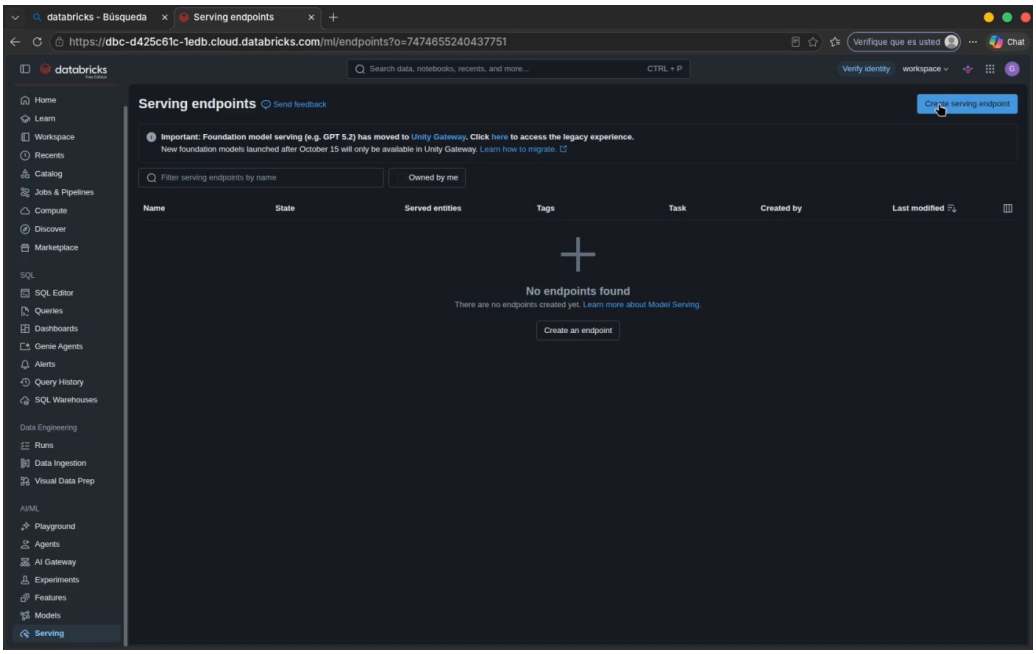


Figura 22: Crear el endpoint de servicio

1.23 Nombrar el endpoint

Asigne el nombre `endpoint-clasificador-vinos` y, en **Entity**, seleccione **My models** y el modelo registrado (`clasificador_vinos_produccion`).

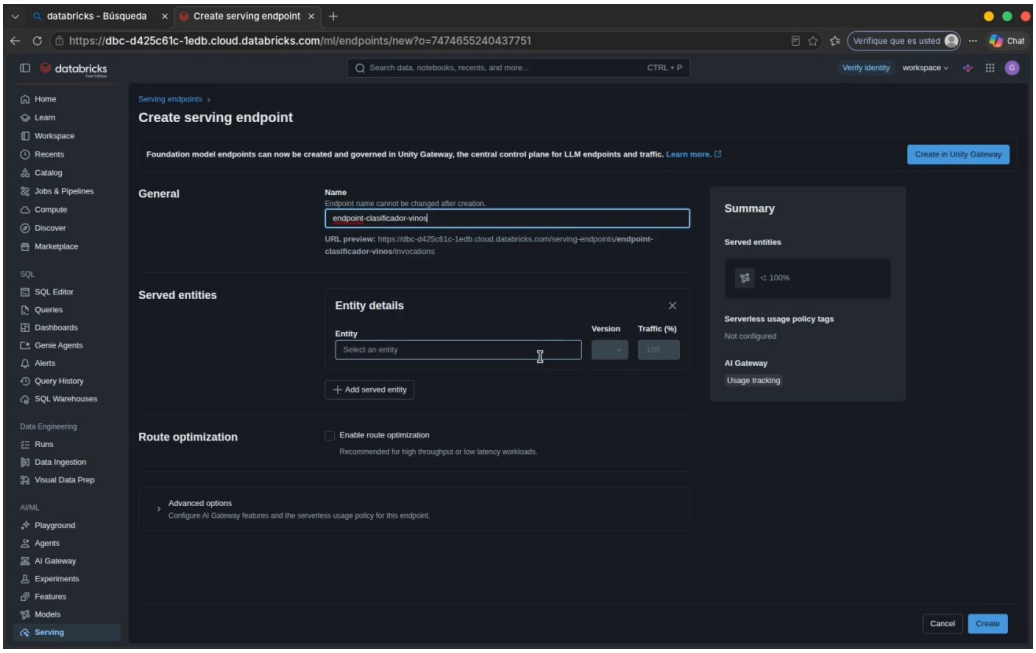


Figura 23: Nombrar el endpoint

1.24 Definir el escalamiento

En **Compute scale-out** elija **Small** y pulse **Create**. El tamaño depende de los requerimientos de cada caso; para esta práctica **Small** es suficiente.

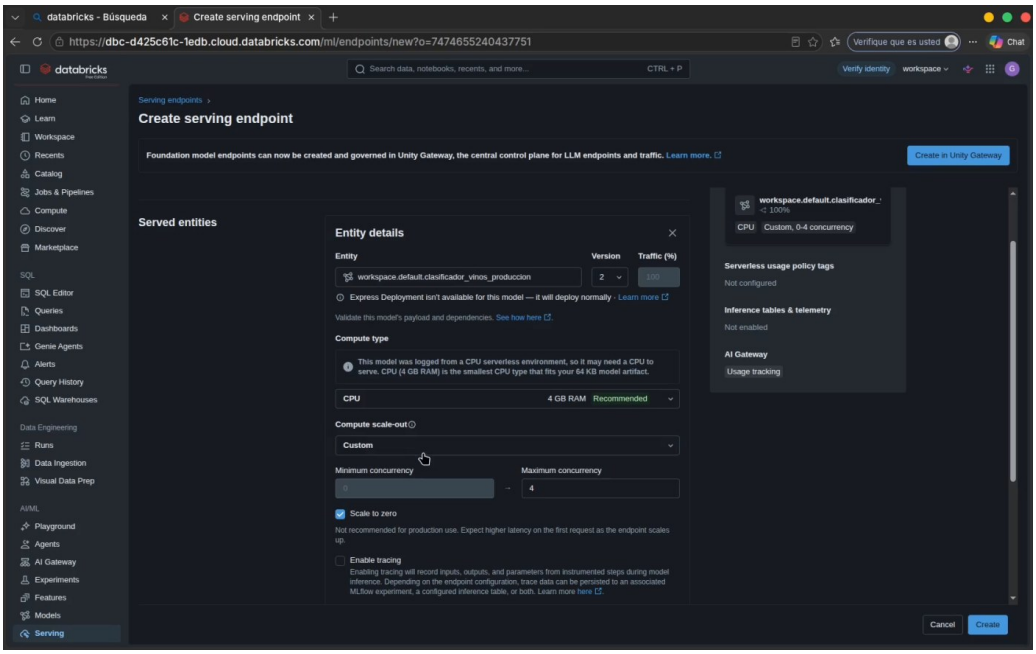


Figura 24: Definir el escalamiento

1.25 Esperar la configuración

El estado inicial es **Not ready**. Espere mientras el sistema configura el servicio.

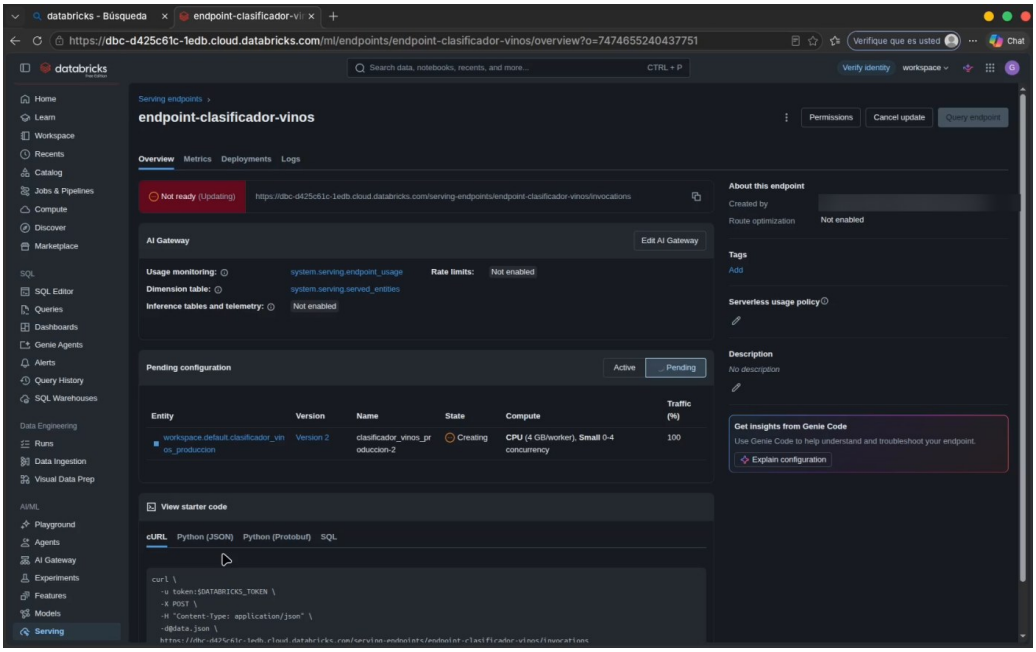


Figura 25: Esperar la configuración

1.26 Endpoint disponible

Cuando el estado cambia a **Ready**, en verde, el servicio está disponible para recibir solicitudes.

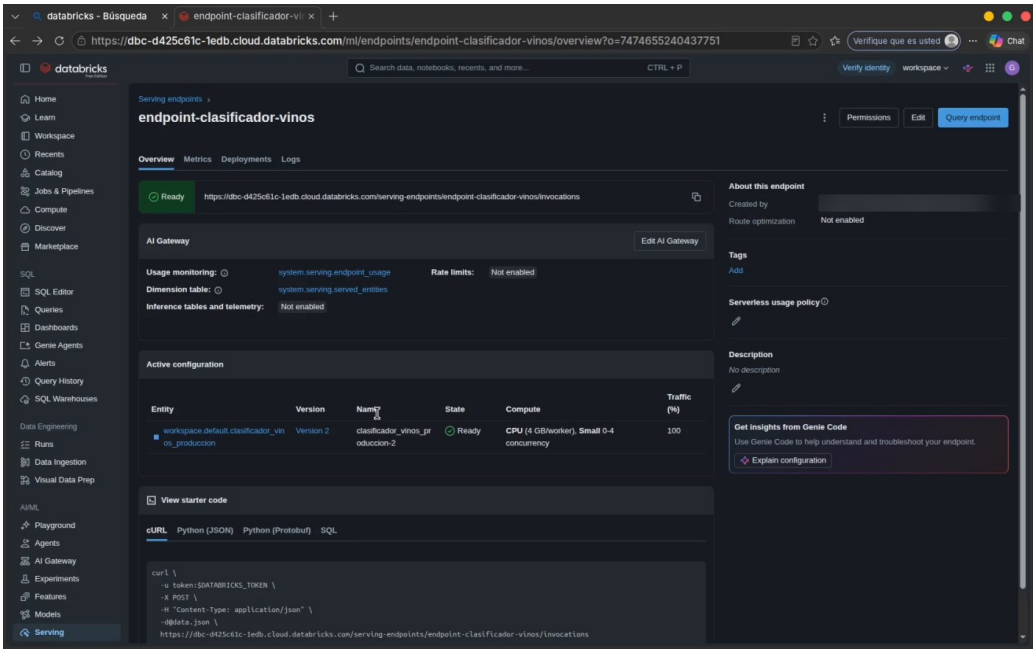


Figura 26: Endpoint disponible

1.27 Probar el servicio

Seleccione **Query endpoint**, reemplace la solicitud de ejemplo por las características del vino que desea evaluar y pulse **Send request**.

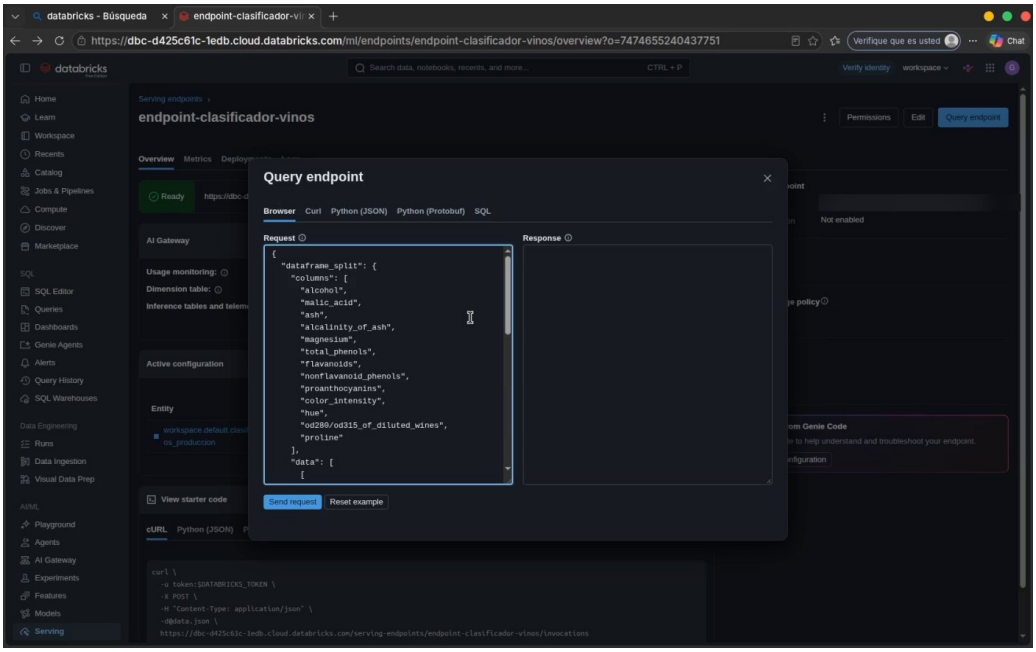


Figura 27: Probar el servicio

1.28 Interpretar la respuesta

La respuesta devuelve `predictions: [1]`, es decir, un vino de alta calidad para las características enviadas. Con esto finaliza el ciclo de vida del proyecto.

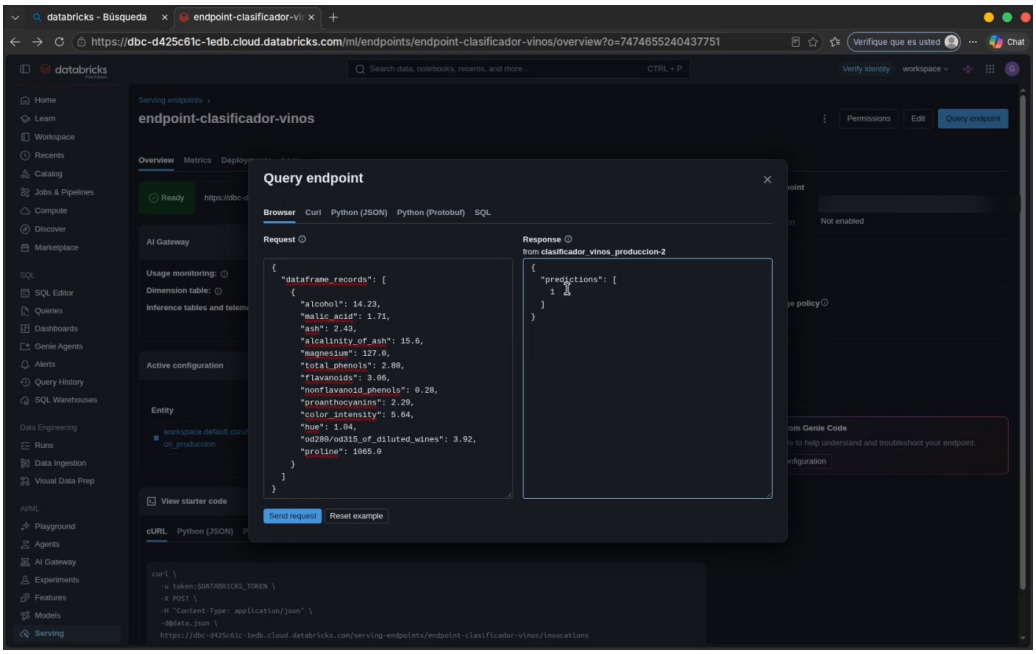


Figura 28: Interpretar la respuesta

Nota

Resumen. (1) Los datos persisten en tablas Delta Lake mediante el catálogo. (2) La experimentación queda registrada con MLflow Tracking. (3) El mejor modelo se versiona en Model Registry. (4) El artefacto se expone como servicio REST mediante Model Serving y se valida su inferencia en tiempo real.