

ESPECIALIZACIÓN EN CIENCIA DE DATOS

Guía de instalación paso a paso

Azure Databricks

Aprovisionamiento y experimento de regularización SVM con MLflow

Ing. Santiago Alejandro Zuñiga Melo



Índice

Presentación **3**

1. Suscripción de estudiante **3**
1.1. Abrir Azure for Students . . . 3
1.2. Verificación académica . . . 4

2. Portal de Azure **4**
2.1. Página inicial . . . 4
2.2. Herramientas de Microsoft Cloud . . . 5
2.3. Menú de servicios . . . 5
2.4. Validar la suscripción . . . 6

3. Creación del área de trabajo **6**
3.1. Buscar Azure Databricks . . . 6
3.2. Crear el servicio . . . 7
3.3. Datos de la instancia . . . 7
3.4. Tipo de área de trabajo . . . 8
3.5. Pestañas restantes . . . 8
3.6. Grupo de recursos . . . 9
3.7. Revisar y crear . . . 9
3.8. Implementación . . . 10

4. Inicio del área de trabajo **10**
4.1. Abrir el recurso . . . 10
4.2. Iniciar el área de trabajo . . . 11
4.3. Interfaz de Databricks . . . 11

5. Importación del cuaderno **12**
5.1. Abrir el espacio de trabajo . . . 12
5.2. Importar el archivo . . . 12
5.3. Revisar la descripción . . . 13

6. Ejecución del experimento **13**
6.1. Configurar el entorno . . . 13
6.2. Cargar los datos . . . 14
6.3. Barrido de regularización . . . 14
6.4. Curva de regularización . . . 15
6.5. Persistencia y registro . . . 15
6.6. Resumen del modelo . . . 16

7. Verificación en MLflow **16**

7.1. Lista de experimentos 16

7.2. Ejecución registrada 17

Presentación

Esta guía documenta el procedimiento presentado en el video tutorial *Azure Databricks*: activar la suscripción de estudiante con la cuenta institucional, crear un área de trabajo de Azure Databricks sin servidor, importar el cuaderno del proyecto y ejecutar un experimento de regularización con máquinas de vectores de soporte sobre datos biomédicos, registrado en MLflow. Cada paso incluye la captura de la pantalla correspondiente.

Importante

Azure Databricks consume los créditos de la suscripción. Revise el plan de tarifa elegido y los créditos disponibles, y elimine los recursos que no utilice al terminar la práctica.

Nota

Por seguridad, los datos de la cuenta aparecen difuminados en las capturas: nombre, correo, identificador de suscripción y direcciones del área de trabajo. Cada estudiante debe diligenciar esos campos con sus propios datos.

Requisitos previos. Navegador actualizado, cuenta institucional de dominio Microsoft y el archivo `04_Experimento_ML_Azure_Databricks.ipynb`.

1. Suscripción de estudiante

1.1 Abrir Azure for Students

En el navegador, ingrese a `azure.microsoft.com/free/students` y pulse **Empezar gratis**. Inicie sesión con el correo institucional.

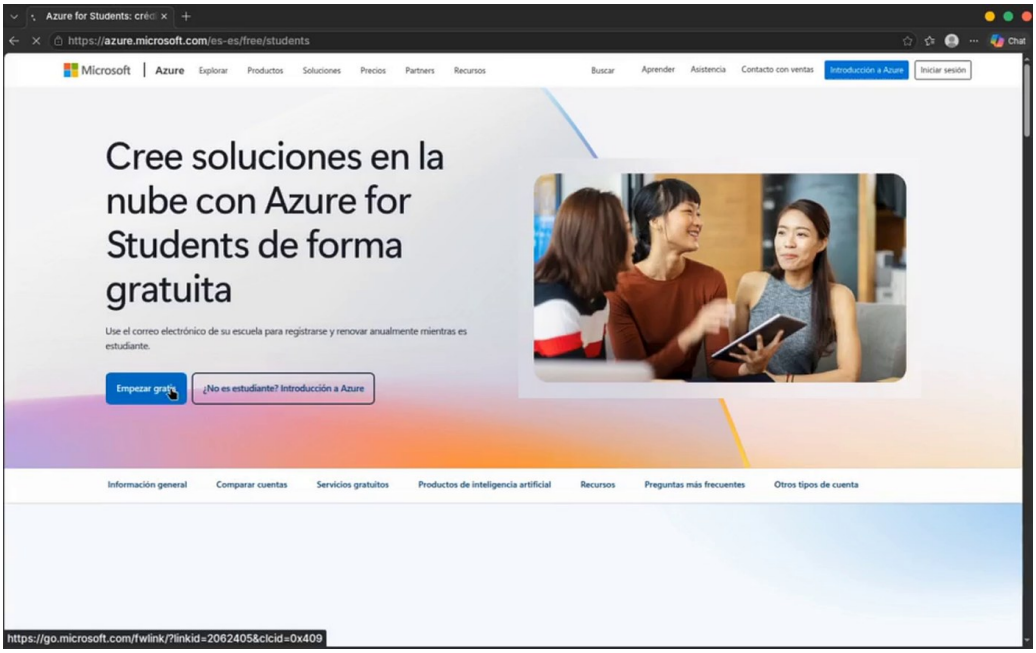


Figura 1: Abrir Azure for Students

1.2 Verificación académica

Diligencie el formulario con su nombre, apellido, país, escuela y fecha de nacimiento según los registros de la institución. Complete la verificación y pulse **Verificar estado académico**.

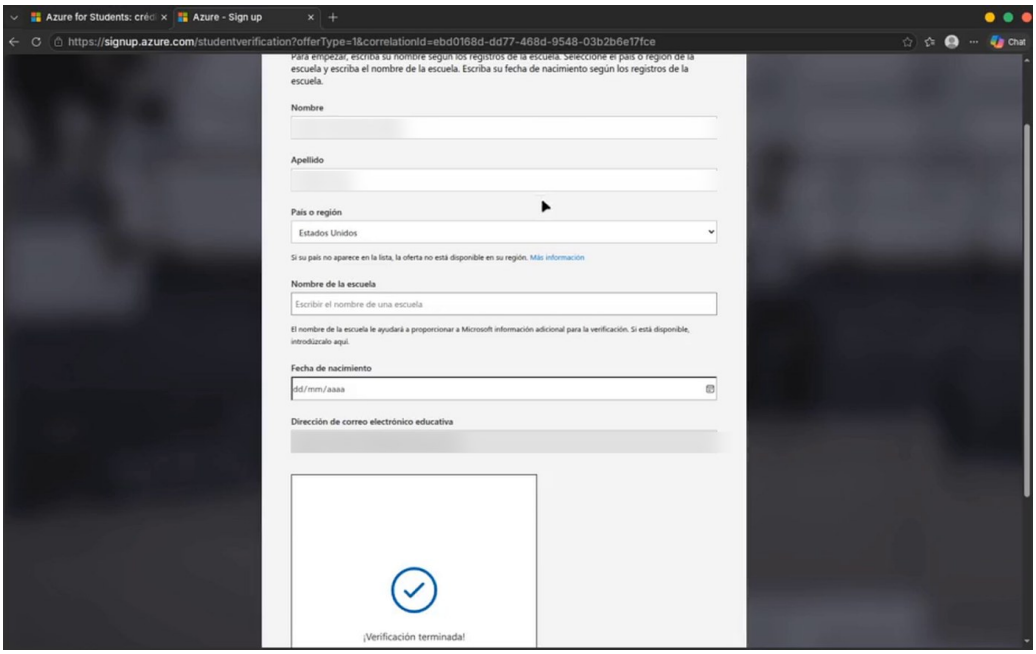


Figura 2: Verificación académica

2. Portal de Azure

2.1 Página inicial

Al terminar la verificación se abre el portal de Azure, con sus opciones de inicio y los servicios disponibles.

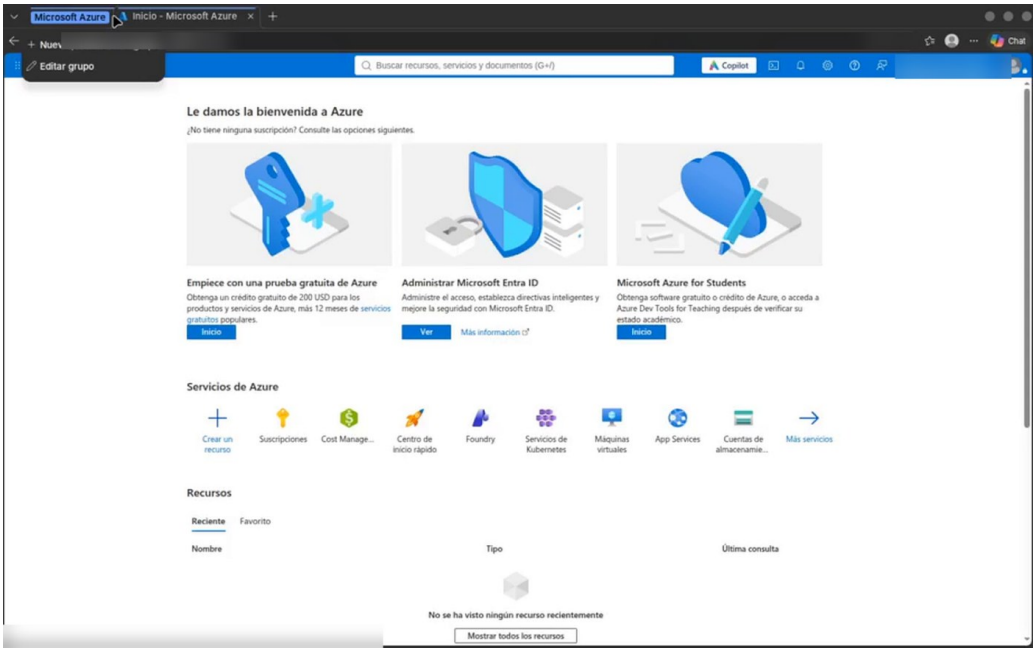


Figura 3: Página inicial

2.2 Herramientas de Microsoft Cloud

El menú superior da acceso a herramientas como Foundry, Copilot Studio, GitHub, Visual Studio Code y Defender.

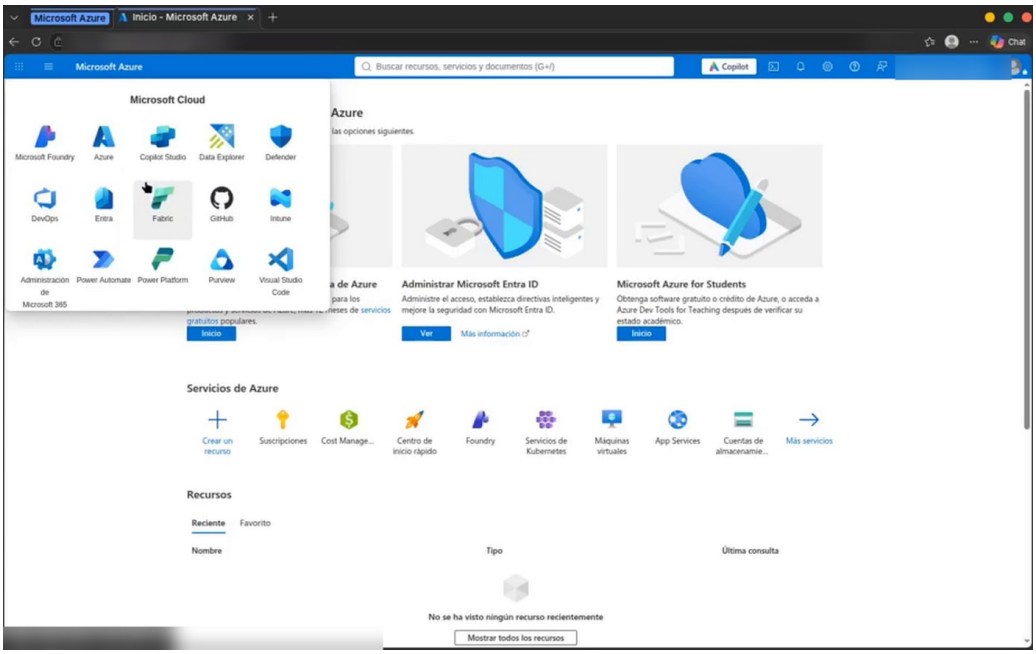


Figura 4: Herramientas de Microsoft Cloud

2.3 Menú de servicios

El menú lateral reúne servicios como bases de datos SQL, Azure Cosmos DB, máquinas virtuales y cuentas de almacenamiento.

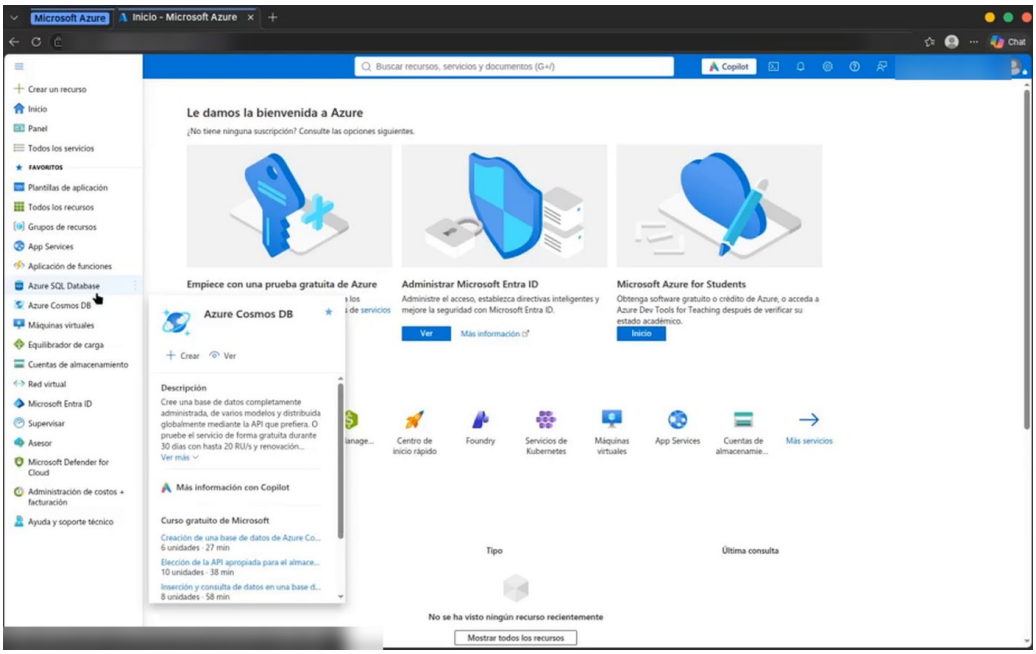


Figura 5: Menú de servicios

2.4 Validar la suscripción

Abra **Suscripciones** para comprobar que la suscripción está activa. Si la tabla aparece vacía, como en la captura, revise el filtro **Suscripciones** de la parte superior.

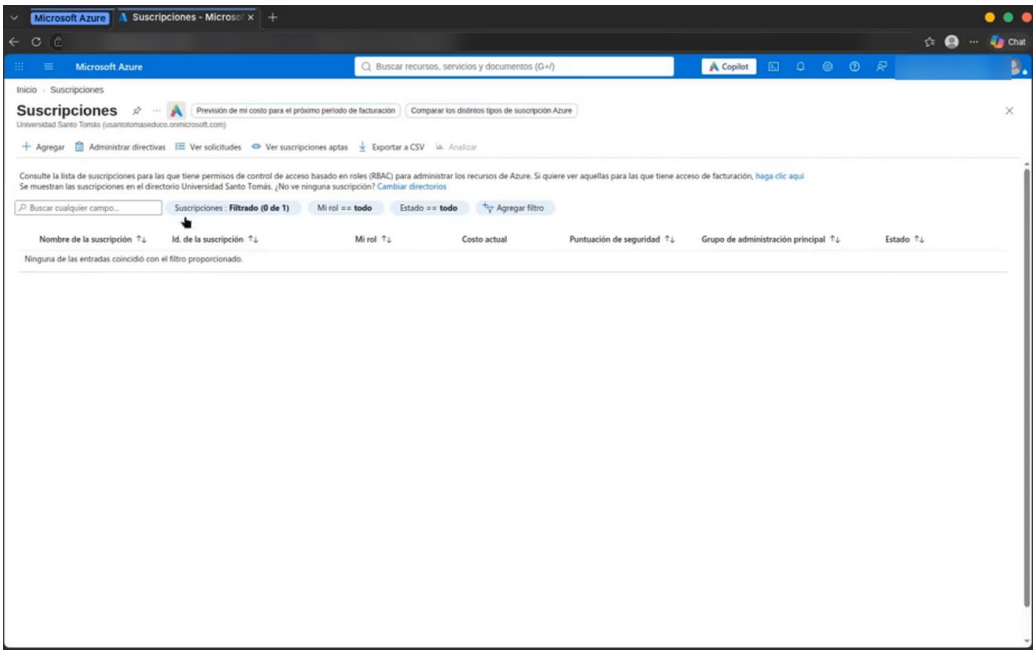


Figura 6: Validar la suscripción

3. Creación del área de trabajo

3.1 Buscar Azure Databricks

En el buscador del portal escriba *Databricks* y abra el servicio **Azure Databricks**.

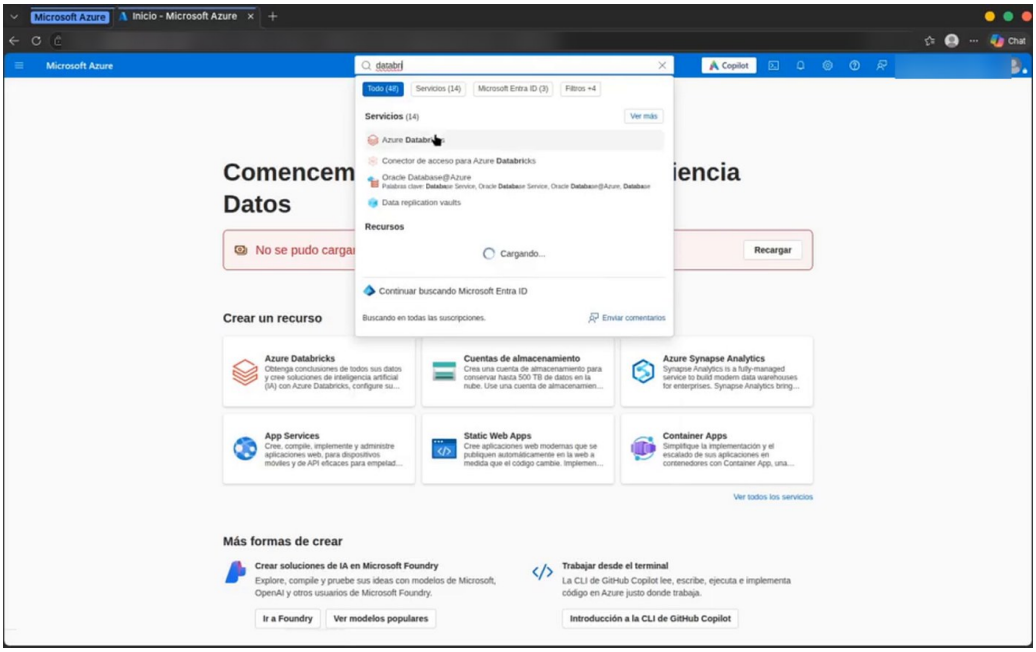


Figura 7: Buscar Azure Databricks

3.2 Crear el servicio

Como todavía no hay servicios para mostrar, pulse **Crear**.

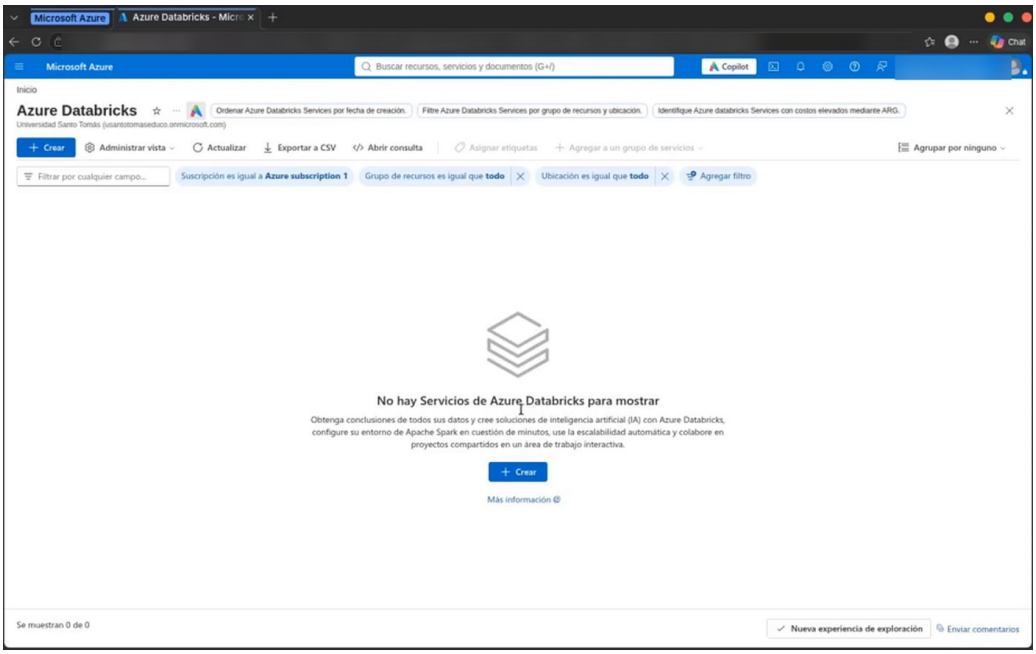


Figura 8: Crear el servicio

3.3 Datos de la instancia

En **Datos básicos**, escriba el nombre del área de trabajo (en el ejemplo, `rg-cienciadatos-tg1`) y seleccione la región (**East US**) y el plan de tarifa (**Premium**).

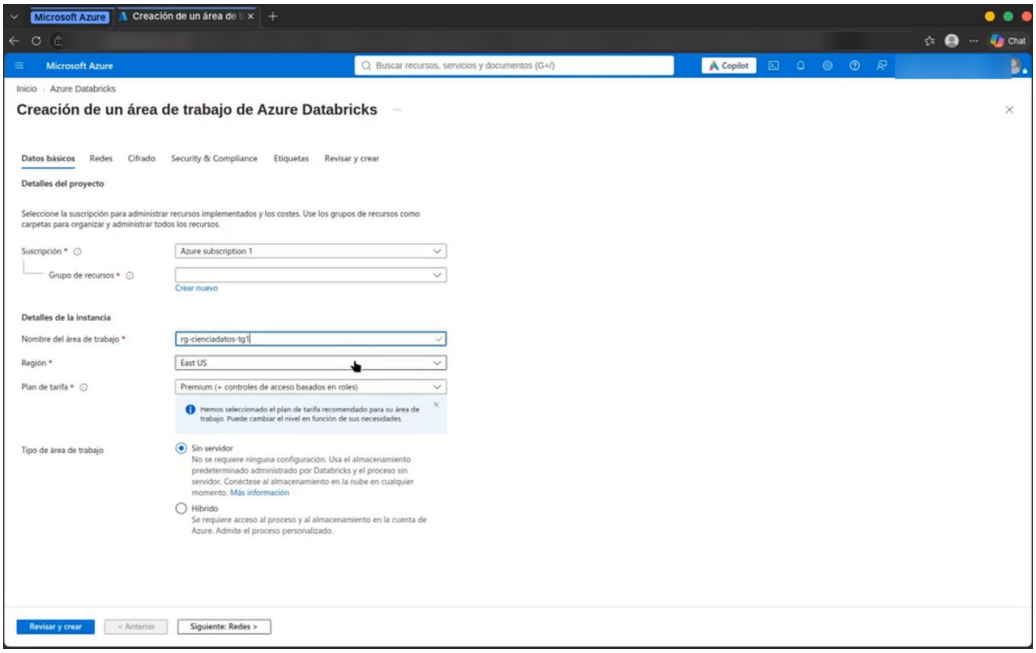


Figura 9: Datos de la instancia

3.4 Tipo de área de trabajo

Conserve la opción **Sin servidor**, con la cual Databricks administra la capacidad de cómputo.

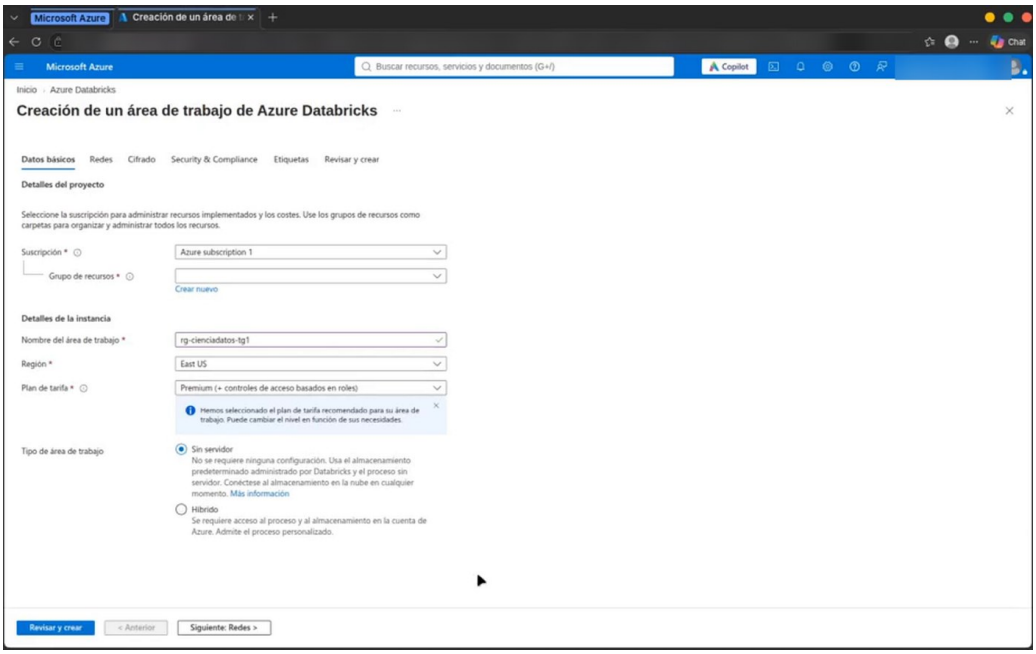


Figura 10: Tipo de área de trabajo

3.5 Pestañas restantes

Revise **Redes**, **Cifrado** y **Security & Compliance**, y conserve los valores predeterminados.

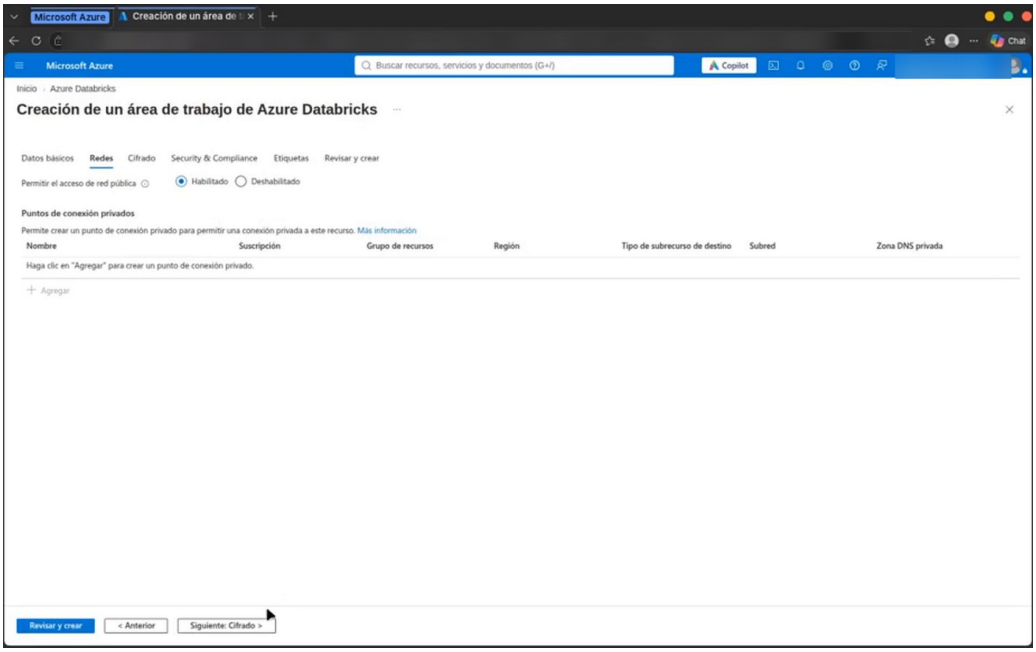


Figura 11: Pestañas restantes

3.6 Grupo de recursos

El grupo de recursos es obligatorio. Si no dispone de uno, en **Datos básicos** seleccione **Crear nuevo**, asigne un nombre (en el ejemplo, `gests`) y acepte. Sin este dato, la validación mostrará un error en esa pestaña.

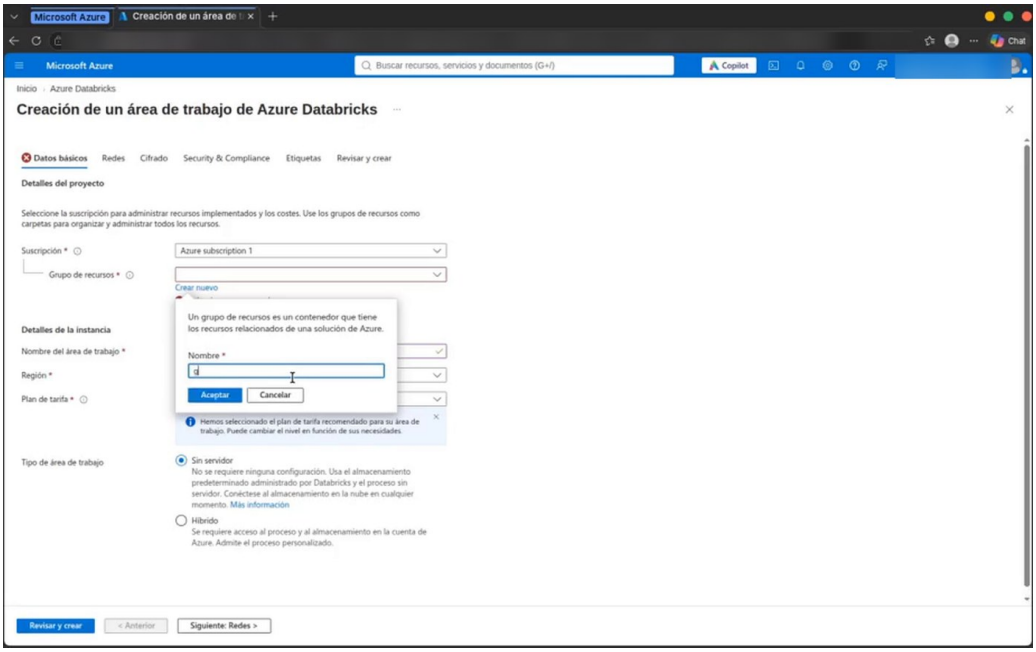


Figura 12: Grupo de recursos

3.7 Revisar y crear

Pulse **Revisar y crear**, espere a que la validación termine correctamente y seleccione **Crear**.

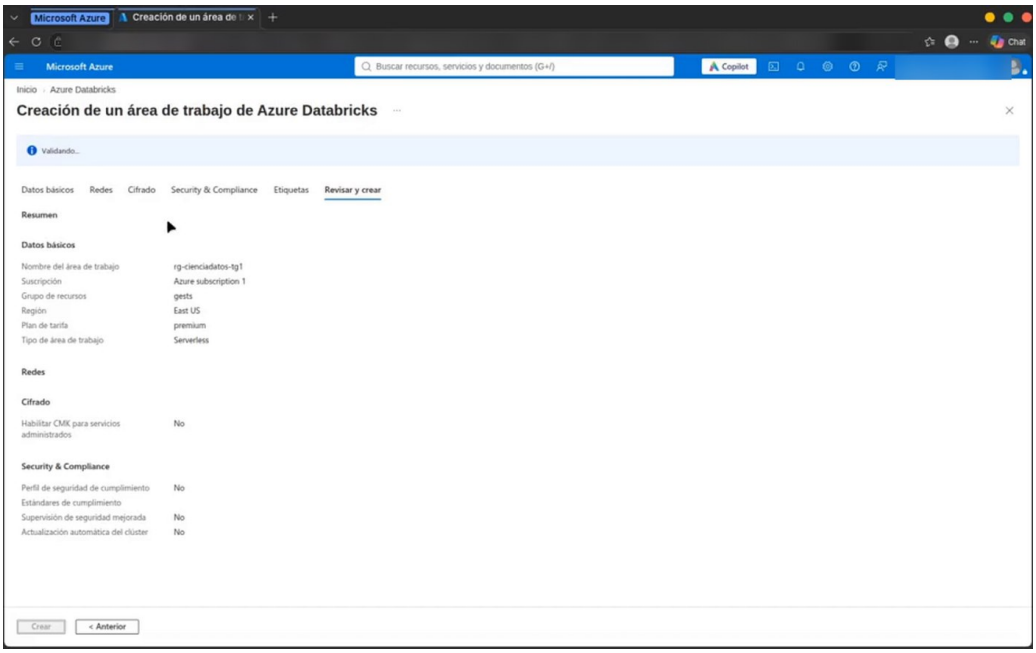


Figura 13: Revisar y crear

3.8 Implementación

El portal muestra el avance de la implementación. Espere a que el recurso quede creado.

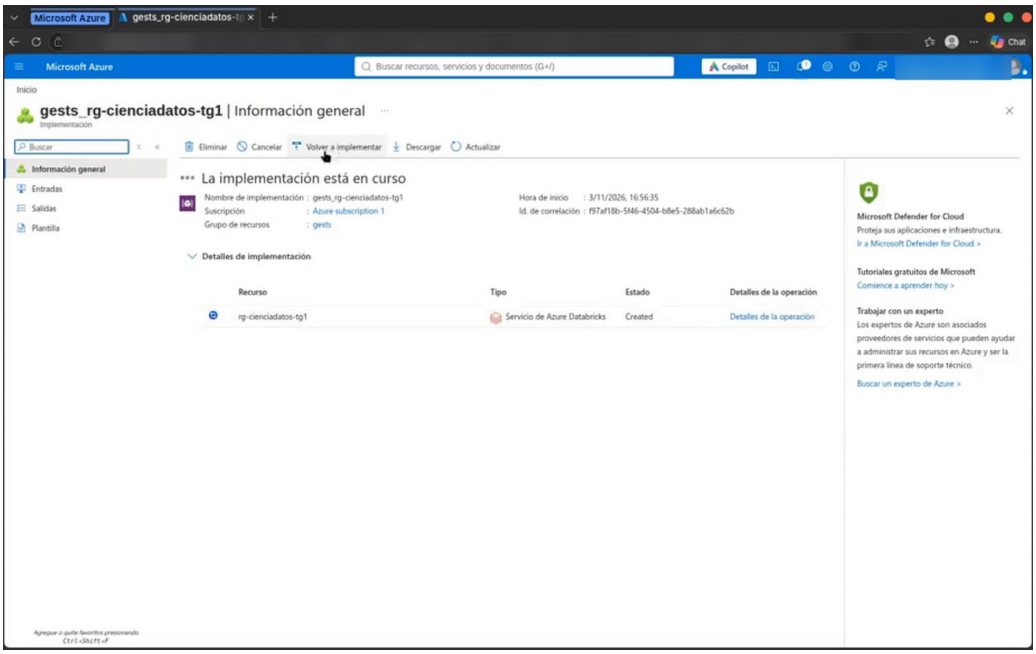


Figura 14: Implementación

4. Inicio del área de trabajo

4.1 Abrir el recurso

Vuelva a **Azure Databricks** y seleccione el área de trabajo creada.

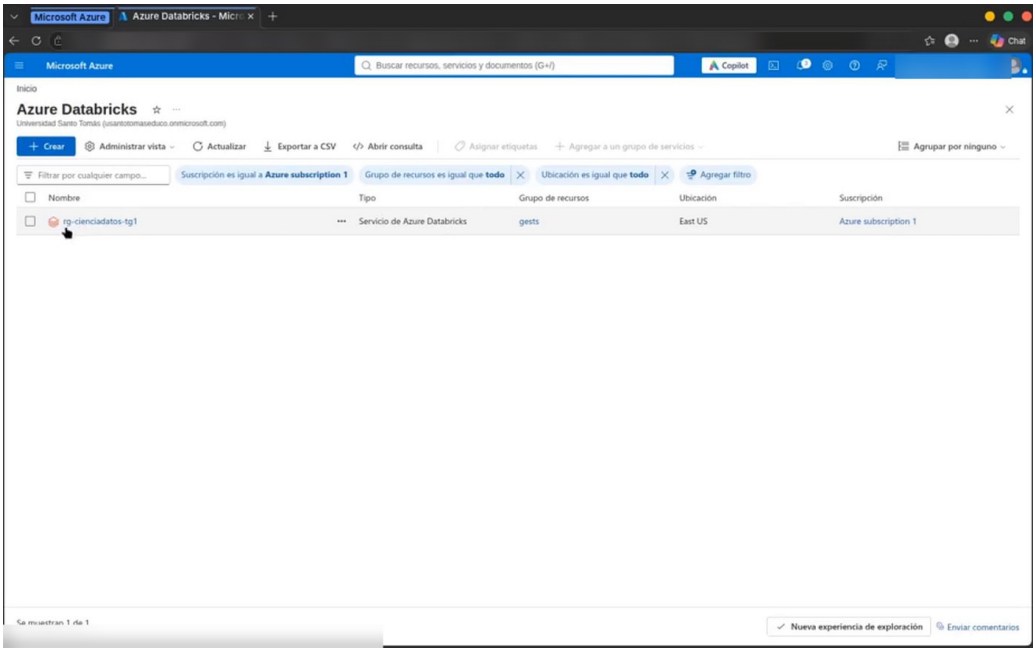


Figura 15: Abrir el recurso

4.2 Iniciar el área de trabajo

En la información general del recurso, pulse **Iniciar área de trabajo**. Se abrirá una pestaña nueva.

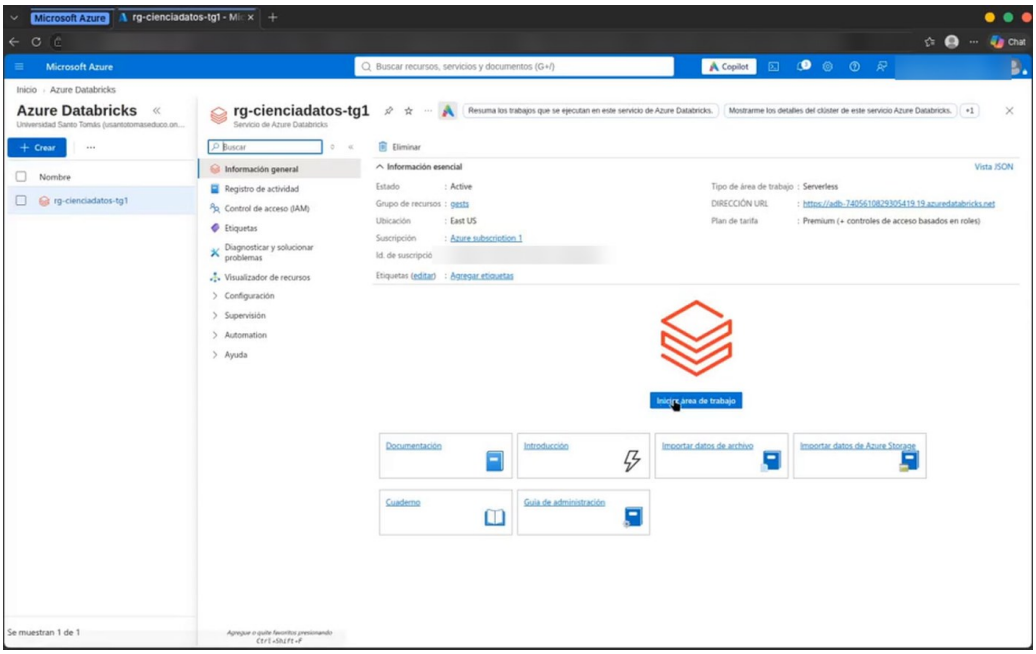


Figura 16: Iniciar el área de trabajo

4.3 Interfaz de Databricks

La interfaz incluye Workspace, Cómputo, Marketplace, herramientas de SQL, ingeniería de datos e inteligencia artificial.

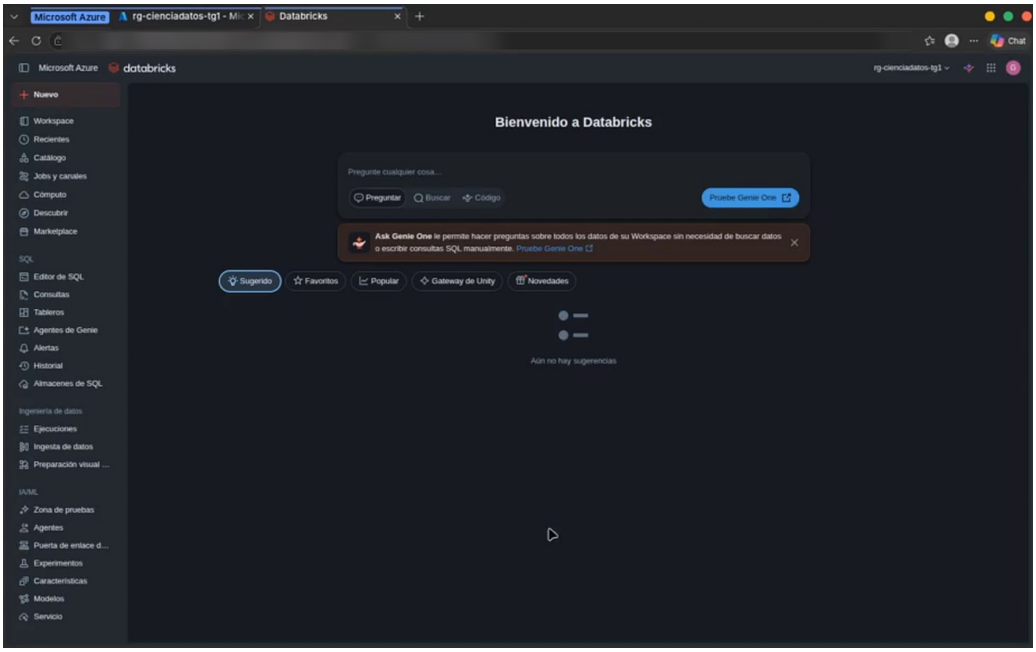


Figura 17: Interfaz de Databricks

5. Importación del cuaderno

5.1 Abrir el espacio de trabajo

Seleccione **Workspace** y abra su carpeta de usuario.

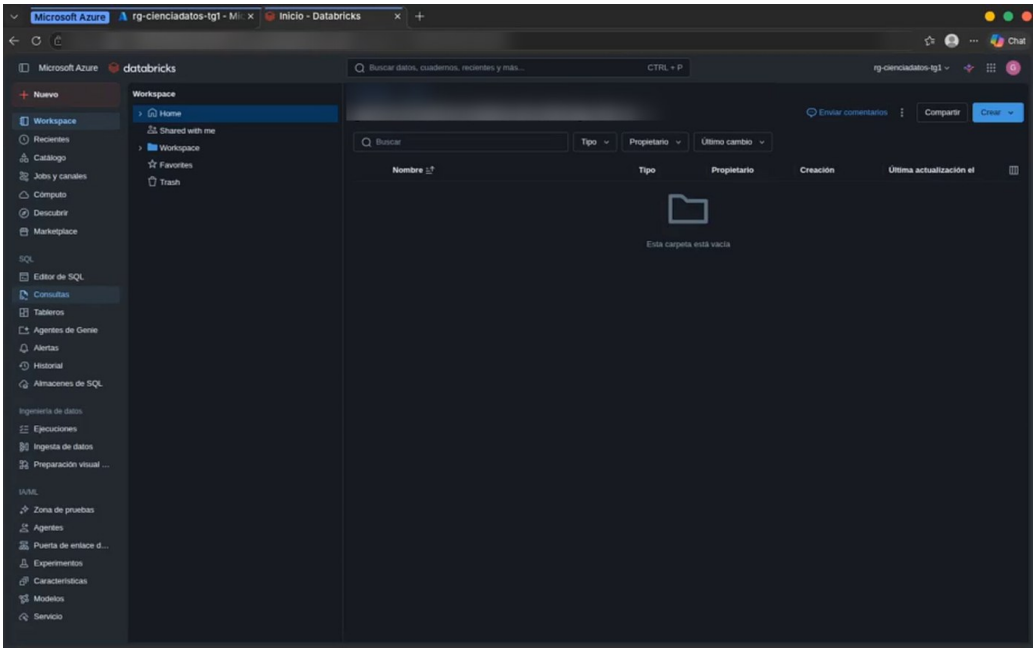


Figura 18: Abrir el espacio de trabajo

5.2 Importar el archivo

Abra el menú de la carpeta, seleccione **Import**, cargue `04_Experimento_ML_Azure_Databricks.ipynb` y confirme con **Importar**.

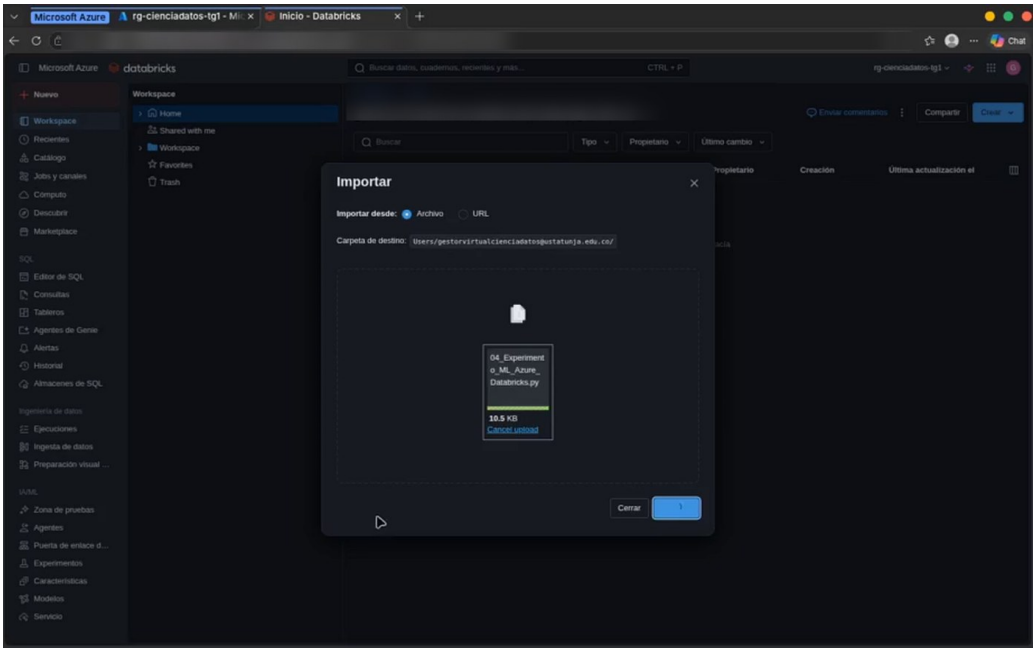


Figura 19: Importar el archivo

5.3 Revisar la descripción

El cuaderno inicia con el problema, las hipótesis, las variables y las métricas. Es una buena práctica describir el proyecto en una celda de Markdown.

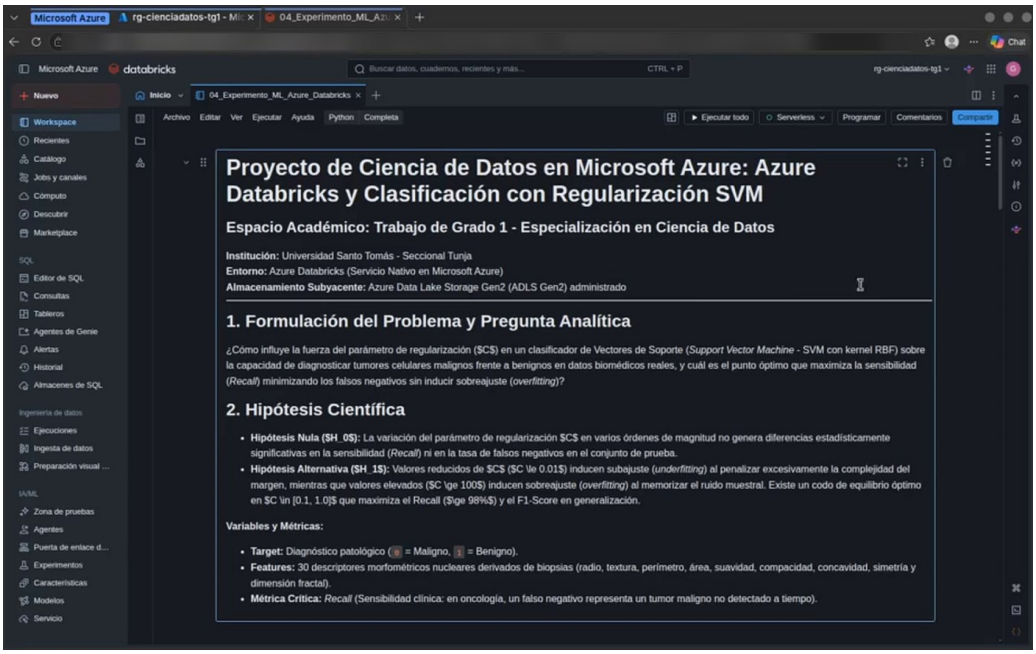


Figura 20: Revisar la descripción

6. Ejecución del experimento

6.1 Configurar el entorno

Ejecute la sección 3, que carga las bibliotecas y muestra la configuración del entorno. El cuaderno usa cómputo **Serverless**.

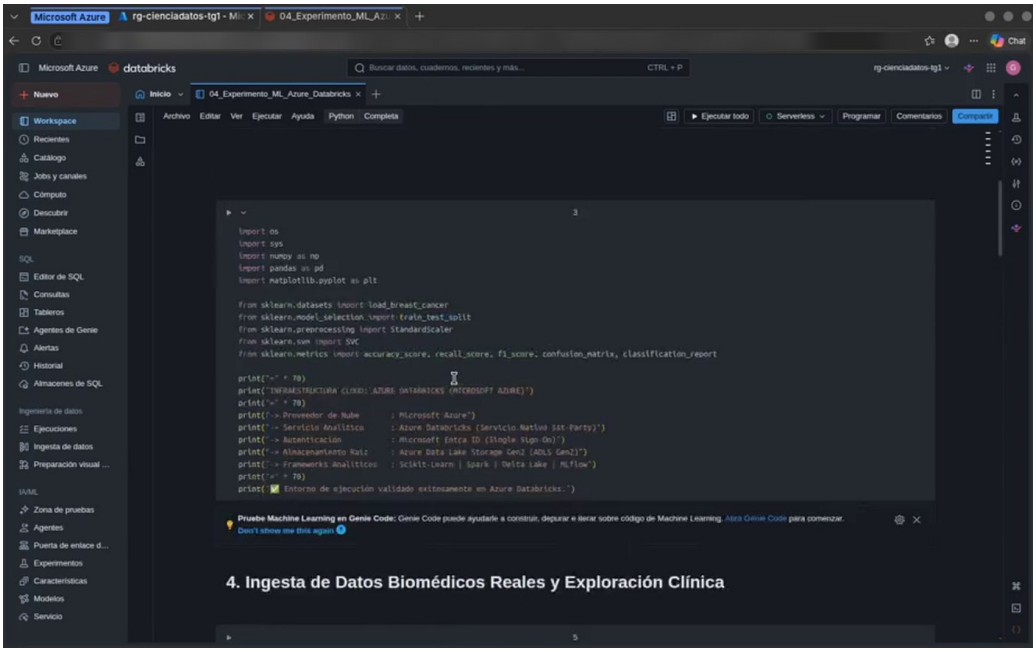


Figura 21: Configurar el entorno

6.2 Cargar los datos

Ejecute la sección 4. Se carga el conjunto de datos de cáncer de mama con `load_breast_cancer` y se muestra la distribución del diagnóstico.

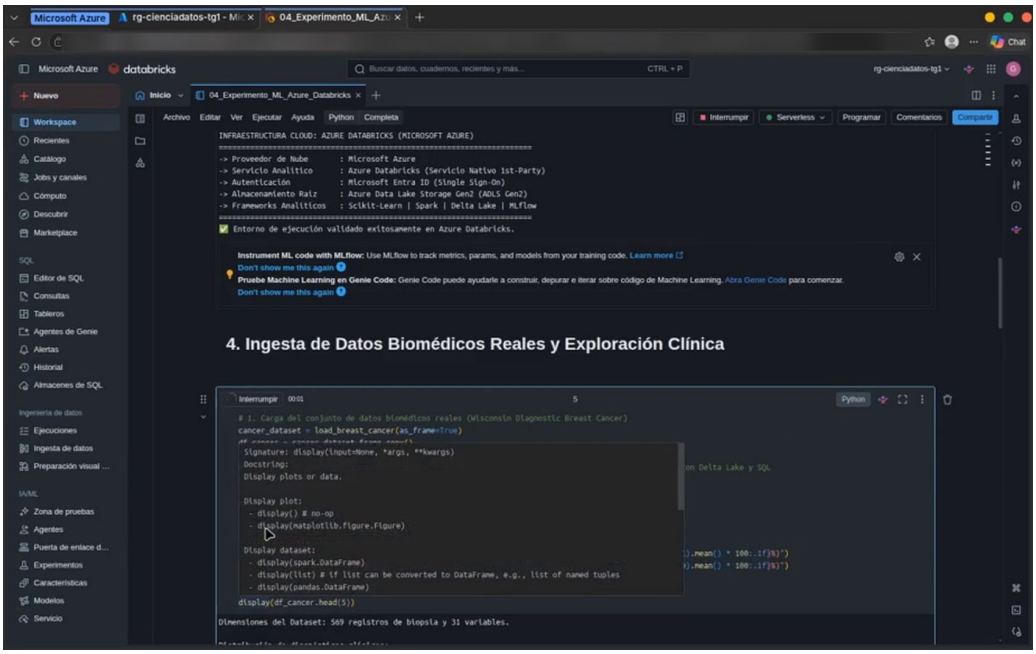


Figura 22: Cargar los datos

6.3 Barrido de regularización

Ejecute la sección 5, de partición y estandarización, y la sección 6, que entrena `SVC` con kernel RBF para valores de C entre 0,001 y 1000. La tabla compara las métricas de entrenamiento y prueba.

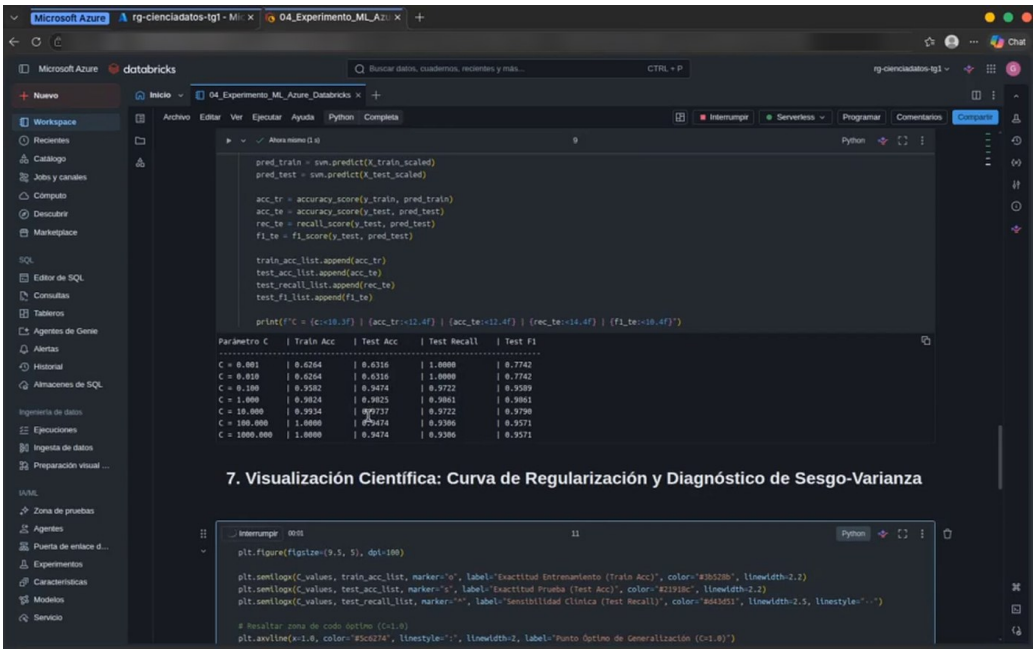


Figura 23: Barrido de regularización

6.4 Curva de regularización

La sección 7 grafica las métricas frente a C en escala logarítmica y marca el punto óptimo de generalización ($C = 1$).

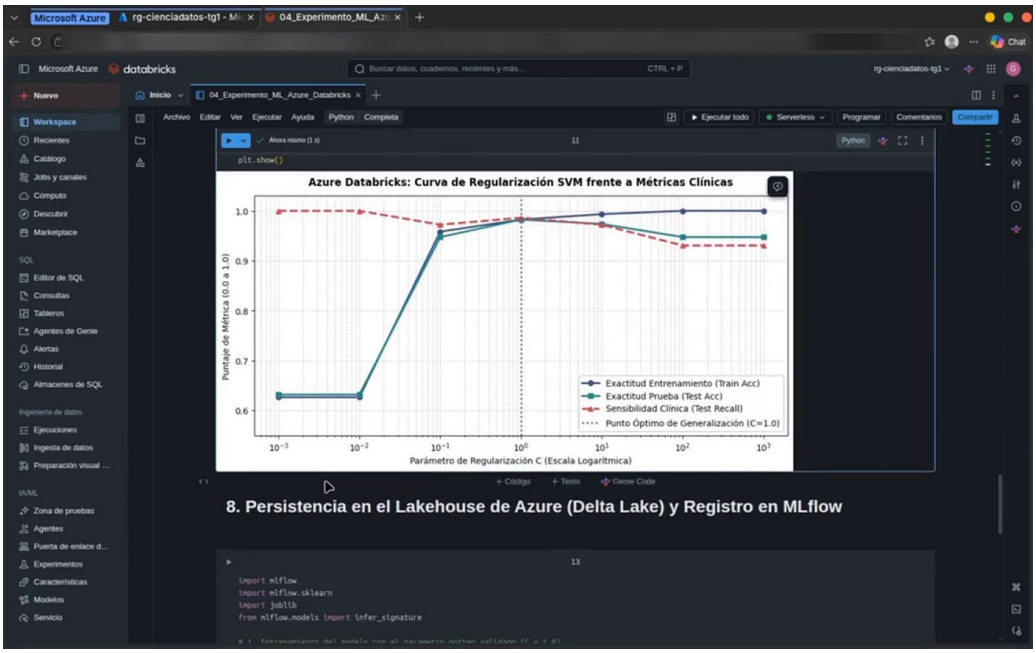


Figura 24: Curva de regularización

6.5 Persistencia y registro

La sección 8 entrena el modelo final, guarda los datos en formato Delta y registra el modelo en MLflow.

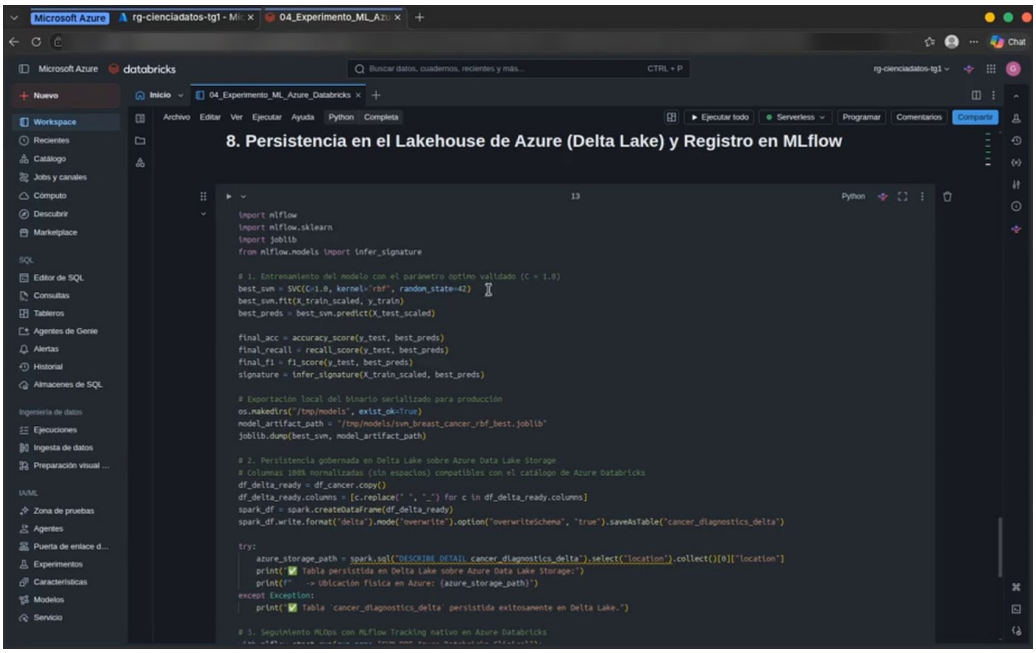


Figura 25: Persistencia y registro

6.6 Resumen del modelo

La salida confirma la tabla persistida y el registro del experimento. En la ejecución del video, con $C = 1$, la exactitud en prueba fue de 98,25 % y la sensibilidad clínica de 98,61 %.

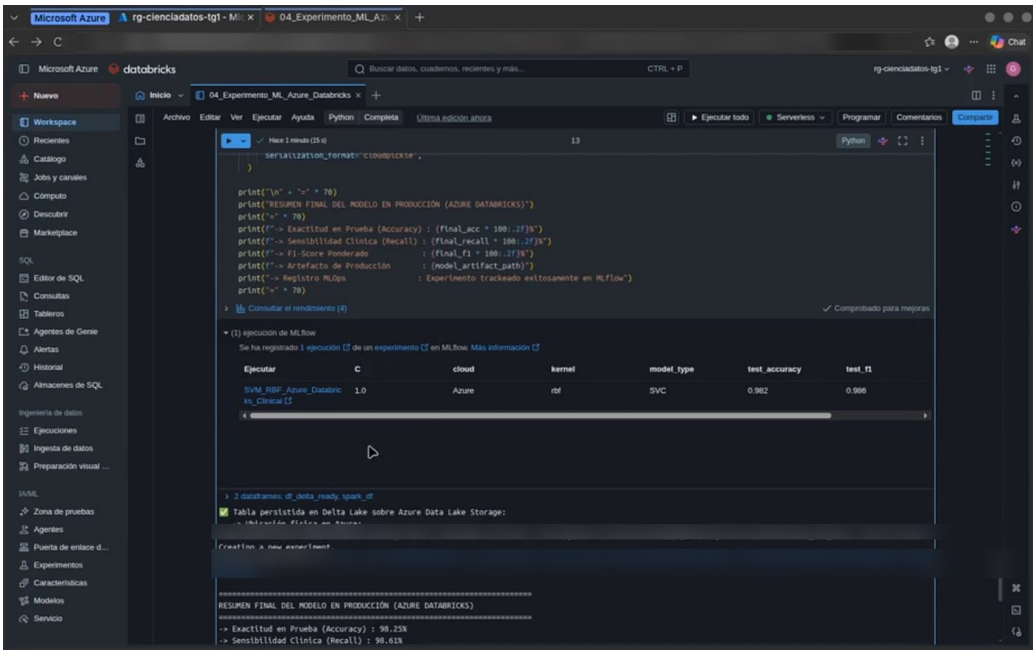


Figura 26: Resumen del modelo

7. Verificación en MLflow

7.1 Lista de experimentos

En el menú lateral, seleccione **Experimentos**. Debe aparecer `Experimento_SVM_Azure`.

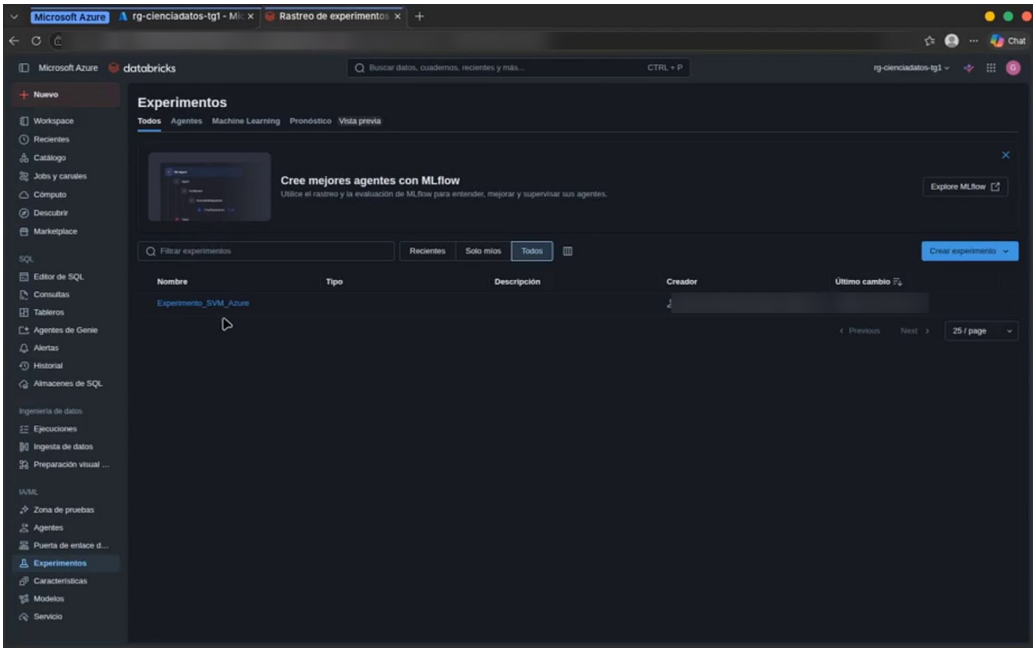


Figura 27: Lista de experimentos

7.2 Ejecución registrada

Abra el experimento para consultar la ejecución y el modelo registrado, que queda disponible para su posterior despliegue.

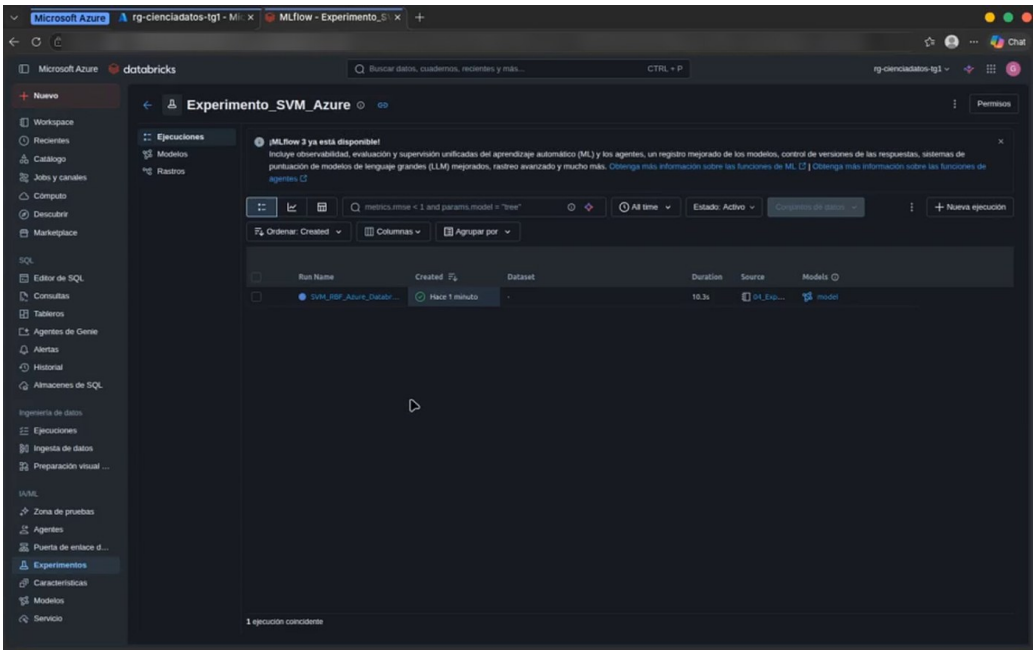


Figura 28: Ejecución registrada

Importante

Al terminar. Elimine el área de trabajo y el grupo de recursos si no continuará con la práctica, y revise el saldo de créditos en el portal de Azure.